



**UNIVERSIDADE FEDERAL DO CEARÁ  
CAMPUS DE RUSSAS  
CURSO DE GRADUAÇÃO EM ENGENHARIA CIVIL**

**EDGAR BRUNO BENICIO DE FREITAS**

**ANÁLISE DO PROCESSO DE MOAGEM EM MOINHO VERTICAL PARA PREVISÃO  
DA FINURA DO CIMENTO PORTLAND**

**RUSSAS**

**2025**

EDGAR BRUNO BENICIO DE FREITAS

ANÁLISE DO PROCESSO DE MOAGEM EM MOINHO VERTICAL PARA PREVISÃO DA  
FINURA DO CIMENTO PORTLAND

Trabalho de Conclusão de Curso apresentado  
ao Curso de Graduação em Engenharia Civil  
do da Universidade Federal do Ceará, como  
requisito parcial à obtenção do grau de bacharel  
em Engenharia Civil.

Orientadora: Profa. Dra. Rosineide Fer-  
nando da Paz

RUSSAS

2025

Dados Internacionais de Catalogação na Publicação

Universidade Federal do Ceará

Sistema de Bibliotecas

Gerada automaticamente pelo módulo Catalog, mediante os dados fornecidos pelo(a) autor(a)

---

D32a de Freitas, Edgar Bruno Benicio.

Análise do processo de moagem em moinho vertical para previsão da finura do cimento  
Portland / Edgar Bruno Benicio de Freitas. – 2025.

70 f. : il. color.

Trabalho de Conclusão de Curso (graduação) – Universidade Federal do Ceará, Campus  
de Russas, Curso de Curso de Engenharia Civil, Russas, 2025.

Orientação: Prof. Dr. Rosineide Fernando da Paz.

1. Análise de dados. 2. Finura do cimento. 3. Cimento Portland. 4. Modelagem estatística.  
I. Título.

---

CDD 620

**EDGAR BRUNO BENICIO DE FREITAS**

**ANÁLISE DO PROCESSO DE MOAGEM EM MOINHO VERTICAL PARA PREVISÃO DA  
FINURA DO CIMENTO PORTLAND**

Trabalho de Conclusão de Curso apresentado  
ao Curso de Graduação em Engenharia Civil  
do da Universidade Federal do Ceará, como  
requisito parcial à obtenção do grau de bacharel  
em Engenharia Civil.

Aprovada em: 28/01/2025

**BANCA EXAMINADORA**

---

Profa. Dra. Rosineide Fernando da Paz (Orientadora)  
Universidade Federal do Ceará (UFC)

---

Prof. Dr. Dmontier Pinheiro Aragão Jr.  
Universidade Federal do Ceará (UFC)

---

Antônio José Cruz de Araújo  
Universidade Federal do Ceará (UFC)

À minha mãe, cuja dedicação e amor incondicional foram a base de toda a minha jornada. Seu cuidado e apoio constante me deram a força e a esperança necessárias para seguir em frente, mesmo nos momentos mais desafiadores. Sou eternamente grato por tudo que você fez e continua a fazer por mim.

## **AGRADECIMENTOS**

Agradeço primeiramente à minha família, cujo apoio incondicional foi fundamental para que eu pudesse trilhar este caminho. A paciência, o amor e a compreensão de vocês foram essenciais em cada etapa desta jornada.

Aos meus amigos, que estiveram ao meu lado durante todo o curso, compartilhando momentos de alegria, desafios e conquistas. A amizade de vocês tornou essa caminhada mais leve e significativa.

Aos professores que contribuíram para minha formação acadêmica, transmitindo conhecimento e valores que levarei para toda a vida. Cada aula e orientação foram fundamentais para o meu crescimento pessoal e profissional.

Em especial, agradeço à Profa. Dra. Rosineide Fernando da Paz, minha orientadora neste TCC, por sua orientação, paciência e incentivo ao longo deste trabalho. Sua dedicação e expertise foram essenciais para a conclusão deste projeto.

Aos funcionários e técnicos da UFC Campus de Russas, por todo o suporte e assistência prestados durante minha trajetória acadêmica. A contribuição de vocês foi indispensável para a realização deste trabalho.

A todos que, de alguma forma, fizeram parte desta jornada, meu sincero agradecimento.

“O fundamental é que tenhamos sempre a capacidade de nos indignar diante da injustiça.”

(Dilma Rousseff)

## **RESUMO**

O trabalho analisa o processo produtivo de um moinho vertical em uma planta de produção de cimento, com foco na finura do cimento Portland. O mesmo visa compreender as variáveis operacionais que influenciam a finura do material, utilizando técnicas de modelagem estatística para prevê-la. Durante um período de 61 dias, foram coletadas séries temporais das variáveis alvo e preditoras, com aplicação de filtros para remoção de ruídos. O estudo busca otimizar o controle do processo produtivo, assegurando que o cimento atenda às normas técnicas, como a NBR 16697. Além disso, identifica oportunidades para práticas eficientes, contribuindo para a redução de custos energéticos e desgate de maquinário. A pesquisa destaca a importância da previsão da finura do cimento para auxílio do controle de qualidade.

**Palavras-chave:** sensor virtual. finura do cimento. análise de dados. modelagem estatística. cimento Portland.

## ABSTRACT

The study analyzes the production process of a vertical mill in a cement production plant, focusing on the fineness of Portland cement. It aims to understand the operational variables that influence the material's fineness using statistical modeling techniques to predict it. Over a period of 61 days, time series data of the target and predictor variables were collected, with filters applied to remove noise. The study seeks to optimize the production process control, ensuring that the cement meets technical standards, such as NBR 16697. Additionally, it identifies opportunities for efficient practices, contributing to reduced energy costs and machinery wear. The research highlights the importance of predicting cement fineness to aid in quality control.

**Keywords:** virtual sensor. cement fineness. data analysis. statistical modeling. portland cement.

## LISTA DE FIGURAS

Figura 1 – O Coliseu de Roma. . . . .	19
Figura 2 – Pedreira de <i>Portland Stone</i> . . . . .	20
Figura 3 – Principais matérias-primas do cimento <i>Portland</i> . . . . .	21
Figura 4 – Pilha de pré-homogeneização da matéria-prima. . . . .	22
Figura 5 – Silo e balança dosadora, que estabelecem as proporções de calcário, argila e demais minerais que entram no moinho. . . . .	22
Figura 6 – Perfil do moinho de rolo vertical. . . . .	23
Figura 7 – Torre de ciclone, onde a farinha de crú é pré-aquecida e pré-calcinada antes de entrar no forno rotativo. . . . .	24
Figura 8 – Forno rotativo, onde ocorre a clinquerização da farinha de crú. . . . .	24
Figura 9 – Transformação dos componentes da farinha crua em componentes do clínquer durante a clinquerização. . . . .	25
Figura 10 – Composição química do clínquer . . . . .	25
Figura 11 – Registro de clínquer levado para análise em laboratório. . . . .	25
Figura 12 – Lista de valores que padronizam a finura para cada tipo de cimento . . . . .	28
Figura 13 – Tabela que padroniza a composição de cada tipo de cimento. . . . .	29
Figura 14 – Esquema simplificado do processo de moagem do cimento. . . . .	30
Figura 15 – Comparação entre a finura estimada pelo sensor e a finura obtida em laboratório. . . . .	31
Figura 16 – Comparação entre a finura estimada pelo modelo preditivo e a finura obtida em laboratório. . . . .	31
Figura 17 – Ilustração do processo de moagem do cimento em moinho de bolas. . . . .	32
Figura 18 – Esquema de um moinho de bolas simplificado. . . . .	32
Figura 19 – Estado de movimento dos corpos moedores no moinho de bolas. . . . .	33
Figura 20 – Esquema do processo de moagem de farinha crua no moinho vertical. . . . .	34
Figura 21 – Finura do cimento (%). . . . .	45
Figura 22 – Vibração do moinho vertical ( $\mu\text{m}$ ). . . . .	46
Figura 23 – Potência do ventilador (kW) . . . . .	47
Figura 24 – Diferencial de pressão do bag filter (mbar) . . . . .	47
Figura 25 – Temperatura de saída ( $^{\circ}\text{C}$ ) . . . . .	48
Figura 26 – Temperatura de entrada ( $^{\circ}\text{C}$ ) . . . . .	48
Figura 27 – Velocidade do classificador (rpm) . . . . .	49

Figura 28 – Pressão de moagem (mbar) . . . . .	49
Figura 29 – Alimentação total do moinho (T/h) . . . . .	50
Figura 30 – Arraste e exaustão dos gases (%DA01) . . . . .	51
Figura 31 – Pressão no bag filter (mbar) . . . . .	51
Figura 32 – Correlação de Pearson para a Finura . . . . .	53
Figura 33 – Gráfico de dispersão para Vibração do moinho . . . . .	55
Figura 34 – Gráfico de dispersão para potência do ventilador . . . . .	56
Figura 35 – Gráfico de dispersão para o diferencial de pressão do bag filter . . . . .	56
Figura 36 – Gráfico de dispersão para temperatura de saída . . . . .	57
Figura 37 – Gráfico de dispersão para temperatura de entrada . . . . .	58
Figura 38 – Gráfico de dispersão para velocidade do classificador . . . . .	58
Figura 39 – Gráfico de dispersão para pressão de moagem . . . . .	59
Figura 40 – Gráfico de dispersão para alimentação total do moinho . . . . .	60
Figura 41 – Gráfico de dispersão para o arraste e exaustão dos gases . . . . .	60
Figura 42 – Gráfico de dispersão para pressão no bag filter . . . . .	61
Figura 43 – Regressão Linear (treinamento e teste) . . . . .	62
Figura 44 – Modelo de Árvore de Decisão (treinamento e teste) . . . . .	63
Figura 45 – Modelo de Floresta Aleatória (treinamento e teste) . . . . .	64
Figura 46 – Modelo de Regressão por Vetores de Suporte (SVR) (treinamento e teste) . .	65

## LISTA DE SÍMBOLOS

$\mu\text{m}$	Micrômetro
$\text{kW}$	kiloWatt
$\text{mbar}$	Milibar
$^{\circ}\text{C}$	Celsius
$\text{rpm}$	Rotação por minuto
$t$	Tonelada
$h$	Hora
$DA01$	Porcentagem de abertura ou posição do dispositivo

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO . . . . .</b>	<b>15</b>
<b>2</b>	<b>OBJETIVOS E JUSTIFICATIVA DO TRABALHO . . . . .</b>	<b>17</b>
<b>2.1</b>	<b>Objetivo geral . . . . .</b>	<b>17</b>
<b>2.2</b>	<b>Objetivos específicos . . . . .</b>	<b>17</b>
<b>2.3</b>	<b>Justificativa . . . . .</b>	<b>17</b>
<b>3</b>	<b>FUNDAMENTAÇÃO TEÓRICA . . . . .</b>	<b>19</b>
<b>3.1</b>	<b>Cimento Portland . . . . .</b>	<b>19</b>
<b>3.2</b>	<b>Produção do Cimento <i>Portland</i> . . . . .</b>	<b>20</b>
<b>3.3</b>	<b>Importância do controle de qualidade do Cimento <i>Portland</i> . . . . .</b>	<b>26</b>
<b>3.4</b>	<b>Finura do cimento como parâmetro de controle de qualidade . . . . .</b>	<b>27</b>
<b>3.5</b>	<b>Tipos de cimento presentes na base de dados . . . . .</b>	<b>28</b>
<b>4</b>	<b>TRABALHOS RELACIONADOS . . . . .</b>	<b>30</b>
<b>4.1</b>	<b><i>Soft sensor for real-time cement fineness estimation</i> . . . . .</b>	<b>30</b>
<b>4.2</b>	<b>Estimativa da finura do cimento durante o processo de moagem em moinho de bolas . . . . .</b>	<b>31</b>
<b>4.3</b>	<b><i>Modeling of Vertical Mill Raw Meal Grinding Process and Optimal Setting of Operating Parameters Based on Wavelet Neural Network</i> . . . . .</b>	<b>33</b>
<b>4.4</b>	<b><i>Prediction of raw meal fineness in the grinding process of cement raw material: a two-dimensional convolutional neural network prediction method</i></b>	<b>34</b>
<b>5</b>	<b>METODOLOGIA . . . . .</b>	<b>36</b>
<b>5.1</b>	<b>Correlação Linear de Pearson . . . . .</b>	<b>36</b>
<b>5.2</b>	<b>Gráficos de Dispersão . . . . .</b>	<b>37</b>
<b>5.3</b>	<b>Regressão Linear Múltipla . . . . .</b>	<b>37</b>
<b>5.4</b>	<b>Árvore de Decisão . . . . .</b>	<b>39</b>
<b>5.5</b>	<b>Floresta Aleatória . . . . .</b>	<b>39</b>
<b>5.6</b>	<b>Regressão por Vetores de Suporte . . . . .</b>	<b>40</b>
<b>5.7</b>	<b>Métricas de Avaliação dos Modelos: Erro Absoluto Médio e Raiz do Erro Quadrático Médio . . . . .</b>	<b>41</b>
<b>5.7.1</b>	<b><i>Raiz do Erro Quadrático Médio (RMSE)</i> . . . . .</b>	<b>41</b>
<b>5.7.2</b>	<b><i>Erro Absoluto Médio (MAE)</i> . . . . .</b>	<b>41</b>

<b>5.8</b>	<b>Variáveis do processo produtivo . . . . .</b>	<b>42</b>
<b>5.9</b>	<b>Lag ou Delay . . . . .</b>	<b>44</b>
<b>6</b>	<b>RESULTADOS . . . . .</b>	<b>45</b>
<b>6.1</b>	<b>Série temporal das variáveis sem aplicação do filtro . . . . .</b>	<b>45</b>
<b>6.1.1</b>	<b><i>Finura da matéria-prima.</i> . . . . .</b>	<b>45</b>
<b>6.1.2</b>	<b><i>Vibração do moinho.</i> . . . . .</b>	<b>46</b>
<b>6.1.3</b>	<b><i>Potência do ventilador.</i> . . . . .</b>	<b>46</b>
<b>6.1.4</b>	<b><i>Diferencial de pressão do bag filter</i> . . . . .</b>	<b>47</b>
<b>6.1.5</b>	<b><i>Temperatura de saída . . . . .</i></b>	<b>47</b>
<b>6.1.6</b>	<b><i>Temperatura de entrada . . . . .</i></b>	<b>48</b>
<b>6.1.7</b>	<b><i>Velocidade do classificador . . . . .</i></b>	<b>48</b>
<b>6.1.8</b>	<b><i>Pressão de moagem . . . . .</i></b>	<b>49</b>
<b>6.1.9</b>	<b><i>Alimentação total do moinho . . . . .</i></b>	<b>50</b>
<b>6.1.10</b>	<b><i>Arraste e exaustão de gases . . . . .</i></b>	<b>50</b>
<b>6.1.11</b>	<b><i>Pressão no bag filter . . . . .</i></b>	<b>51</b>
<b>6.2</b>	<b>Correlação Linear de Pearson . . . . .</b>	<b>53</b>
<b>6.3</b>	<b>Gráficos de dispersão . . . . .</b>	<b>54</b>
<b>6.4</b>	<b>Predição com Regressão Linear Múltipla . . . . .</b>	<b>62</b>
<b>6.5</b>	<b>Predição com o Modelo de Árvore de Decisão . . . . .</b>	<b>63</b>
<b>6.6</b>	<b>Predição com o Modelo de Floresta Aleatória . . . . .</b>	<b>64</b>
<b>6.7</b>	<b>Predição com o Modelo de Regressão por Vetores de Suporte (SVR) . .</b>	<b>65</b>
<b>6.8</b>	<b>Comparação de Modelos e Tempos de Execução . . . . .</b>	<b>65</b>
<b>6.8.1</b>	<b><i>Tempos de Execução dos Modelos e Análise Comparativa . . . . .</i></b>	<b>66</b>
<b>6.8.2</b>	<b><i>Escolha do Melhor Modelo . . . . .</i></b>	<b>66</b>
<b>6.8.3</b>	<b><i>Conclusão . . . . .</i></b>	<b>67</b>
<b>7</b>	<b>CONCLUSÕES E TRABALHOS FUTUROS . . . . .</b>	<b>69</b>
	<b>REFERÊNCIAS . . . . .</b>	<b>71</b>

## 1 INTRODUÇÃO

A indústria de produção de cimento desempenha um papel crucial na construção civil, sendo responsável pela fabricação de um dos materiais mais utilizados no mundo. A qualidade do cimento é um fator determinante para a durabilidade e a resistência das estruturas construídas, o que torna essencial o controle rigoroso de suas propriedades durante o processo produtivo. Entre os parâmetros está a finura da cimento, que influencia diretamente a taxa de hidratação e o desenvolvimento de resistência do cimento (ANDREATTA, 2020).

O objetivo central deste trabalho foi aplicar um modelo estatístico para prever a finura do cimento durante seu processo produtivo. Para isso, foi realizada uma análise detalhada do processo de um moinho vertical de rolos em uma planta de produção de cimento, concentrando-se na investigação das variáveis operacionais que influenciam a finura do material processado. A pesquisa envolveu uma coleta de dados abrangente ao longo de 61 dias, examinando as séries temporais das variáveis alvo e suas preditoras, com a aplicação de filtros para remover ruídos. Este estudo visou não apenas entender a dinâmica operacional do moinho, mas também identificar oportunidades para otimização do processo e melhoria na qualidade do produto final.

A importância deste estudo está na capacidade de prever a finura do cimento, um fator crucial para assegurar que o produto final atenda às exigências técnicas e normativas, como as definidas pela NBR 16697. Com a previsão da finura, é possível otimizar o controle do processo produtivo, garantindo a qualidade do cimento. Além disso, entender as variáveis que influenciam a finura do cimento pode oferecer *insights* valiosos para a adoção de práticas mais sustentáveis e eficientes, resultando na redução de custos de produção e minimização do impacto ambiental (STANIŠIĆ *et al.*, 2015).

Para prever a finura do cimento durante a moagem, foram coletados dados a cada 30 segundos por 61 dias consecutivos, processando-os com o *Software PI System*. Após eliminar *outliers* e dados irrelevantes, utilizou-se análises estatísticas como a correlação de Pearson, estimação dos coeficientes da regressão e cálculo dos p-valores para definir influências e significâncias das variáveis. Técnicas de aprendizado de máquina, como Regressão Linear Múltipla, Árvore de Decisão, Floresta Aleatória e Regressão por Vetores de Suporte, ajudaram a capturar padrões complexos. Esses modelos preditivos foram escolhidos pois já estavam implementados para estudo e execução. Além disso, avaliou-se a precisão dos modelos com MAE (*Mean Absolute Error* ou Erro Absoluto Médio) e RMSE (*Root Mean Squared Error* ou Raiz do Erro Quadrático Médio), incorporando análise de *lag* para ajustar atrasos temporais entre

variáveis preditoras e a finura do cimento, otimizando assim o processo produtivo.

Os resultados obtidos proporcionaram *insights* valiosos sobre o processo produtivo. A análise das séries temporais, juntamente com a aplicação de filtros para remoção de ruídos, permitiu identificar padrões e correlações significativas entre as variáveis operacionais e a finura do material cimentício. Embora o modelo de floresta aleatória tenha demonstrado um bom desempenho preditivo, com métricas de erro (MAE e RMSE) indicando uma precisão satisfatória, a análise comparativa dos modelos destacou que o modelo de regressão linear múltipla oferece a melhor combinação de desempenho preditivo e eficiência de tempo de execução. Isso significa que ela possui métricas parecidas ou melhores em relação aos outros modelos, porém com um custo computacional menor. Portanto, o modelo de regressão linear múltipla é recomendado como o mais apropriado para prever a finura do cimento nas condições estudadas. No entanto, a escolha final do modelo pode depender de requisitos específicos do contexto de aplicação, como a necessidade de explicabilidade ou a disponibilidade de recursos computacionais. Esses resultados fornecem uma base sólida para a otimização do processo e um controle de qualidade mais eficiente.

Este estudo não apenas contribui para o entendimento aprofundado dos fatores que influenciam a finura do cimento no processo de moagem, mas também oferece uma metodologia robusta para a análise e otimização de processos industriais similares.

## 2 OBJETIVOS E JUSTIFICATIVA DO TRABALHO

Este capítulo apresenta os objetivos (geral e específicos) do trabalho.

### 2.1 Objetivo geral

Aplicar um modelo estatístico para prever a finura do cimento, durante o processo produtivo.

### 2.2 Objetivos específicos

- Obter uma base de dados para estudo da variável alvo e suas preditoras.
- Realizar uma exploração dos dados, a fim de identificar dados ruidosos.
- Calibrar os parâmetros dos modelos de regressão linear múltipla, árvore de decisão, floresta aleatória e regressão por vetores de suporte para predizer a variável finura.
- Realizar uma comparação entre os modelos ajustados aos dados de finura.

### 2.3 Justificativa

De acordo com Stanišić *et al.* (2015), o monitoramento da finura do cimento em tempo real é crucial para otimizar o circuito de moagem e assegurar a qualidade do produto final. Esta abordagem oferece vantagens significativas em relação ao método tradicional de ensaio laboratorial, realizado a intervalos de duas horas.

O estudo destaca que prever a finura contribui para a uniformidade da qualidade do cimento, garantindo a conformidade com os padrões estabelecidos. Essa uniformidade é essencial para assegurar a consistência das propriedades do material cimentício, garantindo que o produto final satisfaça continuamente as especificações técnicas e as expectativas dos consumidores.

Além disso, Stanišić *et al.* (2015) enfatiza que a predição da finura permite ajustes imediatos nos parâmetros de moagem, otimizando o consumo de energia durante o processo. Ao evitar tanto a moagem excessiva quanto a insuficiente, há uma redução no desperdício de energia e minimização do desgaste dos equipamentos, resultando em uma operação mais eficiente e sustentável.

A predição também auxilia na prevenção de problemas associados à operação de

moinhos de cimento com alta vibração. Conforme indicado por Stanišić *et al.* (2015), problemas como trincas nos suportes, destacamento das capas dos rolos, desgaste acentuado da solda da mesa do moinho e sobrecarga no acionamento da mesa podem ser evitados através de um controle mais preciso e imediato. Isso permite ajustes nos parâmetros de operação antes que condições críticas sejam atingidas.

Lin e Qian (2014) discute que, com informações em tempo real sobre a finura do cimento, operadores e engenheiros podem tomar decisões de forma mais rápida e assertiva. Essa capacidade possibilita ajustes proativos nos parâmetros do processo, resultando em uma produção mais estável e com menos interrupções. Além disso, a implementação de sensores inteligentes permite a identificação de condições operacionais irregulares, possibilitando ações corretivas antes que a qualidade do produto seja comprometida.

Os autores Stanišić *et al.* (2015) e Lin e Qian (2014) também sugerem que a predição da finura facilita uma gestão mais eficaz do processo produtivo, permitindo maximizar a produção sem comprometer a qualidade do produto final. Isso pode levar a um aumento na produtividade e na eficiência operacional da planta. Os estudos reafirmam que, ao minimizar a necessidade de reprocessamento devido à finura inadequada e otimizar o uso de energia e recursos, a predição em tempo real desempenha um papel crucial na redução dos custos operacionais.

### 3 FUNDAMENTAÇÃO TEÓRICA

#### 3.1 Cimento Portland

A palavra cimento tem origem na palavra latina *caementum*, e faz alusão à uma pedra natural de rochedos e não esquadrejada que havia na Roma Antiga. Ao longo de 4500 anos várias sociedades utilizaram o cimento para a construção de grandes obras. Por exemplo, os egípcios (no Antigo Egito) já utilizavam um ligante composto de uma mistura de gesso calcinado para construção de seus monumentos. Já os Romanos utilizavam solos de origem vulcânica da cidade italiana de Pozzuoli, pois esse material adquiria resistência mecânica quando misturado com a água. A figura 1 , mostra o Coliseu de Roma construído em 70 d.C, com tijolos revestidos de argamassa e areia (BATTAGIN, 2009).

Figura 1 – O Coliseu de Roma.



Fonte: Wikipédia

Com o passar dos anos, o cimento foi sendo aprimorado, sendo que em 1756 o inglês John Smeathon obteve um grande resultado no estudo das propriedades desse material. Através da calcinação de calcários moles e argilosos, o mesmo obteve uma argamassa de alta resistência. Em 1818, o engenheiro francês Louis-Joseph Vicat alcançou resultados semelhantes ao de Smeathon após produzir um ligante pela mistura de componentes argilosos e calcários (BATTAGIN, 2009).

Em 1824 foi produzido o ligante que conhecemos hoje como cimento *Portland*. O construtor inglês Joseph Aspdin produziu um pó fino, que foi obtido pela queima conjunta de pedras calcárias e argila. Aspdin constatou que o cimento *Portland* possuía propriedades mecânicas semelhante à uma pedra após a secagem, além de não se dissolver em água. O nome

*Portland* faz referência à ilha Britânica de *Portland*, pois a argamassa do material produzido por Aspdin se assemelha às rochas existentes na ilha (BATTAGIN, 2009). A figura 2 mostra a pedreira de *Portland Stone*, na ilha Britânica de *Portland*.

Figura 2 – Pedreira de *Portland Stone*.



Fonte: Wikipédia

No Brasil, as iniciativas de fabricação do cimento *Portland* datam de 1888. Tendo inicio na cidade de Sorocaba-SP, lugar onde o comendador Antônio Proost Rodovalho instalou sua fábrica. Mas foi apenas em 1897 que a usina de Rodovalho lançou seu primeiro produto no mercado, o cimento Santo Antônio. O empreendimento interrompeu suas atividades em 1904, voltou a funcionar novamente em 1907 e encerrou suas atividades em 1918 (BATTAGIN, 2009).

Ainda houveram outras iniciativas, como a do engenheiro Louis Felipe de Nóbrega em 1892, que estudou na França e voltou ao Brasil para implementar seu projeto de fabricação. A fábrica foi instalada na ilha de Tiriri-PB. Porém a distância aos centros consumidores e a pequena escala de produção não contribuíram com o empreendimento, tornando-o pouco competitivo com os cimentos importados da época (BATTAGIN, 2009).

O grande marco da indústria brasileira de cimento só ocorreu em 1924, com a implantação de uma fábrica na cidade de Perus-SP pela Companhia Brasileira de Cimento *Portland*. A partir de 1926 seus produtos começaram a ser comercializados, iniciando o fim da dependência do cimento importado pelo mercado brasileiro (BATTAGIN, 2009) .

### 3.2 Produção do Cimento *Portland*

De acordo com Pereira (2012, p. 18), o cimento pode ser definido como um material com propriedades adesivas e coesivas capaz de unir fragmentos e minerais entre si, de modo a

formar um todo compacto. A primeira etapa da produção desse material é a extração de minerais, pois ele é fruto da descarbonatação de rochas calcárias.

Na etapa de extração da matéria-prima, procuram-se rochas que tenham em sua composição o carbonato de cálcio ( $\text{CaCO}_3$ ). Rochas como o calcário, a marga ou o giz (também conhecido como greda) apresentam esse mineral em sua composição química.

Além de rochas carbonáticas, outros minerais são necessários na composição da matéria-prima do cimento. Esses minerais são usados em quantidade muito pequena e atuam como corretivos, adaptando a composição química da mistura bruta aos requisitos do processo produtivo. Matérias como o minério de ferro, bauxita, xisto, argila e areia podem oferecer a porção necessária de óxido de ferro ( $\text{Fe}_2\text{O}_3$ ), alumina ( $\text{Al}_2\text{O}_3$ ) e sílica ( $\text{SiO}_2$ ). Geralmente, as fontes de matéria-prima das plantas de cimento localizam-se em suas proximidades. A figura 3 apresenta 4 das principais matérias-primas do cimento *Portland*.

Figura 3 – Principais matérias-primas do cimento *Portland*.



Fonte: Lima (2011)

Antes da etapa de pré-homogeneização, a matéria-prima que é extraída das pedreiras são encaminhadas às britadeiras (primárias e secundárias), para que as rochas sejam reduzidas em pedaços de aproximadamente 10 cm de diâmetro. Na pré-homogeneização ocorre a mistura das diferentes matérias-primas, para que a farinha crua, material que será produzido a partir dessa mistura, apresente a composição química necessária para a produção de um cimento de boa qualidade. A figura 4 mostra uma pilha de pré-homogeneização da matéria-prima do cimento *Portland*.

Na etapa anterior à alimentação do moinho, a matéria-prima passa novamente por um processo de britagem. O objetivo é reduzir o diâmetro do material bruto para aproximadamente 0,05 mm para depois armazená-lo em silos dosadores. O material que alimentará o moinho precisa ser dosado para que a farinha crua resultante tenha a composição química desejada. A figura 5 mostra a estrutura de um silo e uma balança dosadora.

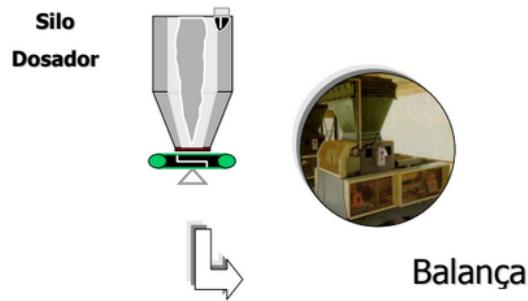
No moinho de rolos vertical a matéria bruta é reduzida até atingir a granulometria esperada. Essa máquina agrupa várias funções: trituração, moagem, secagem, separação e

Figura 4 – Pilha de pré-homogeneização da matéria-prima.



Fonte: Lima (2011)

Figura 5 – Silo e balança dosadora, que estabelecem as proporções de calcário, argila e demais minerais que entram no moinho.



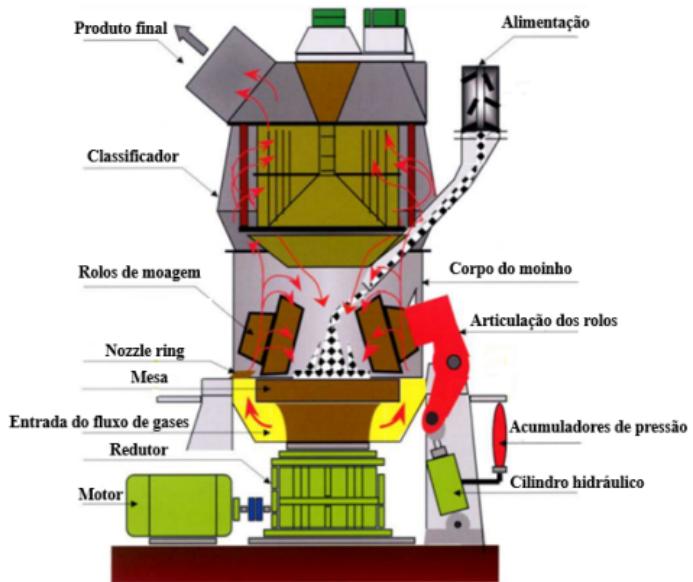
Fonte: Lima (2011)

transporte. No geral, a mesma possui sete componentes: motor de acionamento, rolos de moagem, mesa de moagem, separador, elevador, correia transportadora e o ventilador de tiragem induzida. A figura 6 ilustra a estrutura interna de um moinho de rolo vertical.

No moinho, a matéria-prima será moída por 4 rolos que atuarão sobre uma mesa giratória. A alimentação do moinho ocorre de tal forma que à princípio, o material ocupe o centro da mesa de moagem. Devido a rotação da mesa, o material é levado às extremidades pela força centrífuga. Nas bordas, o material é contido por um anel protetor. Isso contribui para a estabilidade do moinho vertical, pois essa barreira evita o contato dos rolos com a mesa (evitando a ocorrência de vibrações) já que sempre haverá material entre ambos. O material moído que ultrapassa o anel protetor é submetido à um fluxo de ar quente ascendente. Esse fluxo de ar possui 2 finalidades dentro do processo: secagem do material e transporte das partículas até o separador. No separador, as partículas que possuem a granulometria desejada são armazenadas em silos de

fluxo controlado. Neles a farinha crua produzida é homogeneizada. A armazenagem em silos de fluxo controlado também é importante para a atenuação de possíveis erros na correção de fatores, além de fazer com que o forno seja alimentado à uma vazão constante. O material não qualificado retorna ao início do processo de moagem através da correia transportadora e do elevador.

Figura 6 – Perfil do moinho de rolo vertical.



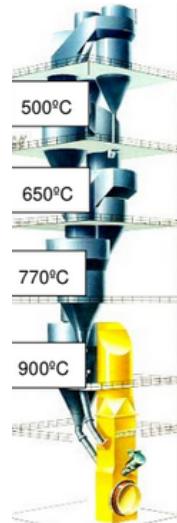
Fonte: UBE Machinery Corporation, LTD. (1980)

Depois de produzida, a farinha crua é pré-aquecida. Nessa etapa, a farinha passa por uma série de ciclones verticais (cuja estrutura externa é apresentada na figura 7), onde ela entra em contato com os gases de exaustão vindos do forno rotativo (cuja estrutura externa é apresentada na figura 8) na direção oposta. A fase de pré -aquecimento prepara a farinha para a clinquerização. Dependendo do teor de umidade do crú, o forno pode possuir até 6 estágios de ciclones, com recuperação de calor crescente a cada estágio.

Em seguida vem a etapa de pré-calcinação. A calcinação é a decomposição do calcário em cal. Uma parte dessa reação química ocorre no pré-calcinador, que é uma câmara de combustão na parte inferior do pré-aquecedor que está acima do forno. Além da cal virgem, essa reação química libera o gás carbônico. De toda farinha crua que será calcinada, cerca de 40% é convertida em gás carbônico (WBCSD, 2009).

A matéria pré-calcinada entra, então, no forno rotativo. Lá o combustível é queimado diretamente no forno para que o mesmo atinja altas temperaturas (cerca de 1450 °C). O forno gira de 3 à 5 vezes por minuto, fazendo com que a matéria-prima deslize progressivamente para

Figura 7 – Torre de ciclone, onde a farinha de crú é pré-aquecida e pré-calcinada antes de entrar no forno rotativo.



Fonte: Lima (2011)

zonas mais quentes (em direção à chama). É o calor intenso no forno que provoca as reações químicas e físicas responsáveis pela transformação da farinha crua pré-calcinada em clínquer. O clínquer está ilustrado na figura 11.

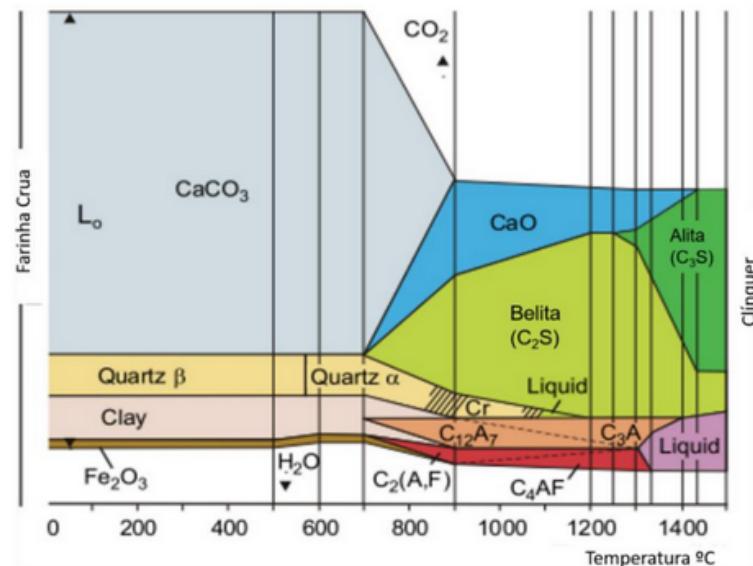
Figura 8 – Forno rotativo, onde ocorre a clinquerização da farinha de crú.



Fonte: Lima (2011)

A clinquerização é processo de transformar a farinha crua em clínquer através de tratamento térmico e está ilustrada na figura 9. A mistura de calcário e argila é aquecida até que seja parcialmente fundida. A reação química entre os óxidos componentes da farinha crua (óxidos de sílica, cálcio, ferro e alumínio) produz os principais componentes do clínquer: o Silicato Tricálcico, responsável por desenvolver a resistência do material cimentício no curto

Figura 9 – Transformação dos componentes da farinha crua em componentes do clínquer durante a clinquerização.



Fonte: Simoneto *et al.* (2020)

prazo; o silicato dicálcico, que é responsável pelo desenvolvimento do material cimentício no longo prazo; o Aluminato Tricálcico, que é responsável pelo endurecimento e o Ferroaluminato Tetracálcico, que é o responsável por realizar as ligações entre os constituintes do material cimentício que possui estrutura cristalina (PEREIRA, 2012). O quadro apresentado na figura 10 resume os principais componentes do clínquer.

Figura 10 – Composição química do clínquer

NOME DO COMPOSTO	NOTAÇÃO	NOME ABREVIADO	ÓXIDOS	CONTRIBUIÇÃO
Silicato Tricálcico	C3S	Alita	3CaO.SiO <sub>2</sub>	Desenvolve a resistência no curto prazo
Silicato Dicálcico	C2S	Belita	2CaO.SiO <sub>2</sub>	Desenvolve a resistência no longo prazo
Aluminato Tricálcico	C3SA	Fasel	3CaO.Al <sub>2</sub> O <sub>3</sub>	Endurecimento do cimento
Ferroaluminato Tetracálcico	C4AF	-	4CaO.Al <sub>2</sub> O <sub>3</sub> .Fe <sub>2</sub> O <sub>3</sub>	Realiza as ligações entre os constituintes que possuem estrutura cristalina

Fonte: Pereira (2012)

Figura 11 – Registro de clínquer levado para análise em laboratório.



Fonte: Lima (2011)

Depois de preparado, o clínquer vai para um resfriador de grelha. Para que a perda de energia do sistema de produção de cimento seja minimizada, o ar que resfria o clínquer recém preparado vêm da combustão do forno rotativo.

Após ser produzido, o clínquer será misturado com outros componentes minerais para dar origem ao cimento. O processo de produção do cimento também passa pelo moinho vertical de rolos. Geralmente a mistura é feita com escória, cinzas volantes e calcário. Além disso, todos os tipos de cimento contêm cerca de 5% gesso, pois ele contribui para as etapas do processo de endurecimento, solidificação ou enrijecimento do material cimentício (propriedade conhecida como tempo de pega).

Por fim, a mistura resfriada (composta por clínquer, gesso e aditivos) é moída. Com isso, tem-se o Cimento *Portland*, muito conhecido e utilizado em construções civis. Os aditivos que podem ser adicionados à mistura são componentes minerais, que podem gerar diversos tipos de cimento.

Após ser produzido, o cimento é homogeneizado e armazenado em silos, para daí ser expedido para uma estação de embalagem ou para um caminhão silo.

### **3.3 Importância do controle de qualidade do Cimento *Portland***

Dois indicadores são fundamentais para o controle de qualidade do cimento: a finura e a homogeneidade. A finura diz respeito à granulometria da matéria-prima após ser processada no moinho vertical. Já a homogeneidade está relacionada à proporcionalidade na composição da matéria-prima que será levada ao moinho.

O ensaio de peneira é um procedimento usado para determinar a finura do cimento. Esse parâmetro influencia diretamente as propriedades do concreto, como a taxa de hidratação, a resistência e a trabalhabilidade. Cimentos mais finos apresentam uma maior área de superfície específica, o que pode acelerar a reação de hidratação, resultando num desenvolvimento mais rápido de resistência.

O ensaio de peneira é realizado utilizando uma peneira padrão, geralmente com abertura de 75 micrômetros (número 200 de acordo com a ABNT 12826). O procedimento básico envolve a pesagem de uma amostra de cimento seco e sua passagem através da peneira, utilizando um movimento padronizado para assegurar que apenas as partículas mais finas passem.

Já o processo de medição da finura do cimento começa pela preparação da amostra. Para isso, uma amostra representativa de cimento é seca em estufa a uma temperatura de 105-

110°C. Essa etapa é crucial para remover qualquer umidade presente, garantindo que o peso medido seja preciso. Em seguida, realiza-se a pesagem inicial, onde a amostra seca é pesada com precisão utilizando uma balança analítica.

Após a pesagem inicial, a amostra é submetida ao peneiramento. Ela é colocada em uma peneira e submetida a um movimento de agitação padronizado, que pode ser realizado de forma manual ou mecânica. Esse processo dura um período específico, geralmente de 15 minutos. Finalmente, após o peneiramento, realiza-se a pesagem final. Nesta etapa, o material retido na peneira é novamente pesado. A diferença entre o peso inicial e o peso do material retido permite que se calcule a porcentagem de partículas finas presentes na amostra de cimento.

A finura do cimento é expressa como a porcentagem de material que fica retido na peneira. O quadro presente na figura 12 mostra como a ABNT NBR 16697 especifica os limites aceitáveis de finura para diferentes tipos de cimento. Um alto percentual de material fino indica um cimento de maior finura, o que pode ser desejável em algumas aplicações, mas também pode aumentar a demanda por água e afetar a trabalhabilidade do concreto.

A finura é um parâmetro crítico no controle de qualidade, pois impacta diretamente a performance do concreto. Cimentos mais finos tendem a desenvolver resistência mais rapidamente, mas também podem ser mais suscetíveis à retração e fissuração. Portanto, é essencial equilibrar a finura com outras propriedades do cimento para garantir a durabilidade e a resistência do concreto.

### **3.4 Finura do cimento como parâmetro de controle de qualidade**

A finura do cimento é um importante parâmetro de qualidade de produção. Por isso, são realizados os monitoramentos do material que está sendo processado no moinho vertical periodicamente.

O método tradicional de monitoramento consiste em avaliar amostras do material que está sendo moído em intervalos longos de tempo (geralmente de duas em duas horas). As amostras são avaliadas de acordo com a granulometria do material recolhido. A desvantagem do método tradicional de monitoramento é que cada teste de qualidade realizado revela o estado anterior do material, e não o atual.

Em contrapartida, a produção do cimento pode ser monitorada a partir de sensores virtuais. Esse método consiste em avaliar, em tempo real, a granulometria do cimento que está sendo produzido, prevendo-a. De acordo com Stanišić *et al.* (2015) , sensores virtuais são

Figura 12 – Lista de valores que padronizam a finura para cada tipo de cimento

Sigla <sup>a</sup>	Classe	Finura	Tempo de início de pega	Expansibilidade a quente	Resistência à compressão MPa				Índice de branura
		Resíduo na peneira 75 µm %			min	mm	1 dia	3 dias	
CP I	25	≤ 12,0	≥ 60	≤ 5	–	–	≥ 8,0	≥ 15,0	≥ 25,0
CP I-S	32	≤ 12,0	≥ 60	≤ 5	–	–	≥ 10,0	≥ 20,0	≥ 32,0
CP II-E	40	≤ 10,0	≥ 60	≤ 5	–	–	≥ 15,0	≥ 25,0	≥ 40,0
CP II-F	25	≤ 8,0	≥ 60	≤ 5	–	–	≥ 8,0	≥ 15,0	≥ 25,0
CP II-Z	32	≤ 8,0	≥ 60	≤ 5	–	–	≥ 10,0	≥ 20,0	≥ 32,0
CP III	40	≤ 8,0	≥ 60	≤ 5	–	–	≥ 12,0	≥ 23,0	≥ 40,0
CP IV	ARI	≤ 6,0	≥ 60	≤ 5	–	–	≥ 14,0	≥ 24,0	≥ 34,0
CPB	25	≤ 12 <sup>b</sup>	≥ 60	≤ 5	–	–	–	≥ 8,0	≥ 15,0
Estrutural	32	≤ 12 <sup>b</sup>	≥ 60	≤ 5	–	–	–	≥ 10,0	≥ 20,0
CPB	40	≤ 12 <sup>b</sup>	≥ 60	≤ 5	–	–	–	≥ 15,0	≥ 25,0
Não estrutural	–	≤ 12,0 <sup>b</sup>	≥ 60	≤ 5	–	–	–	≥ 5,0	≥ 7,0
								≥ 10,0	≥ 10,0
									≥ 82

<sup>a</sup> Requisitos aplicáveis também aos cimentos resistentes a sulfatos e de baixo calor de hidratação, identificados por sua sigla seguida do sufixo RS ou BC, respectivamente.  
<sup>b</sup> Resíduo na peneira 45 µm.

Fonte: ABNT NBR 16697.

modelos matemáticos que usam dados disponíveis para fornecer informações em tempo real sobre variáveis de processo quando as informações, por quaisquer motivos, não estão disponíveis por medição direta.

### 3.5 Tipos de cimento presentes na base de dados

Neste tópico, exploramos com maior riqueza de detalhes os tipos de cimento fabricados na planta cimenteira em questão, destacando as características distintivas de cada um, suas composições específicas e as propriedades de resistência que os tornam adequados para diferentes aplicações. Essa análise não só enfatiza as especificações técnicas, mas também ilustra como cada tipo de cimento atende às normas rigorosas de qualidade e desempenho, refletidas na sua composição e no uso de materiais suplementares, como o material carbonático e escória granulada, para otimizar suas propriedades mecânicas e químicas.

O CP II F - 32 é classificado como um cimento de classe simples com adição de material carbonático. Ele apresenta uma resistência mínima de 32 MPa aos 28 dias. A composição inclui clínquer e sulfatos de cálcio, que variam entre 75% e 79%, além de material carbonático presente entre 11% e 25%. Devido à sua classificação, permite-se a utilização de clínquer de qualidade B em sua produção (16697, 2018).

O CP III - 40 RS, conhecido como cimento Portland de alto-forno, possui resistência mínima de 40 MPa aos 28 dias e é identificado pelo acrônimo RS, que indica resistência a sulfatos. Este cimento é considerado especial e é composto por clínquer e sulfatos de cálcio entre 25% e 65%, escória granulada de alto-forno entre 35% e 75%, e material carbonático entre 11% e 25% (16697, 2018).

O CP V ARI é um cimento especial de alta resistência inicial, devendo atingir uma resistência mínima de 14 MPa em um dia e 34 MPa em sete dias. Sua composição é predominantemente de clínquer e sulfatos de cálcio, variando entre 90% e 100%, com material carbonático entre 0% e 10%. Por sua natureza especial, não é recomendada a utilização de clínquer de qualidade inferior (16697, 2018).

A figura 13 apresenta o quadro que resume a composição de cada tipo de cimento, de acordo com a ABNT NBR 16697.

Figura 13 – Tabela que padroniza a composição de cada tipo de cimento.

Designação normalizada (tipo)	Subtipo	Sigla	Classe de resistência	Sufixo
Cimento Portland comum	Sem adição	CP I	25, 32 ou 40 <sup>c</sup>	RS <sup>a</sup> ou BC <sup>b</sup>
	Com adição	CP I-S		
Cimento Portland composto	Com escória granulada de alto forno	CP II-E	25, 32 ou 40 <sup>c</sup>	RS <sup>a</sup> ou BC <sup>b</sup>
	Com material carbonático	CP II-F		
	Com material pozolânico	CP II-Z		
Cimento Portland de alto-forno		CP III	ARI <sup>d</sup>	–
Cimento Portland pozolânico		CP IV		
Cimento Portland de alta resistência inicial		CP V	ARI <sup>d</sup>	–
Cimento Portland branco	Estrutural	CPB	25, 32 ou 40 <sup>c</sup>	–
	Não estrutural	CPB	–	–

<sup>a</sup> O sufixo RS significa resistente a sulfatos e se aplica a qualquer tipo de cimento Portland que atenda aos requisitos estabelecidos em 5.3, além dos requisitos para seu tipo e classe originais.  
<sup>b</sup> O sufixo BC significa baixo calor de hidratação e se aplica a qualquer tipo de cimento Portland que atenda aos requisitos estabelecidos em 5.4, além dos requisitos para seu tipo e classe originais.  
<sup>c</sup> As classes 25, 32 e 40 representam os valores mínimos de resistência à compressão aos 28 dias de idade, em megapascals (MPa), conforme método de ensaio estabelecido pela ABNT NBR 7215.  
<sup>d</sup> Cimento Portland de alta resistência inicial, CP V, que apresenta a 1 dia de idade resistência igual ou maior que 14 MPa, quando ensaiado de acordo com a ABNT NBR 7215 e atende aos demais requisitos estabelecidos nesta Norma para esse tipo de cimento.

Fonte: ABNT NBR 16697.

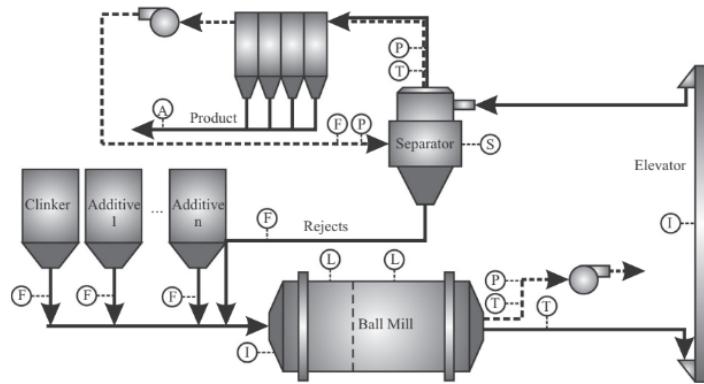
## 4 TRABALHOS RELACIONADOS

Esta seção apresenta uma introdução aos trabalhos relacionados à pesquisa. No geral, os trabalhos estão relacionados à predição da finura do material cimentício.

### 4.1 Soft sensor for real-time cement fineness estimation

Stanišić *et al.* (2015) fala sobre o uso de sensores (*soft sensors*) para a estimação da finura do cimento em tempo real durante o processo de moagem. O trabalho aborda as etapas do processo produtivo do cimento, como pode ser visto na figura 14.

Figura 14 – Esquema simplificado do processo de moagem do cimento.

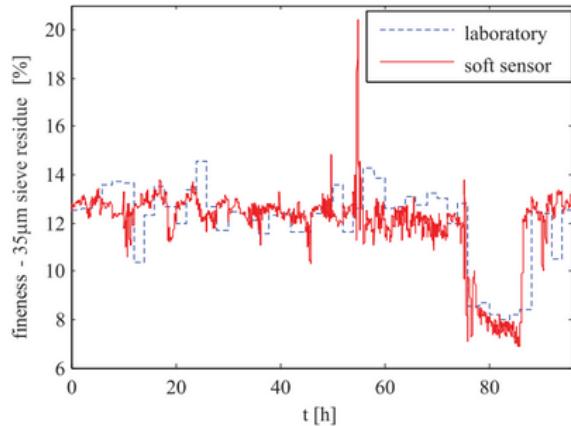


Fonte: Stanišić *et al.* (2015)

Essa abordagem é apresentada como um complemento ao método de análise da finura feita em laboratório (método *offline*) a cada duas horas. O argumento é que medindo esse parâmetro considerando esse grande intervalo de tempo entre duas análises, perde-se muita informação relevante sobre o processo de moagem.

Além disso, mesmo que análises realizadas em duas amostras consecutivas indiquem que a finura do cimento esteja dentro do padrão de qualidade estabelecido, grande parte do cimento produzido dentro desse intervalo de duas horas pode não apresentar a granulometria esperada. Os autores afirmam que 40% da energia consumida na produção de cimento ocorre durante o processo de moagem, e conhecendo-se a finura do cimento em tempo real pode-se fazer com que o moinho trabalhe com mais eficiência energética, além de uniformizar a qualidade do cimento. A figura 15 apresenta um gráfico que compara a finura estimada pelo *soft sensor* com a finura obtida em laboratório.

Figura 15 – Comparação entre a finura estimada pelo sensor e a finura obtida em laboratório.

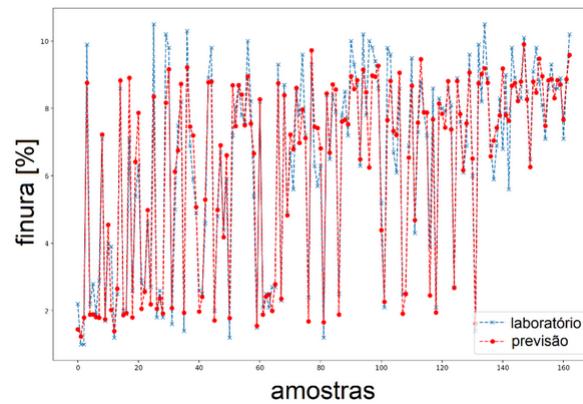


Fonte: Stanišić *et al.* (2015)

#### 4.2 Estimativa da finura do cimento durante o processo de moagem em moinho de bolas

Andreatta (2020) apresenta 3 possibilidades de modelos de regressão supervisionados para a previsão da finura online do cimento: rede neural *perceptron* multicamadas, máquina de vetores de suporte e a rede neural de função de base radial. A figura 16 apresenta um gráfico que ilustra a comparação a predição realizada pelos autores e a finura obtida em laboratório.

Figura 16 – Comparação entre a finura estimada pelo modelo preditivo e a finura obtida em laboratório.

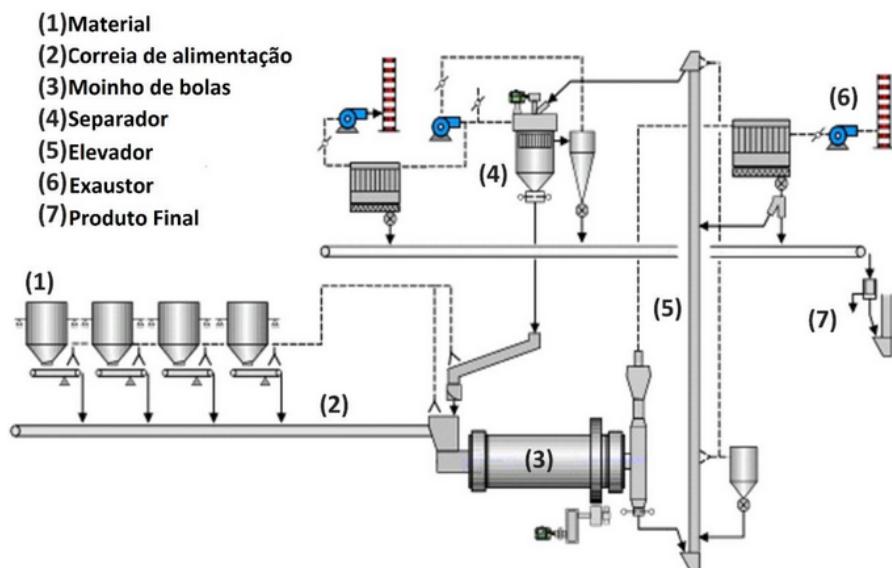


Fonte: Andreatta (2020)

A finura é apresentada como uma variável que corresponde ao tamanho dos grãos de cimento. Ela pode ser determinada tanto pelo método Blaine como pelo ensaio de peneira (que no Brasil diz respeito à ABNT NBR 11579). O Blaine é um aparelho utilizado para a determinação da superfície específica do cimento de acordo com a prescrição da norma ABNT NBR 16372. O método consiste na determinação da finura pelo método de permeabilidade ao ar e a superfície específica do grão é dada em  $\text{cm}^2/\text{g}$ . Já o ensaio de peneira calcula a porcentagem

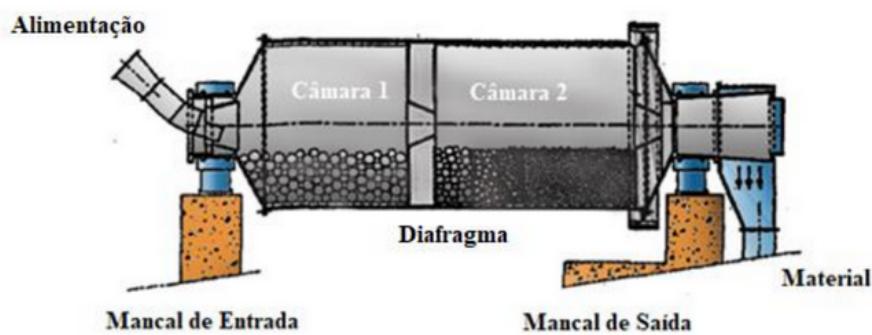
de farinha (ou cimento) retida na peneira. O texto relata que a finura é uma variável fundamental na caracterização do cimento que será produzido, e por isso o seu controle e monitoramento é importante. O monitoramento *offline* dessa variável ocorre através da análise representativa do material durante o processo de moagem. Geralmente o intervalo entre duas análises em laboratório é de duas horas. A finura do cimento está diretamente relacionada à qualidade do produto, pois quanto maior a finura, maior será a resistência à compressão do material cimentício. A finura do cimento também está diretamente relacionada ao custo de produção do cimento. A velocidade de rotação do rotor do separador é a principal responsável pela "trituração" do cimento.

Figura 17 – Ilustração do processo de moagem do cimento em moinho de bolas.



Fonte: Andreatta (2020)

Figura 18 – Esquema de um moinho de bolas simplificado.



Fonte: Andreatta (2020)

Quanto maior essa velocidade maior será a finura do cimento e, consequentemente,

Figura 19 – Estado de movimento dos corpos moedores no moinho de bolas.



Fonte: Andreatta (2020)

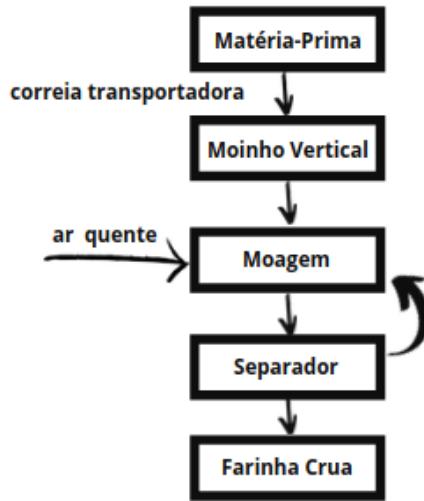
maior será o custo energético para a produção de uma tonelada de cimento (KWh/ton). Portanto, pode-se concluir que o consumo de energia e a qualidade do produto são diretamente proporcionais à finura do cimento. Esse trabalho comenta brevemente sobre todo o processo produtivo do cimento, como pode ser visto na figura 17. Além disso também há uma ênfase na estrutura externa e interna do moinho de bolas, ilustrado nas figuras 18 e 19.

#### **4.3 Modeling of Vertical Mill Raw Meal Grinding Process and Optimal Setting of Operating Parameters Based on Wavelet Neural Network**

Lin e Qian (2014) propõem um método de rede neural convolucional bidimensional que seja utilizado na previsão da finura da farinha crua durante o processo de moagem da matéria-prima. Comenta-se que a finura da farinha é obtida por ensaio de peneira de 80µm. O ensaio de peneira é realizado após a moagem da matéria prima do cimento. A previsão da finura da farinha crua é fundamental para a operação do moinho vertical, já que isso contribui para o uso mais eficiente do equipamento. Devido à complexidade do processo de produção do cimento, as variáveis desse processo se comportam, muitas vezes, de forma não linear, o que dificulta o estudo do sistema. A rede neural convolucional bidimensional foi usada para extração do acoplamento entre as variáveis, resolução do atraso da variável no tempo e das características não lineares entre elas.

Sobre o processo de moagem da matéria prima (que pode ser resumido na figura 20), o estudo cita o calcário, a argila e o pó de minério de ferro como os principais ingredientes da farinha crua. Além disso, apresenta-se os principais componentes do moinho de rolos vertical: o motor de acionamento, os rolos de moagem, a mesa de moagem, o separador, o elevador, a

Figura 20 – Esquema do processo de moagem de farinha crua no moinho vertical.



Fonte: Autor.

correia transportadora e o ventilador de tiragem induzida. O processo de produção da farinha crua inicia com a matéria prima sendo transportada para a mesa de moagem. Essa mesa é acionada pelo motor de acionamento e começa a girar até que atinja uma velocidade ideal constante. Assim a matéria-prima é "quebrada" por extrusão pelos rolos verticais. Durante esse processo, as partículas são empurradas para as bordas da mesa giratória. As partículas grandes caem diretamente no fundo do moinho e são levadas novamente à entrada do moinho pela esteira e pelo elevador, para que sejam novamente moídas. As partículas mais finas são levadas por um fluxo ascendente de ar para a câmara do moinho. O ventilador de tiragem induzida, que se localiza à saída do moinho, traz as partículas para o separador, onde o material não qualificado cai na mesa de moagem para ser moído mais uma vez. Já o material qualificado (o pó fino) vai para o armazém de farinha crua. O texto relata também que existem relações entre as diversas variáveis do processo, por exemplo, a quantidade de alimentação da matéria-prima e a corrente do motor de acionamento são diretamente proporcionais.

#### **4.4 Prediction of raw meal fineness in the grinding process of cement raw material: a two-dimensional convolutional neural network prediction method**

Liu *et al.* (2021) tiveram o objetivo de estabelecer um modelo de previsão do índice de produção do processo de moagem da farinha crua em moinho vertical, utilizando uma rede neural Wavelet. O objetivo principal foi garantir que o desempenho da produção de farinha crua

atendesse às expectativas.

O texto destaca que dois parâmetros afetam diretamente a qualidade e o rendimento da produção de farinha crua: a qualidade da matéria-prima e a estabilidade do processo produtivo. O moinho vertical é apresentado como um equipamento de moagem energeticamente eficiente que agrupa várias funções, incluindo trituração, moagem, secagem, separação e transporte da matéria-prima.

Embora se espere que o moinho vertical trabalhe para que a farinha crua obtenha uma finura pré-estabelecida e que a pressão de moagem seja estável, a produção real pode ser prejudicada pela subjetividade e arbitrariedade do operador, tornando a produção ineficiente energeticamente. Devido à complexidade dos processos físicos e químicos envolvidos, é muito difícil determinar os parâmetros operacionais ideais que orientam a produção.

A rede neural serve para estudar e resolver a não linearidade existente entre as variáveis do processo. Assim, a rede neural Wavelet foi utilizada para ajudar a selecionar os principais fatores que afetam a estabilidade da operação de moagem.

Sobre o processo de moagem da farinha crua, o texto comenta que há quatro etapas principais: alimentação, moagem, coleta de pó e seleção de pó. O processo começa com o material entrando e acumulando-se no meio da placa do moinho através da esteira transportadora. O disco giratório (mesa giratória) então leva o material para sua borda, onde os rolos o moem.

Após a moagem, inicia-se a secagem com ar quente, onde as partículas grandes são levadas novamente ao disco de moagem e as demais partículas fluem para o separador pelo fluxo ascendente de ar quente. O pó não qualificado (que não passa pelo separador) retorna ao disco de moagem para ser moído novamente, enquanto o pó fino é coletado fora da máquina.

O texto comenta que o funcionamento estável do moinho ocorre quando a diferença de pressão está entre 4500 e 6500 kPa e a granulometria do pó de farinha crua fica em torno de 80  $\mu\text{m}$ , com uma margem de 25% para mais ou para menos. A diferença de pressão de moagem (entre a entrada e a saída do moinho vertical) e a granulometria do pó de farinha crua são ressaltados como os dois principais indicadores do processo de moagem da matéria-prima.

## 5 METODOLOGIA

Para investigar as variáveis que influenciam a finura do cimento no processo de moagem, foi realizada uma coleta de dados ao longo de 61 dias de operação de um moinho vertical (19/06/2024 à 18/08/2024), com registros a cada 30 segundos de operação. Esses dados foram armazenados em arquivos no formato .csv, utilizando o *Software PI System*. A seleção dos dados foi feita com base nas variáveis relevantes identificadas em estudos anteriores e na experiência dos operadores da planta que forneceram as informações.

Para otimizar a análise, foi realizada uma exploração dos dados, a fim de preparar a base de dados para as análises subsequentes. Isso incluiu lidar com períodos de inatividade do equipamento devido a manutenções corretivas ou preventivas. Assim, foi necessário integrar dados dispersos, remover outliers, valores ausentes e variáveis não relacionadas ao objetivo do estudo. Após essa preparação, aplicaram-se modelos de aprendizado de máquina para tirar conclusões sobre o processo produtivo. Todo a análise de dados foi realizada no *Google Colab*, é um serviço hospedado do *Jupyter Notebook* que não requer configuração para ser usado e fornece acesso gratuito a recursos de computação.

Neste trabalho, utilizou-se a correlação de Pearson para quantificar a força e a direção das relações lineares entre as variáveis. A regressão linear múltipla foi empregada para entender a influência de algumas variáveis sobre a finura do cimento. Nesse contexto, os coeficientes da regressão, juntamente com seus p-valores, foram utilizados para avaliar a significância dessas influências. Para capturar padrões mais complexos, foram implementadas as técnicas: árvore de decisão, floresta Aleatória e regressão por vetores de suporte. Estes modelos podem explorar as relações não lineares (além das lineares). Para avaliação dos modelos, foram utilizadas métricas como o MAE e RMSE (erro médio absoluto e raiz do erro quadrático médio). Também foi considerada a análise de Lag ou Delay, que examina o atraso temporal entre mudanças nas variáveis preditoras e seus efeitos na finura do cimento, permitindo um ajuste mais preciso dos modelos preditivos (MENESES, 2023, p. 51).

### 5.1 Correlação Linear de Pearson

A correlação de Pearson é uma medida estatística amplamente utilizada para quantificar a força e a direção de uma relação linear entre duas variáveis numéricas. Este coeficiente é essencial em diversas áreas de pesquisa, pois fornece uma indicação clara de como duas variáveis

se comportam (uma em relação uma à outra) (FáVERO; BELFIORE, 2017, p. 381).

O coeficiente de correlação de Pearson varia de -1 a 1. Um valor próximo de 1 indica uma forte correlação positiva, o que significa que o aumento de uma variável está associado ao aumento da outra. Um valor próximo de -1 sugere uma forte correlação negativa, onde o aumento de uma variável está associado à diminuição da outra. Um valor próximo de 0 indica que não há uma relação linear clara entre as variáveis. Para produção dos gráficos, foram utilizadas as bibliotecas *python seaborn* e *matplotlib* para gerar um *heatmap*, que é uma representação gráfica das correlações entre as variáveis em um conjunto de dados.

## 5.2 Gráficos de Dispersão

Os gráficos de dispersão são ferramentas analíticas poderosas utilizadas para visualizar a relação entre duas variáveis quantitativas. Cada ponto no gráfico representa um par de valores correspondentes, permitindo aos analistas identificar facilmente padrões, tendências e possíveis correlações entre as variáveis envolvidas.

A principal vantagem dos gráficos de dispersão é a sua capacidade de mostrar como uma variável se comporta em relação à outra, proporcionando uma visão clara de tendências lineares ou não-lineares. Eles são amplamente utilizados em diversas áreas, como estatística, economia, ciências sociais e engenharia, para explorar relações em conjuntos de dados complexos.

A disposição dos pontos em um gráfico de dispersão pode revelar diferentes tipos de associações entre as variáveis, como correlação positiva, negativa ou ausência de correlação. Além disso, os gráficos de dispersão podem ajudar a identificar valores atípicos, ou seja, pontos que se desviam significativamente do padrão geral do conjunto de dados (SAINANI, 2016).

Novamente utilizou-se as bibliotecas *matplotlib* e *seaborn* para criar os gráficos de dispersão.

## 5.3 Regressão Linear Múltipla

A regressão linear múltipla é uma técnica estatística utilizada para avaliar como um conjunto de variáveis explicativas afeta uma variável de saída, que no contexto apresentado refere-se à finura do cimento. Diferente da regressão linear simples, nela se incorporam múltiplas variáveis explicativas ( $X_1, X_2, \dots, X_k$ ), permitindo que a variável dependente ( $Y$ ) seja uma função linear de duas ou mais variáveis independentes. Neste modelo, os coeficientes ( $\beta$ ) são estimados

e indicam a magnitude e direção do impacto das variáveis explicativas. A equação também considera um termo de erro ( $u$ ) que captura a variação não explicada pelas variáveis no modelo. Para uma aplicabilidade robusta, assume-se que a média dos erros é zero, a variância é constante, e que as observações são independentes, o que pode ser validado com o uso de resíduos e técnicas como validação cruzada.

Além disso, o método dos mínimos quadrados é geralmente empregado para estimar os parâmetros, minimizando a soma dos resíduais quadráticos. Este método não requer premissas de distribuição normal para o erro, mas pressupõe erros homocedásticos e não correlacionados, com distribuição normal. Este conjunto de suposições apoia a inferência precisa e a capacidade preditiva do modelo regressivo, que é comumente representado em notação matricial como  $Y = X\beta + u$ , integrando todos os elementos do modelo de forma sistemática e coesa (MENESES, 2023, p.30).

Na regressão linear múltipla, os testes de hipótese desempenham um papel crucial na validação da relevância das variáveis inclusas no modelo. Cada coeficiente associado às variáveis independentes é submetido a um teste individual, utilizando o teste t, para determinar se ele é significativamente diferente de zero e, portanto, se tem um impacto estatisticamente relevante na variável dependente. Este processo envolve o cálculo de um valor t para cada coeficiente, comparando seu valor observado com o erro padrão do coeficiente. A rejeição da hipótese nula, que sugere que o coeficiente é igual a zero, indica que a variável desempenha um papel significativo no modelo. Essa análise específica permite não apenas avaliar a significância individual de cada variável, mas também entender a estrutura de relevância do conjunto de variáveis no modelo (GILES; SRIVASTAVA, 1993).

O cálculo do p-valor é um componente essencial desse processo de teste de hipótese. Ele fornece uma medida de evidência contra a hipótese nula: quanto menor o p-valor, maior é a evidência contra a hipótese de que o coeficiente seja zero. Na prática, um p-valor é comparado a um nível de significância previamente definido, como 0,05. Se o p-valor de um coeficiente é inferior ao nível de significância, rejeitamos a hipótese nula, indicando que há evidência estatística suficiente para afirmar que o coeficiente associado é diferente de zero. Isso sugere que a variável independente correspondente é um preditor significativo da variável dependente no contexto do modelo. Assim, o p-valor fornece uma forma quantitativa e objetiva de avaliar a significância dos coeficientes estimados na regressão, guiando o refinamento do modelo e a interpretação dos resultados obtidos (GILES; SRIVASTAVA, 1993).

Para geração dos gráficos e cálculo dos p-valores foram utilizadas duas bibliotecas *python*: *scikit-learn* (usando módulo *LinearRegression*) e *statsmodels*.

## 5.4 Árvore de Decisão

A Árvore de Decisão é uma técnica de aprendizado de máquina utilizada para fazer previsões com base em decisões que seguem uma estrutura hierárquica. Este modelo é amplamente aplicado em problemas de classificação e regressão devido à sua simplicidade e interpretabilidade (DEHGHANI *et al.*, 2023).

A construção de uma árvore de decisão começa com a identificação da variável dependente que se deseja prever. O modelo analisa as variáveis independentes para determinar quais características dividem melhor o conjunto de dados em diferentes ramos. Por exemplo, na predição da qualidade de um produto, características como temperatura, pressão e tempo podem ser usadas para construir os nós da árvore.

Cada nó interno da árvore representa uma decisão sobre uma variável independente que divide o espaço de dados. O modelo utiliza condições de divisão para separar os dados em subconjuntos mais homogêneos, facilitando a previsão da variável alvo.

Por fim, as folhas da árvore representam as previsões finais ou classes. A previsão é feita navegando pela árvore de decisão a partir do nó raiz até uma folha, com base nas características das amostras. A simplicidade do modelo permite fácil interpretação dos resultados, uma vez que a árvore fornece uma representação clara e visual das decisões tomadas.

Para geração dos gráficos foi utilizada a biblioteca *scikit-learn* (usando módulo *DecisionTreeRegressor*).

## 5.5 Floresta Aleatória

A Floresta Aleatória é uma técnica de aprendizado de máquinas que combina múltiplas árvores de decisão para melhorar a precisão e a robustez da previsão. Este método é especialmente eficaz em problemas de classificação e regressão, onde a variabilidade das árvores individuais pode ser reduzida pela agregação (FáVERO *et al.*, 2023).

O processo inicia-se com a criação de múltiplas árvores de decisão, cada uma treinada em diferentes subconjuntos aleatórios dos dados, conhecidos como amostras de bootstrap. Cada árvore contribui para a variabilidade geral do modelo.

Durante o crescimento de cada árvore, um subconjunto aleatório de características é selecionado em cada nó de divisão. Esse procedimento promove a diversidade entre as árvores e reduz o risco de *overfitting*.

A previsão final de uma floresta aleatória é obtida combinando as previsões de todas as árvores no conjunto. Na classificação, a previsão final é determinada por votação majoritária, enquanto na regressão, é calculada pela média das previsões das árvores. Esta abordagem melhora tanto a precisão quanto a estabilidade do modelo.

Para geração dos gráficos foi utilizada a biblioteca *scikit-learn* (usando módulo *RandomForestRegressor*).

## 5.6 Regressão por Vetores de Suporte

A Regressão por Vetores de Suporte (SVR) também é uma técnica utilizada para resolver problemas de regressão, buscando encontrar uma função que tenha, no máximo, uma determinada margem de desvio ( $\varepsilon$ ) para todas as amostras do treinamento, ao mesmo tempo em que é tão plana quanto possível (ZHANG; O'DONNELL, 2020).

O objetivo da SVR é encontrar um hiperplano em um espaço multidimensional que não apenas separa os dados, mas que também se aproxima dos pontos de dados o quanto possível, respeitando uma margem de tolerância predefinida. Isso é especialmente útil para capturar o padrão nos dados com um controle sobre a tolerância ao erro.

Ao contrário das SVM's (Máquinas de Vetores de Suporte) de classificação, a SVR tenta ajustar o melhor hiperplano dentro de uma margem ( $\varepsilon$ ), enquanto minimiza o erro previsto fora dessa margem. Isso é feito incorporando um termo de penalização de erro que controla as exceções, permitindo um equilíbrio entre precisão do modelo e capacidade de generalização.

Quando a relação entre as variáveis independentes e a dependente não é linear, a SVR pode aplicar funções kernel para mapear os dados em espaços de maior dimensão, onde a regressão linear pode ser realizada de maneira eficaz. Isso permite que o modelo capture complexas relações não lineares e, assim, forneça previsões mais precisas.

Para geração dos gráficos foi utilizada a biblioteca *scikit-learn* (usando módulo *SVR*).

## 5.7 Métricas de Avaliação dos Modelos: Erro Absoluto Médio e Raiz do Erro Quadrático Médio

As métricas de avaliação MAE (Erro Absoluto Médio) e RMSE (Raiz do Erro Quadrático Médio) são fundamentais na análise de modelos de regressão, oferecendo perspectivas quantitativas sobre a precisão das previsões.

### 5.7.1 Raiz do Erro Quadrático Médio (RMSE)

Derivado diretamente do MSE, o RMSE é a raiz quadrada do MSE e caracteriza a dispersão do erro na mesma dimensão das variáveis originais, sendo mais intuitivo para interpretação. A fórmula é:

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

O RMSE é preferido quando se deseja uma métrica que retorne o erro em unidades comparáveis às das variáveis de entrada, facilitando a compreensão do impacto dos erros no contexto dos dados. Em ambos os casos, valores mais baixos de MSE e RMSE indicam um melhor ajuste do modelo aos dados, refletindo previsões mais precisas e confiáveis. Essas métricas são, portanto, essenciais na escolha e ajuste de modelos de regressão, permitindo que os analistas determinem a eficácia do modelo e identifiquem potenciais necessidades de aprimoramento (SHOBHA; RANGASWAMY, 2018).

### 5.7.2 Erro Absoluto Médio (MAE)

O Erro Absoluto Médio (MAE) é uma métrica utilizada para avaliar a precisão de modelos de previsão, especialmente em problemas de regressão. Ele calcula a média das diferenças absolutas entre os valores reais e as estimativas feitas pelo modelo. A fórmula do MAE é dada por:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

onde  $n$  representa o número de observações,  $y_i$  é o valor real e  $\hat{y}_i$  é o valor previsto.

O MAE é uma métrica simples e de fácil interpretação, pois é expresso na mesma unidade dos dados originais. Ele permite avaliar quão próximas as previsões do modelo são dos valores reais, em média.

Um valor baixo de MAE indica que as previsões estão próximas dos valores reais, o que sugere um modelo preciso. Por outro lado, um valor mais alto de MAE sugere maior discrepância entre as previsões e os valores reais, indicando menor precisão.

O MAE é preferido em certos contextos devido à sua robustez em relação a *outliers*, ao contrário do Erro Quadrático Médio (MSE), que penaliza em maior grau as grandes discrepâncias, uma vez que ele utiliza a soma dos quadrados das diferenças. Dessa forma, o MAE fornece uma medida direta e confiável da precisão de modelos de previsão (de Myttenaere *et al.*, 2016).

Para cálculo das métricas de avaliação em *python* foi utilizada a biblioteca *scikit-learn* (usando os módulos *mean\_absolute\_error* e *mean\_squared\_error*).

## 5.8 Variáveis do processo produtivo

- Tipo de Cimento (sem unidade), que é uma variável categórica que identifica qual tipo de cimento está sendo produzido. Para que ela fosse incluída no modelo foram utilizadas 2 variáveis *dummy*.
- Vibração do moinho ( $\mu\text{m}$ ), que é um indicador crucial da saúde operacional do equipamento. Vibrações excessivas podem indicar problemas mecânicos, como desalinhamento, desgaste dos rolamentos ou desbalanceamento dos componentes rotativos. No processo de moagem, manter vibrações dentro de limites aceitáveis é essencial para garantir a eficiência do moinho e prevenir falhas que possam interromper a produção.
- Potência do ventilador (kW), que está diretamente relacionada à eficiência do sistema de ventilação no moinho, que é responsável por mover o ar através do sistema, afetando a temperatura e a pressão internas, que são críticas para o controle da qualidade do produto final. Uma potência elevada pode indicar obstruções ou mau funcionamento que precisam ser corrigidos para otimizar o processo de moagem.
- Diferencial de pressão do *bag filter* (mbar), que é uma medida da eficiência de filtragem e da resistência ao fluxo de ar. Um diferencial de pressão elevado pode indicar que o filtro está saturado com partículas, necessitando de limpeza ou substituição. Manter um diferencial de pressão adequado é essencial para garantir que o ar liberado na atmosfera esteja dentro das normas ambientais e para proteger o equipamento de sobrecargas.

- Temperatura de saída (°C), que é uma variável crítica que influencia a qualidade do cimento produzido. Temperaturas muito altas podem causar a desidratação do gesso, levando a problemas de qualidade no cimento, como o endurecimento rápido. O controle da temperatura de saída é, portanto, essencial para garantir a consistência e a qualidade do produto final.
- Temperatura de entrada (°C), que afeta diretamente a eficiência do processo de moagem. Temperaturas adequadas ajudam a otimizar a umidade do material, melhorando a eficiência de moagem e prevenindo problemas como a formação de aglomerados. Um controle preciso dessa temperatura é importante para maximizar a eficiência energética e a qualidade do produto.
- Velocidade do classificador (rpm), que determina o tamanho das partículas que são separadas e recirculadas no sistema de moagem. Ajustar corretamente a velocidade do classificador é crucial para garantir que o produto final tenha a granulometria desejada, afetando diretamente a reatividade e as propriedades do cimento.
- Pressão de moagem (mbar), que é uma medida da força aplicada pelos rolos de moagem sobre o material. Uma pressão adequada é essencial para garantir uma moagem eficiente, afetando a finura do cimento e a eficiência energética do processo. Pressões inadequadas podem levar a um desgaste excessivo dos equipamentos e a uma qualidade inferior do produto.
- Alimentação total do moinho (t/h), que é um parâmetro fundamental que afeta a capacidade de produção e a eficiência do processo de moagem. Controlar a alimentação é crucial para evitar sobrecargas e garantir que o moinho opere dentro dos parâmetros ideais, maximizando a produção e mantendo a qualidade do cimento.
- Arraste e exaustão de gases (%DA01), que são importantes para o controle de temperatura e a remoção de umidade do sistema de moagem. Um controle eficaz dessa variável ajuda a otimizar a eficiência energética e a qualidade do produto, além de garantir que o sistema opere de forma segura e dentro dos limites ambientais.
- Pressão no *bag filter* (mbar), que é um indicador da eficiência do sistema de filtragem de ar. Manter uma pressão adequada é essencial para garantir que o ar seja filtrado corretamente, protegendo o meio ambiente de emissões de partículas e assegurando que o sistema de ventilação opere de forma eficiente.

## 5.9 Lag ou Delay

O conceito de *lag* ou *delay* refere-se ao atraso temporal entre uma ação ou mudança em uma variável e o seu efeito observado em outra variável (MENESES, 2023, p.33). Em sistemas dinâmicos, como os processos industriais, esse atraso pode ser devido a inércia física, tempos de resposta dos equipamentos ou processos de acumulação. O *lag* é um aspecto crítico a ser considerado na modelagem e controle de processos, pois pode afetar a precisão das previsões e a eficácia das ações de controle (ELLIS, 2004).

Quando analisa-se a finura do cimento como variável alvo, o conceito de *lag* pode ser visualizado ao examinar como as mudanças nas variáveis preditoras influenciam essa finura ao longo do tempo.

No caso da vibração do moinho, alterações podem não ter um impacto imediato na finura do cimento, mas podem indicar problemas mecânicos que, com o tempo, afetam o processo de moagem e, consequentemente, a finura.

Quanto à potência do ventilador, um ajuste pode levar algum tempo para estabilizar o fluxo de ar e, assim, impactar a eficiência da separação de partículas, refletindo-se na finura do cimento após um certo atraso.

Alterações na velocidade do classificador podem modificar a classificação das partículas, impactando a finura do cimento com um certo atraso, dependendo da dinâmica do sistema.

Mudanças na pressão de moagem podem levar a ajustes na compactação do material, afetando a finura com um *lag* que depende da resposta do material e do equipamento.

Variações na alimentação total do moinho podem impactar a carga do moinho e a eficiência de moagem, com efeitos na finura que podem demorar a se manifestar.

## 6 RESULTADOS

Este capítulo apresenta os resultados das análises realizadas com base na coleta de dados referentes ao processo produtivo de um moinho vertical em uma planta de produção de cimento. Analisa-se, nesta seção, a influência das variáveis operacionais sobre a finura da matéria-prima processada.

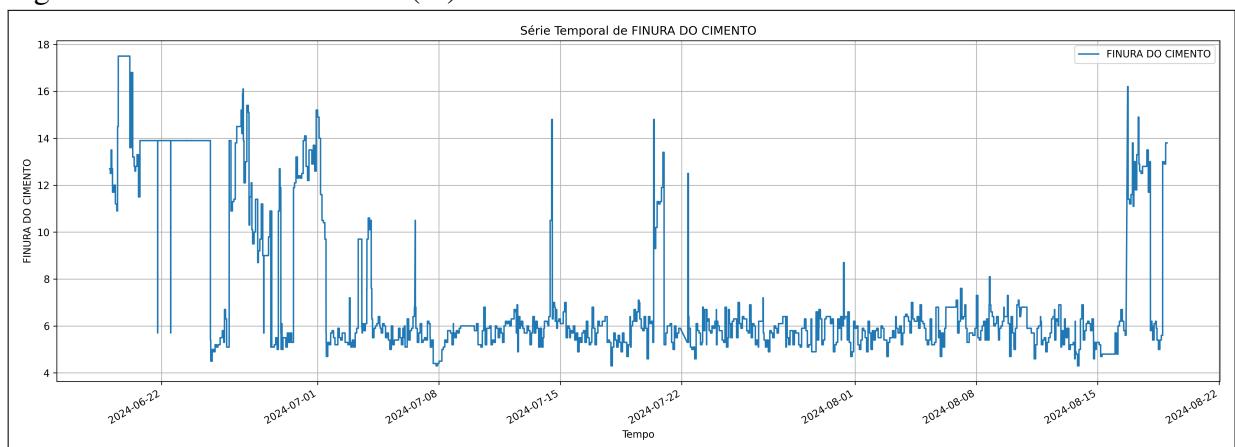
### 6.1 Série temporal das variáveis sem aplicação do filtro

Esta seção mostra os gráficos de série temporal da variável alvo e suas respectivas preditoras sem a aplicação de filtros para remoção de ruídos (conforme pode ser visto da figura 22 até a figura 32). O intervalo de tempo utilizado para produção das análises vai do dia 19/06/2024 á 18/08/2024, totalizando 61 dias.

#### 6.1.1 Finura da matéria-prima.

A finura da matéria-prima é dada em porcentagem para representar a quantidade de material que fica retido na peneira de ensaio (cuja malha é de 75 micrômetros). O gráfico mostra que não há o registro de valores negativos e isso está de acordo com o que se espera. Porém existe uma preocupação sobre o limite superior dos dados. Em alguns momentos, os valores ultrapassam 12%, que é o valor máximo de finura permitido para a amostra.

Figura 21 – Finura do cimento (%).

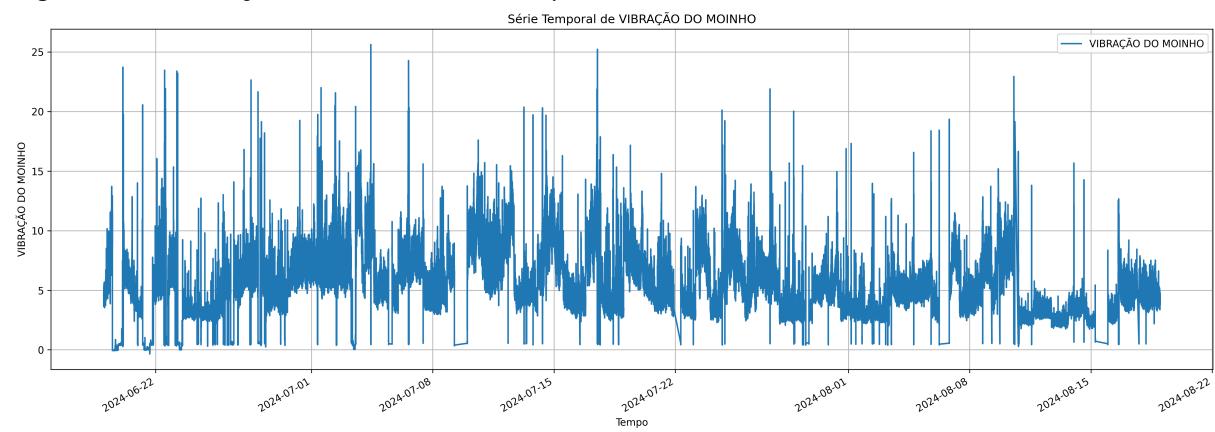


Fonte: Elaborado pelo autor (2024).

### 6.1.2 Vibração do moinho.

Para a vibração do moinho, não houve a detecção de valores muito discrepantes que pudessem ser classificados como *outliers*. Os valores iguais a 0 não são relevantes para a análise das variáveis que influenciam a vibração do corpo do moinho, pois indicam períodos em que o equipamento esteve parado ou com os rolos suspensos.

Figura 22 – Vibração do moinho vertical ( $\mu\text{m}$ ).

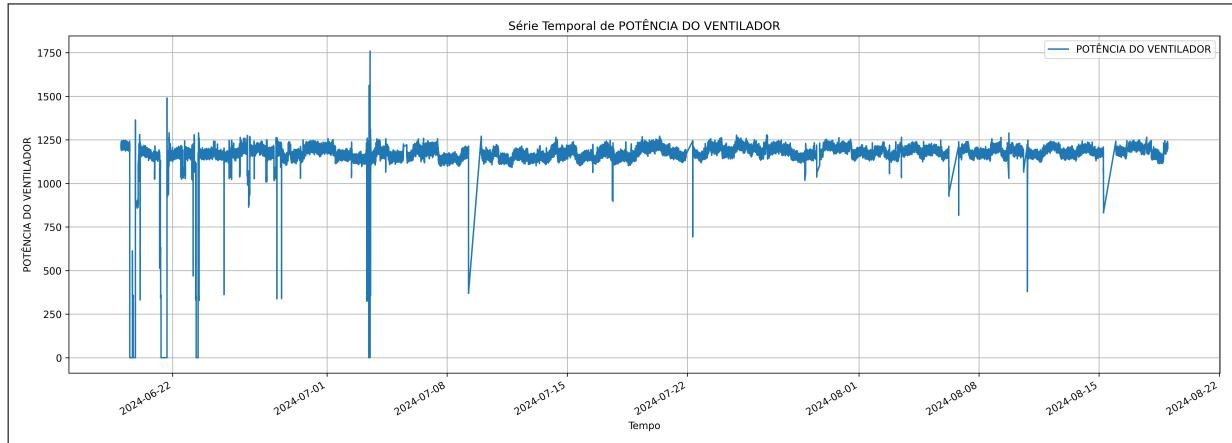


Fonte: Elaborado pelo autor (2024).

### 6.1.3 Potência do ventilador.

A potência do ventilador desempenha um papel crucial na eficiência e qualidade da produção, pois controla a circulação de ar e a temperatura no moinho de rolos. Quando essa potência está zerada, diversas interpretações são possíveis, cada uma com suas próprias implicações. O caso mais simples é: a potência zerada indica a parada do moinho. Assim, a leitura de potência zerada foi retirada para a melhor análise do processo produtivo. Também não foi encontrado nenhum *outlier* para o limite superior.

Figura 23 – Potência do ventilador (kW)

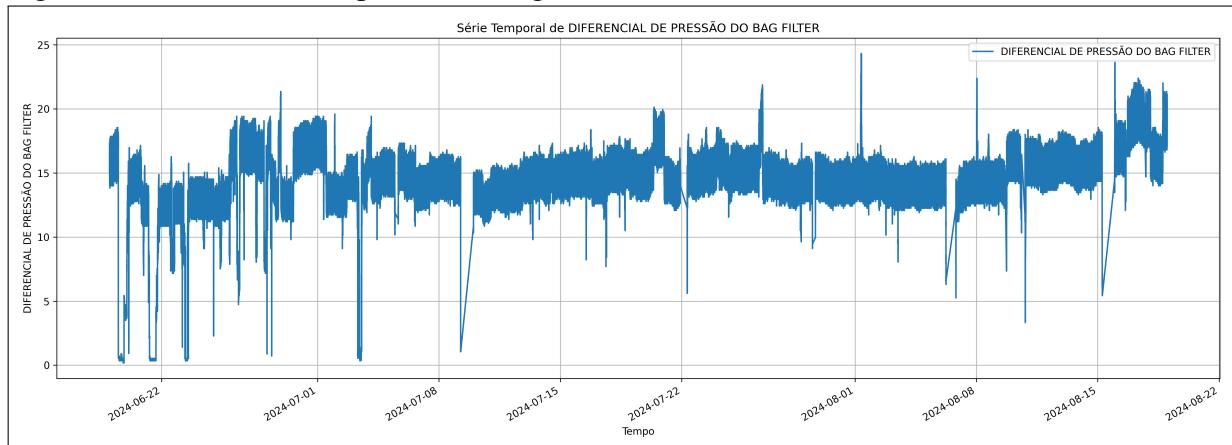


Fonte: Elaborado pelo autor (2024).

#### 6.1.4 Diferencial de pressão do bag filter

No diferencial de pressão do *bag filter* também não foi encontrado nenhum *outlier* para seu limite superior. Porém houve o registro de valores zerados (ou próximo disso). A presença de valores zerados ou próximos de zero no diferencial de pressão do *bag filter* pode indicar possíveis anomalias ou erros no processo de medição e, por isso, a importância de removê-los ou tratá-los adequadamente na análise de dados é crucial.

Figura 24 – Diferencial de pressão do bag filter (mbar)

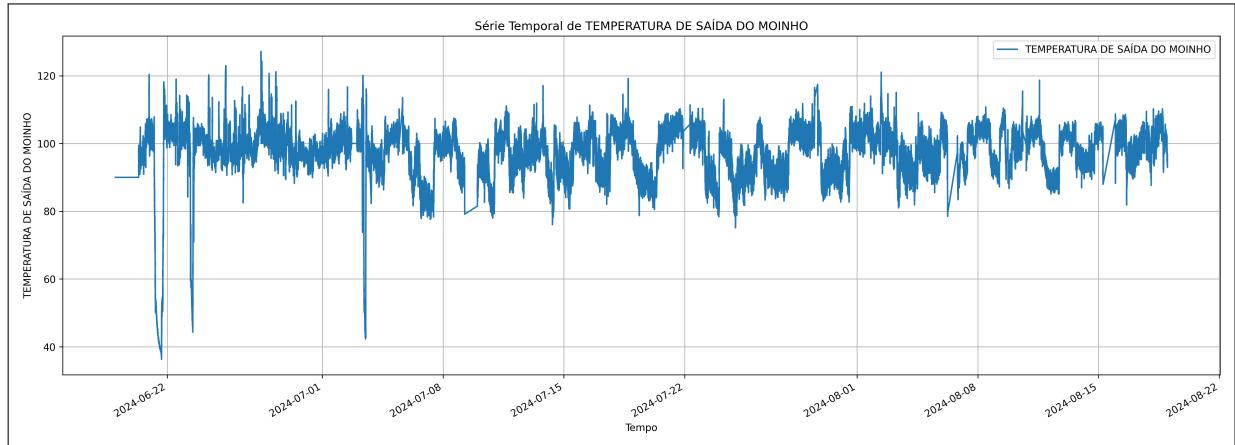


Fonte: Elaborado pelo autor (2024).

#### 6.1.5 Temperatura de saída

A remoção de valores zerados ou próximos de zero nas medições de temperatura de saída do moinho vertical de rolos é essencial para garantir a precisão e eficiência na análise do processo de moagem, pois desconsidera-se os períodos de parada.

Figura 25 – Temperatura de saída (°C)

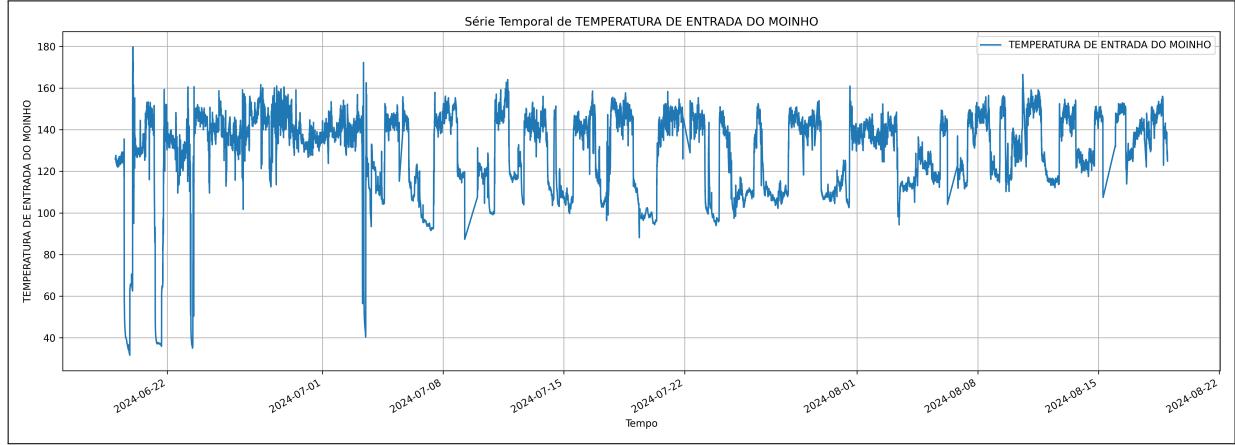


Fonte: Elaborado pelo autor (2024).

#### **6.1.6 Temperatura de entrada**

Da mesma forma que na temperatura de saída do moinho, foram desconsiderados os valores zerados e próximos de zero (períodos de parada) para análise da variável.

Figura 26 – Temperatura de entrada (°C)

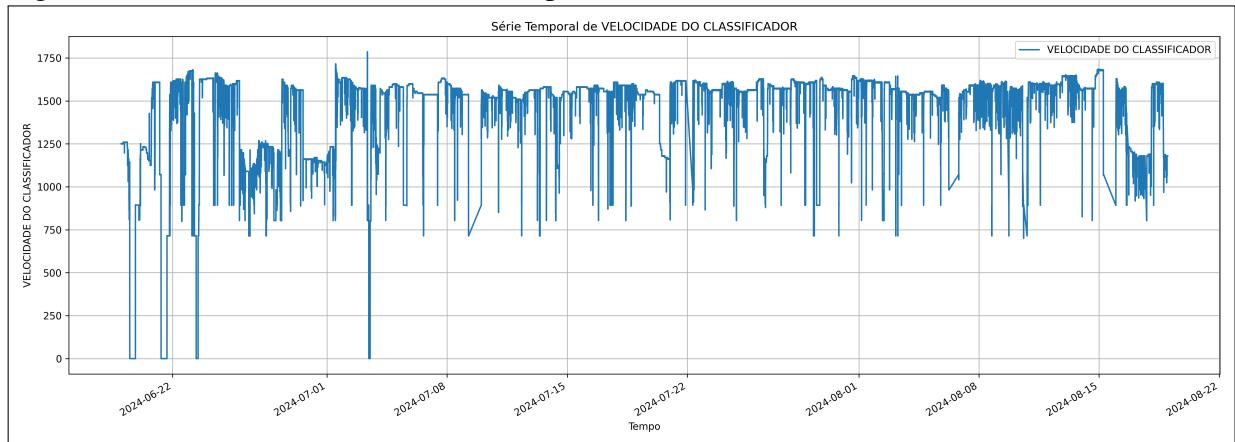


Fonte: Elaborado pelo autor (2024).

#### **6.1.7 Velocidade do classificador**

Eliminar valores zerados ou próximos de zero nas medições de velocidade do classificador do moinho vertical de rolos é crucial para a análise dos dados. Esses valores podem indicar problemas nos sensores ou interrupções operacionais que não refletem o funcionamento real. Ao remover esses dados, a análise se torna mais confiável, tornando o processo de predição da variável alvo mais eficaz.

Figura 27 – Velocidade do classificador (rpm)

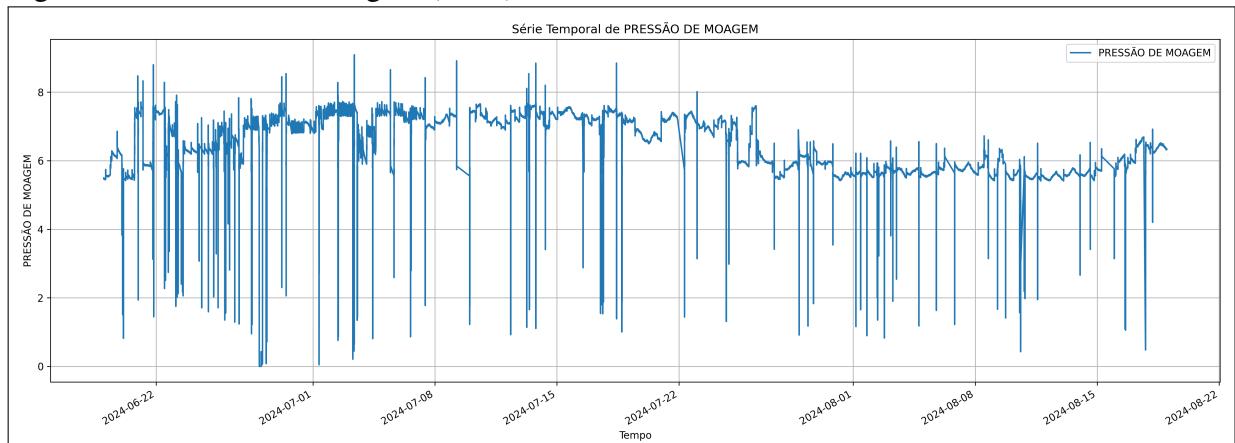


Fonte: Elaborado pelo autor (2024).

#### 6.1.8 Pressão de moagem

A remoção de valores zerados ou próximos de zero da série temporal da pressão de moagem é fundamental para garantir a qualidade da análise de dados e a eficácia de modelos preditivos. Esses valores podem resultar de leituras errôneas ou interrupções no processo, que não representam o comportamento real do sistema. Incluir tais dados pode distorcer a análise estatística, levando a conclusões imprecisas. Além disso, em modelos preditivos, esses valores podem introduzir ruído e reduzir a capacidade do modelo de prever com precisão as condições futuras. Ao filtrar esses dados, assegura-se que o modelo seja treinado com informações relevantes e consistentes, melhorando sua precisão e confiabilidade na otimização do processo de moagem.

Figura 28 – Pressão de moagem (mbar)

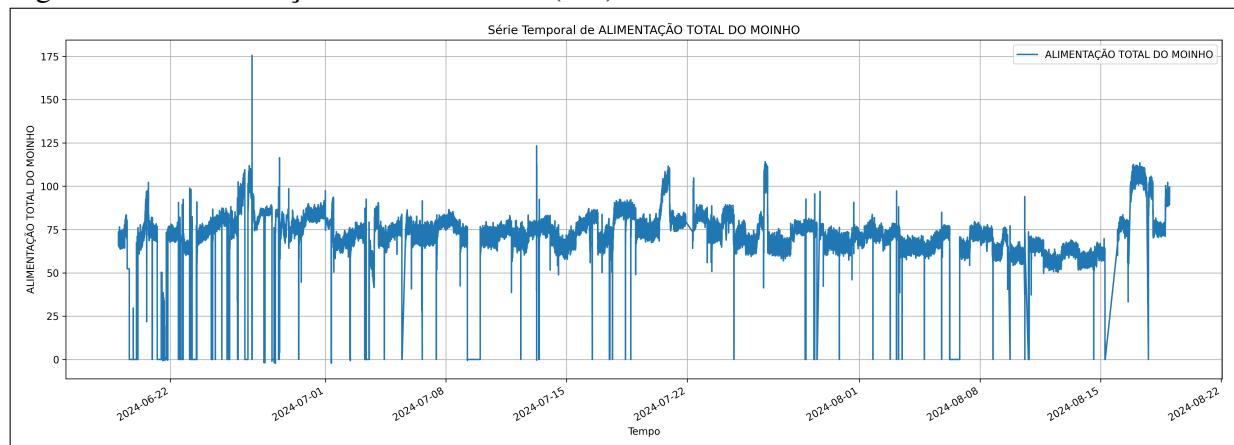


Fonte: Elaborado pelo autor (2024).

### 6.1.9 Alimentação total do moinho

A retirada de valores zerados ou próximos de zero da série temporal da alimentação total do moinho é crucial para a integridade da análise de dados e o desempenho de modelos preditivos. Manter esses dados pode resultar em análises distorcidas, afetando a identificação de tendências e padrões reais. Em modelos preditivos, a presença de dados irrelevantes ou errôneos pode introduzir ruído, comprometendo a capacidade do modelo de prever com precisão o comportamento do sistema. Ao eliminar esses valores, assegura-se que o modelo seja alimentado com dados consistentes e representativos, melhorando a precisão das previsões e contribuindo para a otimização do processo de moagem.

Figura 29 – Alimentação total do moinho (T/h)

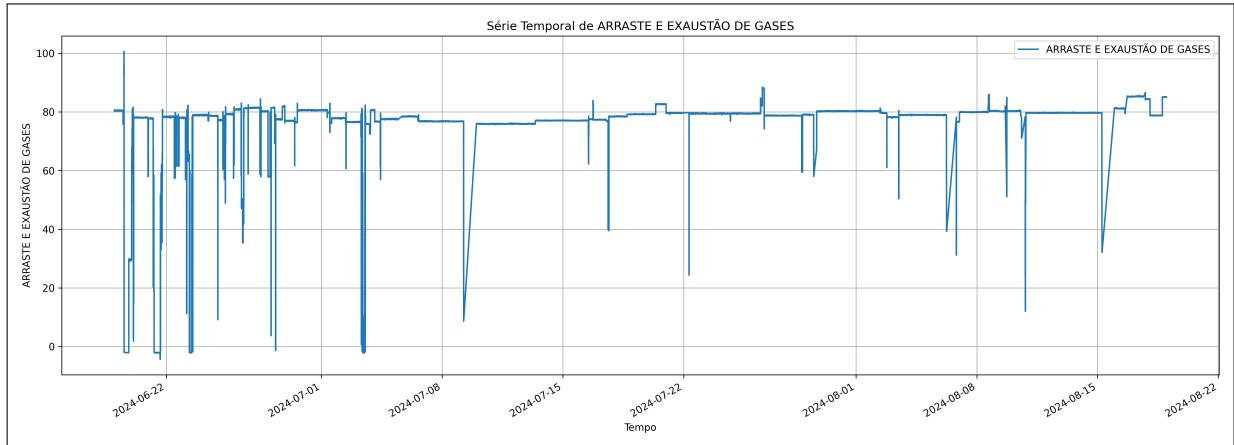


Fonte: Elaborado pelo autor (2024).

### 6.1.10 Arraste e exaustão de gases

A remoção de valores zerados ou próximos de zero na série temporal de arraste e exaustão de gases é vital para garantir a precisão e a confiabilidade das análises e dos modelos preditivos. Assim como foi feito para as outras variáveis, foram desconsiderados os valores zerados ou próximos de zero.

Figura 30 – Arraste e exaustão dos gases (%DA01)

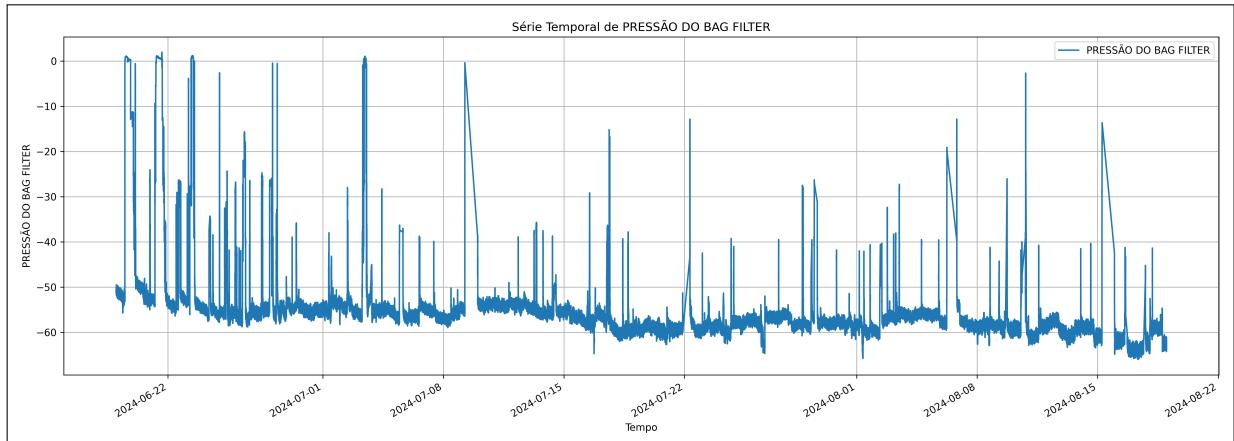


Fonte: elaborado pelo autor (2024).

#### 6.1.11 Pressão no bag filter

Na análise de dados da pressão no *bag filter*, a identificação de *outliers* é essencial para garantir a precisão e a confiabilidade das conclusões. Valores que excedem o limite superior de -20 mbar ou ficam abaixo do limite inferior de -80 mbar indicam desvios significativos das condições operacionais normais. Detectar esses outliers é crucial, pois eles podem sinalizar problemas como entupimentos, vazamentos ou falhas nos sensores, que exigem intervenção imediata. A pressão no *bag filter* é sempre negativa porque o sistema opera sob pressão negativa para garantir a eficiência na captação de partículas, evitando que gases ou partículas escapem para o ambiente externo. Manter a pressão dentro dos limites estabelecidos é vital para a eficiência do sistema de filtração e para a segurança operacional. Ao filtrar esses valores atípicos, os analistas podem focar em dados representativos, melhorando a qualidade das previsões e a eficácia das estratégias de manutenção preventiva.

Figura 31 – Pressão no bag filter (mbar)



Fonte: elaborado pelo autor (2024).

Filtrar os dados envolve a definição de limites superiores e inferiores para as variáveis, o que ajuda a eliminar valores atípicos e ruídos que podem distorcer os resultados. Este processo garante que o modelo seja alimentado com informações consistentes e representativas, melhorando o resultado do modelo preditivo. A tabela a seguir apresenta um resumo dos valores utilizados como filtros nas variáveis, destacando os limites estabelecidos para garantir a robustez do modelo.

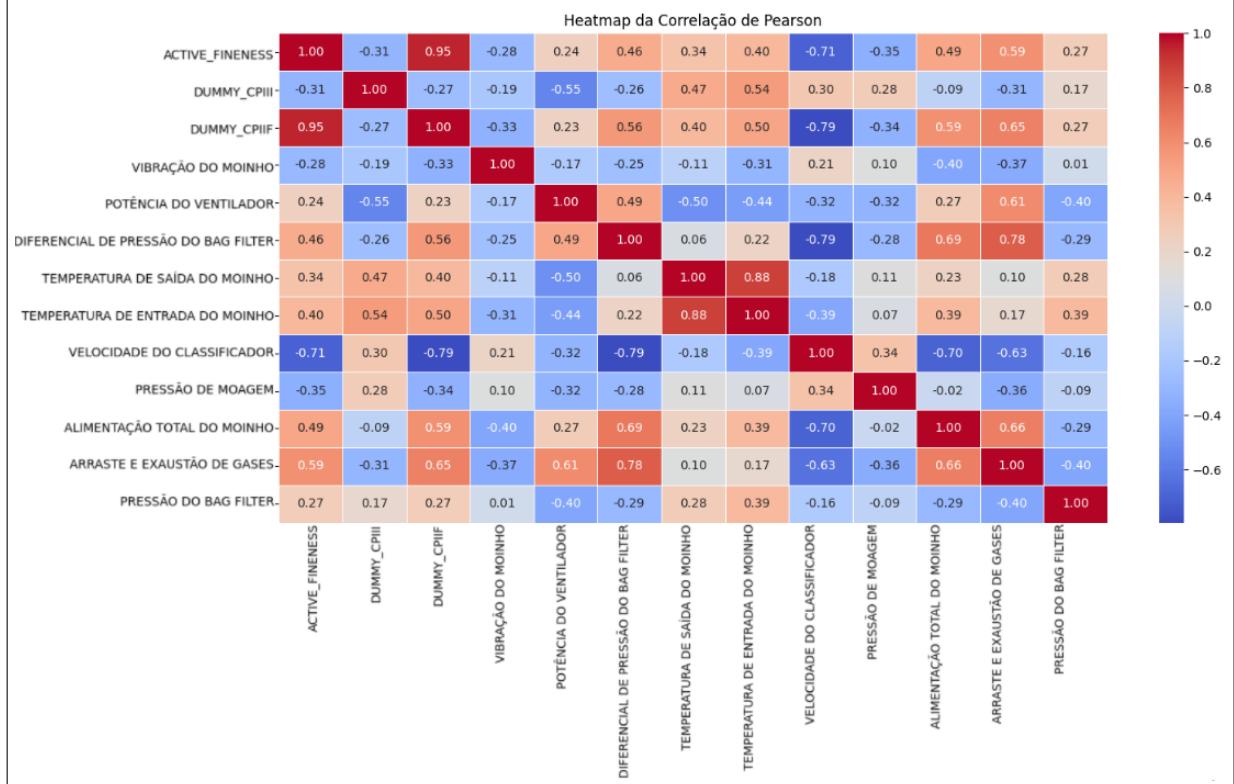
Tabela 1 – Tabela de Variáveis de Processo e seus limites

<b>Variação de Processo</b>	<b>Mínimo</b>	<b>Máximo</b>
TEMPERATURA DE ENTRADA	75	175
VELOCIDADE DO CLASSIFICADOR	30	80
POTÊNCIA DO VENTILADOR	750	1500
POTÊNCIA DO MOINHO	1000	2200
PRESSÃO DIFERENCIAL NO MOINHO	0	40
VIBRAÇÃO DO MOINHO	5	18
DIFERENCIAL DE PRESSÃO DO BAG FILTER	5	20
INJEÇÃO DE ÁGUA	0	4000
ARRASTE E EXAUSTÃO DOS GASES 1	60	85
ARRASTE E EXAUSTÃO DOS GASES 2	60	80
VELOCIDADE DO CLASSIFICADOR	750	1750
TEMPERATURA DE SAÍDA	80	120
ALIMENTAÇÃO TOTAL	25	125
FINURA DO CIMENTO	1	15
VIBRAÇÃO DO MOINHO	5	150
PRESSÃO DO BAG FILTER	-80	-20

Elaborado pelo autor (2024).

## 6.2 Correlação Linear de Pearson

Figura 32 – Correlação de Pearson para a Finura



Fonte: elaborado pelo autor (2024).

Aqui, analisa-se a relação entre a finura do cimento (*ACTIVE\_FINENESS*) e as demais variáveis explicativas, usando a tabela de correlação de Pearson como referência (como pode ser visto na figura 33).

- **DUMMY\_CPIII:** A correlação de -0,348 indica uma relação negativa moderada entre a presença do tipo de cimento CP III e a finura ativa, sugerindo que quando este tipo de cimento está presente, a finura tende a ser um pouco menor.
- **DUMMY\_CPIIF:** Com uma correlação de 0,946, existe uma forte relação positiva com a finura ativa, o que implica que a presença do cimento CP II F está associada a um aumento significativo na finura.
- **VIBRAÇÃO DO MOINHO:** A correlação de -0,305 sugere uma relação negativa moderada, indicando que aumentos na vibração do moinho podem estar associados a uma leve redução na finura.
- **POTÊNCIA DO VENTILADOR:** A correlação de 0,353 mostra uma relação positiva moderada, indicando que uma maior potência do ventilador pode contribuir para um

aumento na finura do cimento.

- **DIFERENCIAL DE PRESSÃO DO BAG FILTER:** Com uma correlação de 0,494, há uma relação positiva moderada, sugerindo que um maior diferencial de pressão no filtro de mangas está associado a uma maior finura.
- **TEMPERATURA DE SAÍDA:** A correlação de 0,311 indica uma relação positiva fraca, sugerindo que a temperatura de saída do moinho pode ter um ligeiro efeito positivo sobre a finura.
- **TEMPERATURA DE ENTRADA:** A correlação de 0,372 sugere uma relação positiva moderada, indicando que temperaturas de entrada mais altas podem estar relacionadas a um aumento na finura.
- **VELOCIDADE DO CLASSIFICADOR:** Com uma correlação de -0,704, existe uma relação negativa forte, sugerindo que velocidades mais altas do classificador estão associadas a uma redução na finura.
- **PRESSÃO DE MOAGEM:** A correlação de -0,458 indica uma relação negativa moderada, sugerindo que pressões mais altas podem estar associadas a uma redução na finura.
- **ALIMENTAÇÃO TOTAL:** Com uma correlação de 0,497, há uma relação positiva moderada, sugerindo que um maior volume de alimentação total do moinho está associado a uma maior finura.
- **ARRASTE E EXAUSTÃO DE GASES:** A correlação de 0,683 indica uma relação positiva forte, sugerindo que a posição da válvula DA01 tem uma influência significativa no aumento da finura.
- **PRESSÃO DO BAG FILTER:** Finalmente, a correlação de 0,219 sugere uma relação positiva fraca, indicando que a pressão no filtro de mangas tem um efeito pequeno sobre a finura.

Essas relações indicam como diferentes variáveis do processo podem influenciar a finura do cimento, sendo algumas mais impactantes que outras.

### 6.3 Gráficos de dispersão

Os gráficos de dispersão são ferramentas visuais fundamentais em estatística, usadas para examinar a relação entre duas variáveis quantitativas. Cada ponto no gráfico representa um par de valores correspondentes das duas variáveis em análise. A disposição desses pontos pode fornecer *insights* sobre a associação entre as variáveis. Os gráficos de dispersão produzidos estão

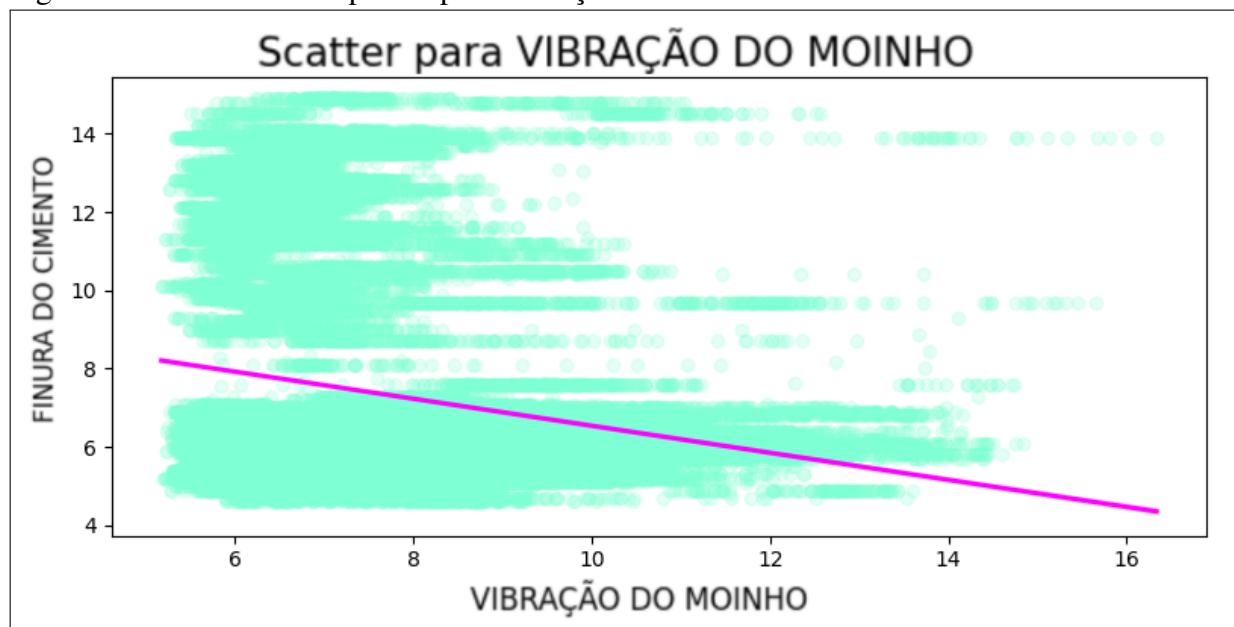
ilustrados da figura 34 até a figura 43.

Quando a inclinação no gráfico de dispersão é negativa, isso indica que há uma relação inversa entre as duas variáveis. Em outras palavras, à medida que o valor de uma variável aumenta, o valor da outra tende a diminuir. Essa disposição sugere uma correlação negativa, implicando que as variáveis se movem em direções opostas.

Por outro lado, uma inclinação positiva sugere que existe uma relação direta entre as variáveis, onde o aumento de uma está associado ao aumento da outra. Isso indica uma correlação positiva, refletindo que ambas as variáveis tendem a se mover na mesma direção.

Finalmente, quando a inclinação é próxima de zero, isso geralmente indica que não há uma relação linear evidente entre as variáveis. Os pontos no gráfico de dispersão estarão mais dispersos, sem formar uma tendência clara ascendente ou descendente, sugerindo que as variáveis são aproximadamente independentes ou que a correlação entre elas é fraca.

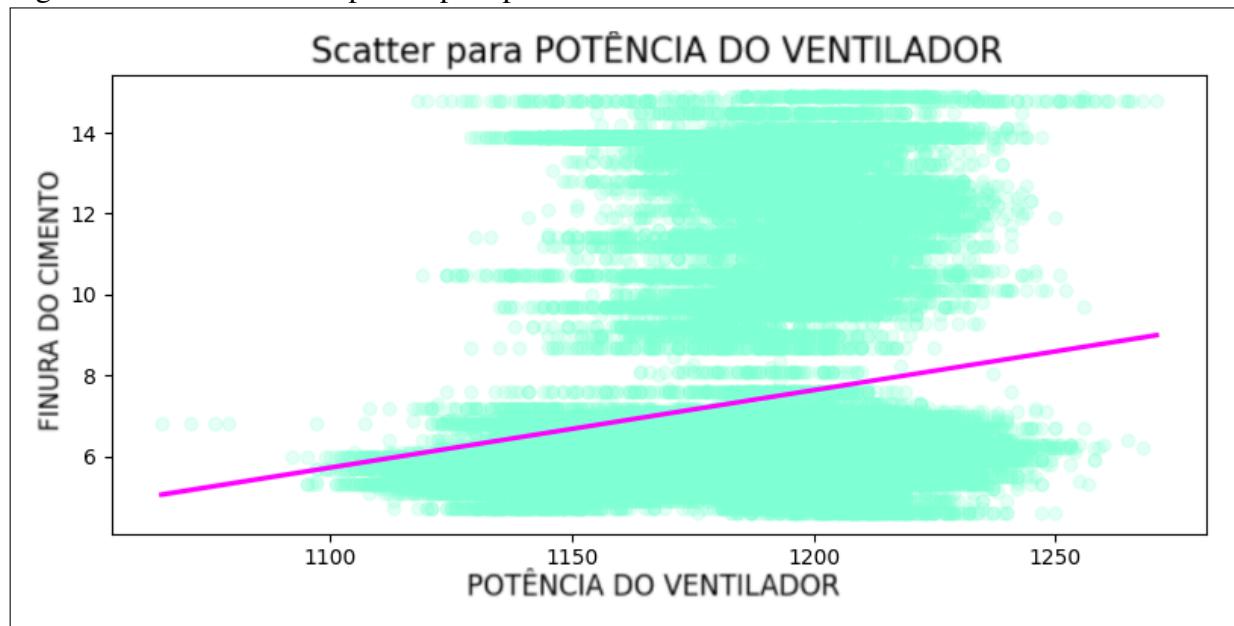
Figura 33 – Gráfico de dispersão para Vibração do moinho



Fonte: elaborado pelo autor (2024).

O gráfico da figura 33 mostra uma relação inversa entre a finura do cimento e a vibração do moinho, sugerindo que um aumento na finura, possivelmente devido à moagem mais intensa, está associado a uma redução nas vibrações do moinho. Podemos inferir do gráfico que moagens mais finas ocorrem em condições de operação estáveis e controladas que minimizam vibrações. Porém não é isso que encontramos no comportamento real do maquinário. Quanto mais intensa a moagem, maior as vibrações na máquina.

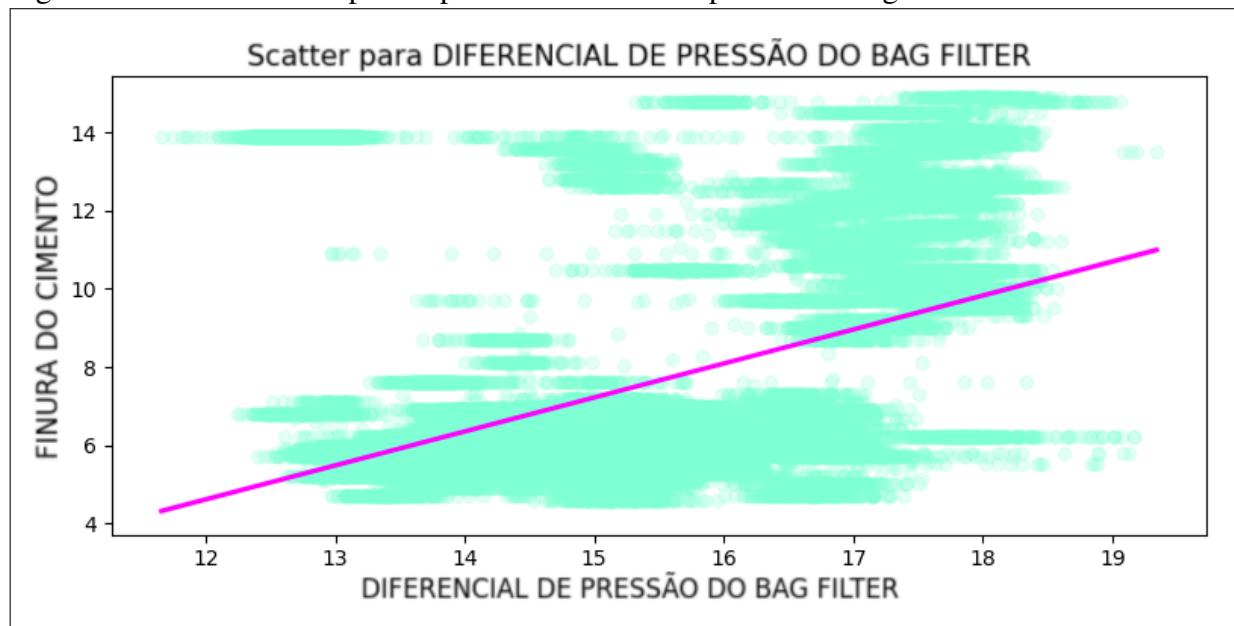
Figura 34 – Gráfico de dispersão para potência do ventilador



Fonte: elaborado pelo autor (2024).

A correlação positiva apresentada no gráfico da figura 34 (entre a finura do cimento e a potência do ventilador) indica que aumentos na finura exigem ajustes na potência do ventilador para manter o fluxo adequado de material e gás através do sistema de moagem. Isso pode refletir tentativas de otimizar a eficiência de separação das partículas finas e garantir condições adequadas de transporte pneumático nos processos subsequentes.

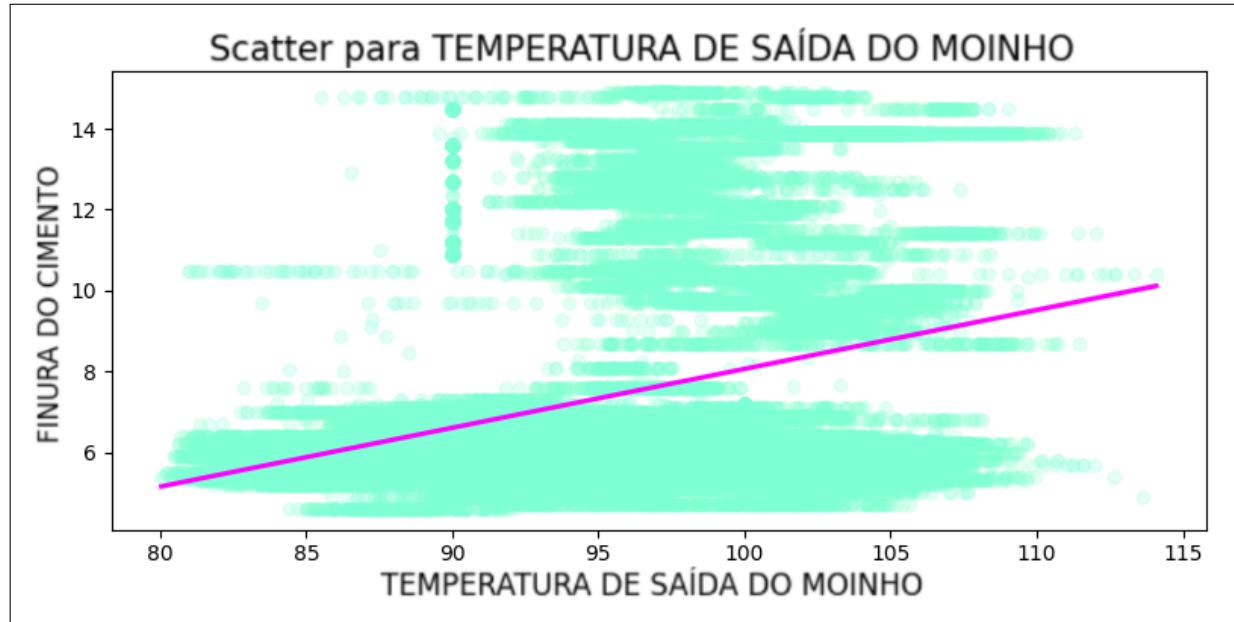
Figura 35 – Gráfico de dispersão para o diferencial de pressão do bag filter



Fonte: elaborado pelo autor (2024).

No gráfico da figura 35, essa inclinação positiva sugere que com o aumento da finura do cimento, há um incremento na resistência do fluxo de ar através do filtro de mangas. Isso pode ser atribuído à maior presença de partículas finas no fluxo de gases, as quais resultam em maior entupimento do meio filtrante. Tais observações podem ser fundamentais no planejamento da manutenção dos filtros, dadas as taxas de filtração que precisam ser monitoradas para evitar quedas no desempenho da instalação.

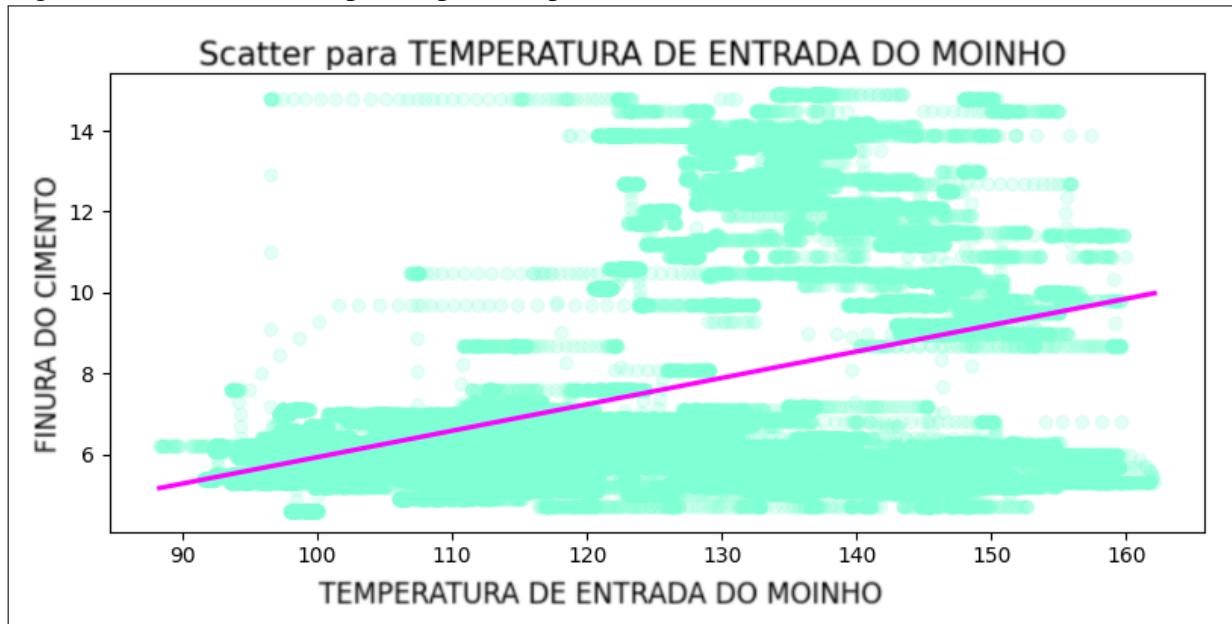
Figura 36 – Gráfico de dispersão para temperatura de saída



Fonte: elaborado pelo autor (2024).

A tendência positiva apresentada no gráfico da figura 36 (entre a finura do cimento e a temperatura de saída do moinho) pode indicar que condições de moagem mais intensas, necessárias para produzir partículas finas, resultam em elevação das temperaturas devido ao aumento de atrito e resistência no processo. Esse comportamento está de acordo com o que ocorre na realidade.

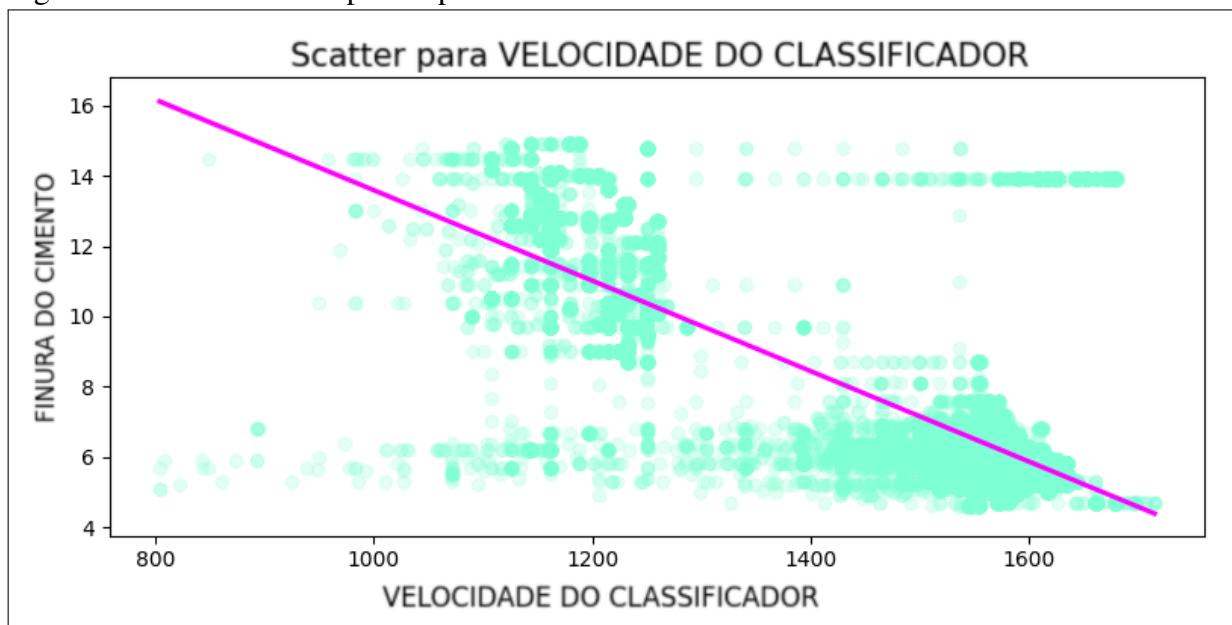
Figura 37 – Gráfico de dispersão para temperatura de entrada



Fonte: elaborado pelo autor (2024).

A relação apresentada no gráfico da figura 37 sugere que temperaturas de entrada mais altas são conduzidas por exigências de ressecamento e tratamento do cimento antes da moagem intensa. O controle preciso das temperaturas de entrada pode ajudar na preservação da eficiência de moagem e na manutenção de níveis de umidade apropriados no composto.

Figura 38 – Gráfico de dispersão para velocidade do classificador

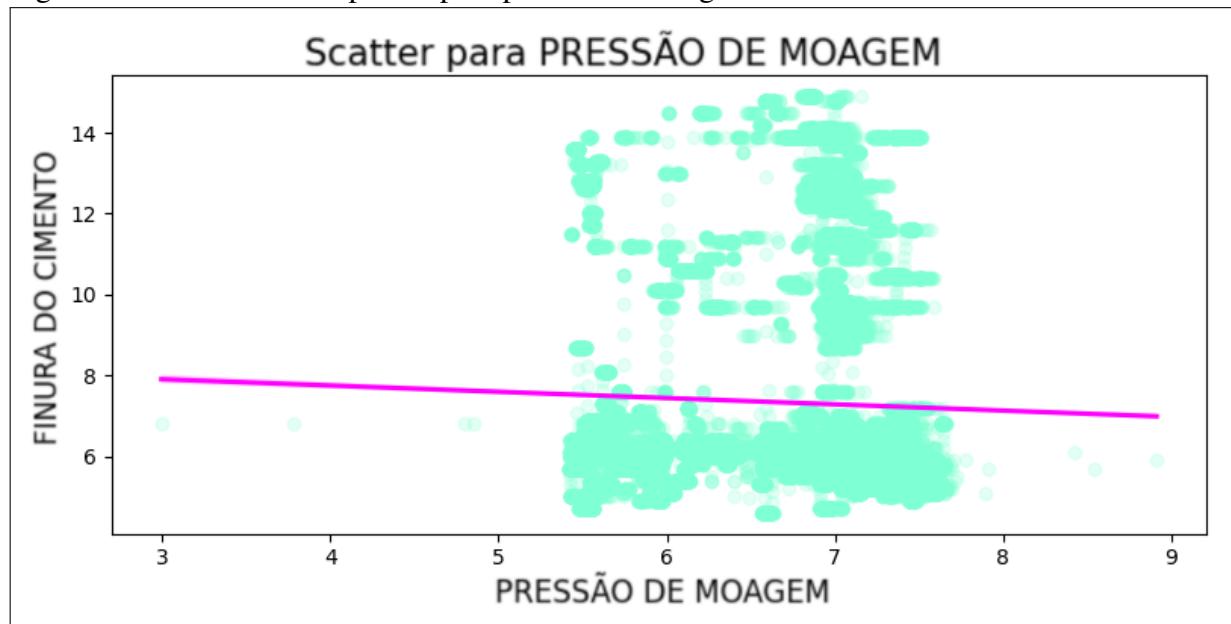


Fonte: elaborado pelo autor (2024).

A relação inversa bastante acentuada apresentada no gráfico da figura 38 destaca que

à medida que se busca uma maior finura do cimento, a velocidade do classificador precisa ser reduzida. Isso talvez seja explicado pela necessidade de um tempo de residência maior em fases específicas do processo, garantindo a segregação eficiente das partículas excedentes, promovendo a remoção dos grossos antes da liberação do produto final.

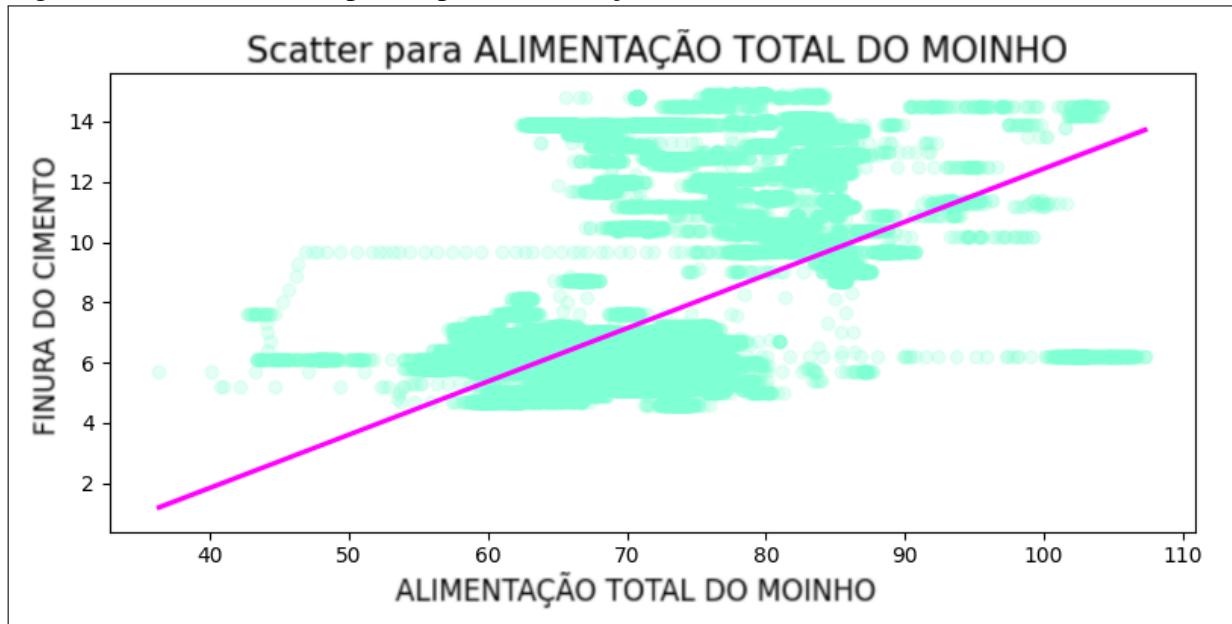
Figura 39 – Gráfico de dispersão para pressão de moagem



Fonte: elaborado pelo autor (2024).

A leve inclinação negativa entre a finura e a pressão de moagem (figura 39) sugere ajustes específicos na pressão para alcançar as metas de finura do produto. A otimização da pressão pode contribuir para um Processo de Moagem mais calibrado, impactando positivamente a eficiência energética e reduzindo custos operacionais.

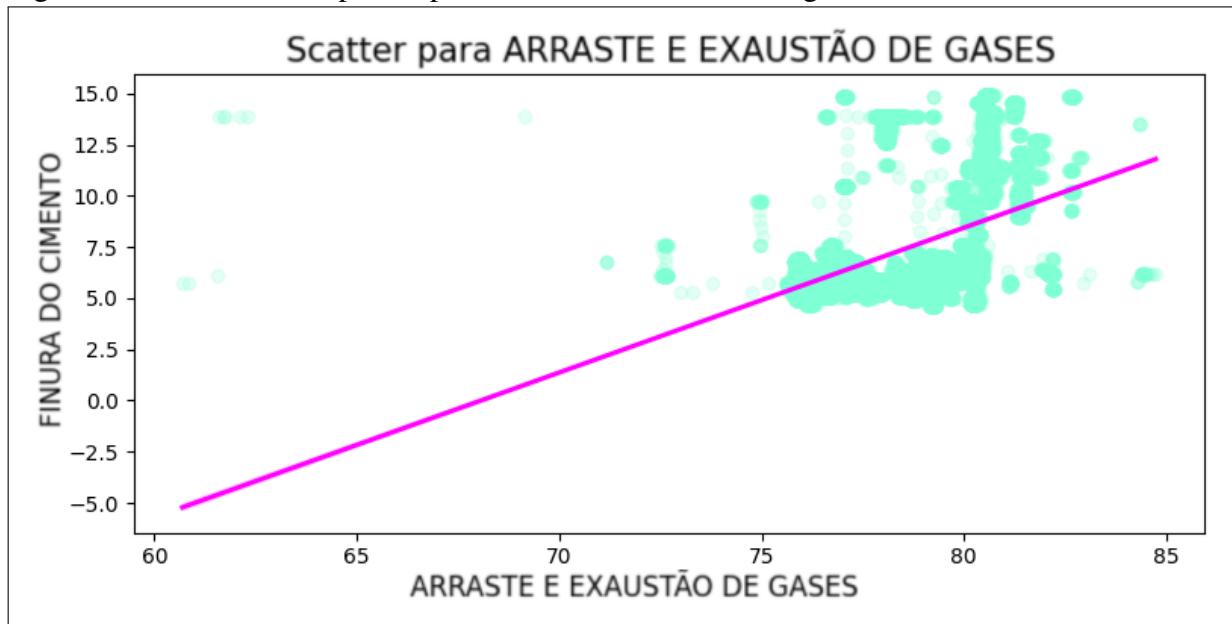
Figura 40 – Gráfico de dispersão para alimentação total do moinho



Fonte: elaborado pelo autor (2024).

A figura 40 mostra uma correlação acentuadamente positiva demanda atenção à capacidade de alimentação para suportar o incremento na produção de partículas finas. Isso postula uma necessidade de otimização das taxas de alimentação para maximizar a produção sem comprometer a eficiência do moinho.

Figura 41 – Gráfico de dispersão para o arraste e exaustão dos gases

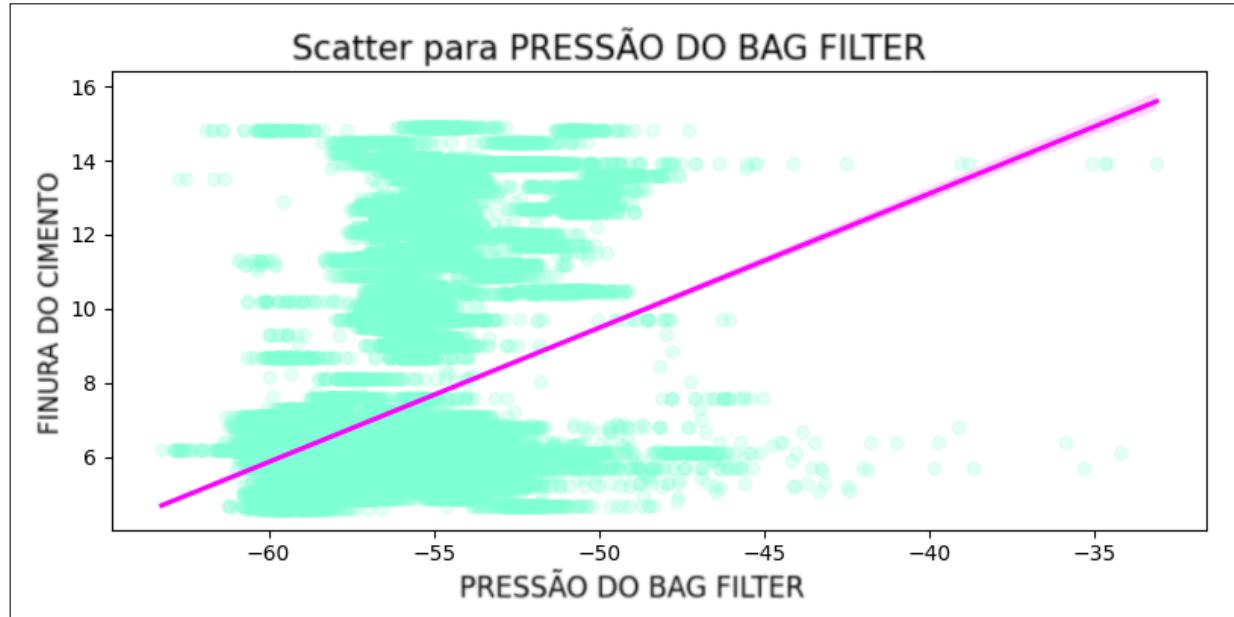


Fonte: elaborado pelo autor (2024).

Essa relação (figura 41) sugere aumentos significativos nos fluxos de gás arrastados

e exauridos, atribuíveis ao incremento na finura. Gerenciar o arraste é essencial para manter níveis aceitáveis de pressão e funcionamento contínuo dos sistemas exaustores, evitando perda de eficiência por meio de entupimentos frequentes.

Figura 42 – Gráfico de dispersão para pressão no bag filter

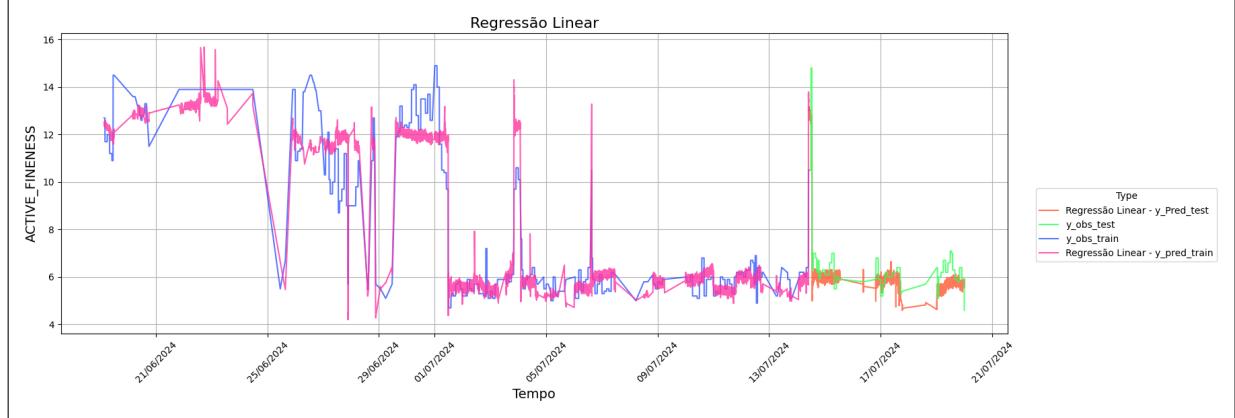


Fonte: elaborado pelo autor (2024).

A tendência indicada (figura 42) de uma maior finura resultando em crescentes pressões nos filtros de mangas ressalta a exacerbção de choque filtrante e opaquescimento nos elementos filtrantes. Ensaios laboratórios prévios e análises pontuais durante o processo produtivo devem corroborar medidas de mitigação ativa, como análises de ciclo de vida do equipamento e aplicação de técnicas de limpeza mais eficazes.

## 6.4 Predição com Regressão Linear Múltipla

Figura 43 – Regressão Linear (treinamento e teste)



Fonte: elaborado pelo autor (2024).

Neste estudo, foi aplicada a regressão linear múltipla para prever a finura do cimento (como pode ser visto na figura 44), medida em termos de porcentagem de resíduo retido em uma peneira de 75 nanômetros. Esse resíduo é uma indicação crucial da qualidade do cimento, e diferenças na finura são observadas entre os tipos de cimento analisados: CPIII, CPVARI e CPIIF, com valores específicos de 8%, 6% e entre 10% a 12%, respectivamente.

A análise de regressão linear múltipla permitiu identificar a contribuição de várias variáveis independentes para a predição da finura do cimento. Os coeficientes da regressão estimados representam o impacto de cada variável sobre a finura, enquanto os p-valores associados indicam a significância estatística dos coeficientes.

O modelo de regressão possui seus coeficientes, cada um indicando o impacto de diferentes variáveis sobre a finura. O intercepto tem um valor de 20.3688, acompanhado de um p-valor extremamente baixo, o que sugere que ele é estatisticamente significativo. Isso implica que, quando todas as outras variáveis são zero, a finura inicia a partir deste valor base.

Os coeficientes referentes às variáveis fictícias **DUMMY\_CPIII** e **DUMMY\_CPIIF** revelam diferenças substanciais em relação ao tipo base CPVARI. **DUMMY\_CPIII** possui um coeficiente de 0.1631, enquanto **DUMMY\_CPIIF** tem 7.4596. Ambos os coeficientes são estatisticamente significativos, reforçando evidências apresentadas na análise de correlação de Pearson sobre as diferenças entre os tipos de cimento.

Além disso, várias variáveis de ambiente e operacionais mostraram-se influentes na previsão da finura. Por exemplo, a variável **VIBRAÇÃO DO MOINHO** tem um coeficiente

de -0.0680 e a variável **POTÊNCIA DO VENTILADOR** tem 0.0029, ambos estatisticamente significativos, sugerindo que afetam consideravelmente a finura. A **DIFERENCIAL DE PRESSÃO DO BAG FILTER** com um coeficiente de -0.2031 e a **TEMPERATURA DE SAÍDA** com 0.0451 também destacam a sua influência significativa sobre a finura.

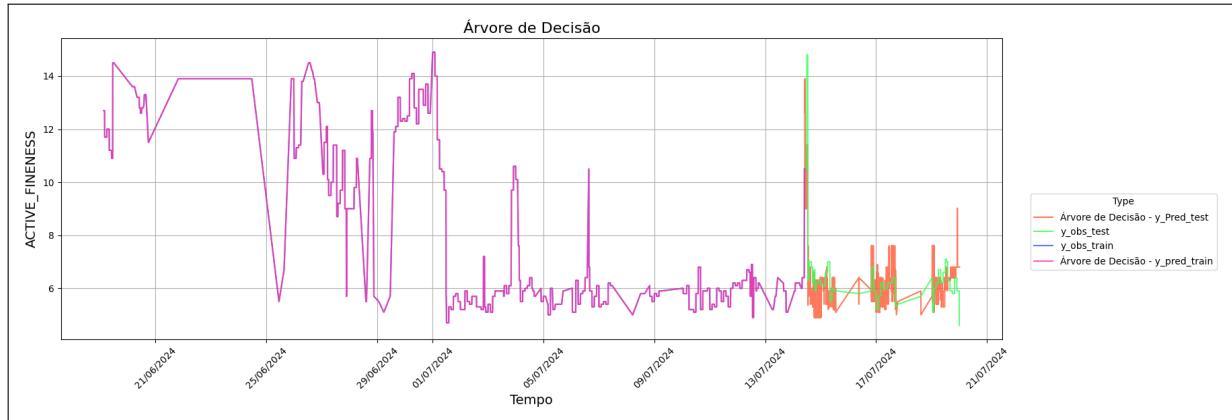
Por outro lado, a variável **PRESSÃO DE MOAGEM** não apresentou significância estatística, com um p-valor de 0.5732. Isso sugere que esta variável pode não ter um efeito relevante na previsão da finura dentro do contexto dos dados analisados.

A qualidade do modelo foi avaliada usando as métricas RMSE (Raiz do Erro Quadrático Médio) e MAE (Erro Absoluto Médio), com valores de 0.7303 e 0.5379, respectivamente. Esses valores indicam um desempenho satisfatório do modelo na predição da finura do cimento, mostrando que as variáveis selecionadas capturaram bem as variações observadas nos dados.

Para este e os demais modelos preditivos, foi usada 80% da base de dados para treino e 20% para teste.

## 6.5 Predição com o Modelo de Árvore de Decisão

Figura 44 – Modelo de Árvore de Decisão (treinamento e teste)



Fonte: elaborado pelo autor (2024).

Este modelo, conhecido por sua capacidade de capturar interações complexas entre variáveis, foi avaliado utilizando um conjunto de dados de treino com 80% da base para verificar sua eficácia. O gráfico pode ser visto na figura 45.

Para o conjunto de treino, o modelo de árvore de decisão apresentou métricas de desempenho excepcionais. O RMSE (Raiz do Erro Quadrático Médio) e o MAE (Erro Médio Absoluto) foram ambos igual a 0.0000, indicando que o modelo foi capaz de prever perfeitamente os dados de treino sem erros, o que configura *overfitting*.

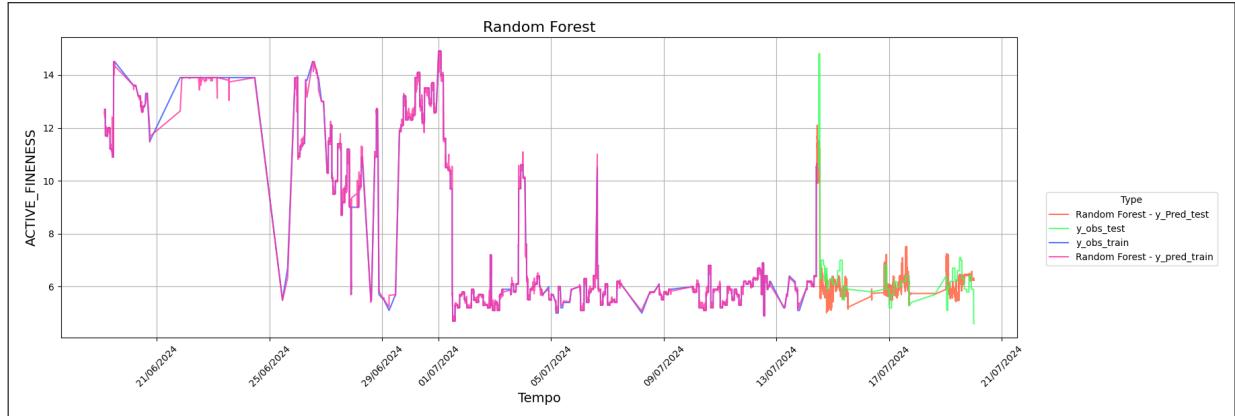
No conjunto de teste, o desempenho do modelo diminuiu, como esperado, mostrando a capacidade de generalização do modelo. O RMSE foi de 0.8642 e o MAE foi de 0.6384, indicando erros de predição moderados.

Apesar do *overfitting* evidenciado nos dados de treinamento (onde o modelo está excessivamente ajustado aos dados), o modelo conseguiu generalizar bem para novos dados , que é o objetivo final de um modelo preditivo.

O resultado evidencia a robustez do modelo de árvore de decisão em capturar padrões complexos nos dados de treino, embora a sua capacidade de generalização nos dados de teste seja mais limitada. Isso sugere a necessidade potencial de ajuste fino do modelo ou a consideração de técnicas de *ensemble*, como o modelo de florestas aleatórias, para melhorar a precisão das previsões em novos dados.

## 6.6 Predição com o Modelo de Floresta Aleatória

Figura 45 – Modelo de Floresta Aleatória (treinamento e teste)



Fonte: elaborado pelo autor (2024).

Também foi aplicado o modelo de Floresta Aleatória para prever a finura do cimento, uma técnica poderosa que combina múltiplas árvores de decisão para melhorar a precisão preditiva e a capacidade de generalização. A predição pode ser vista na figura 46.

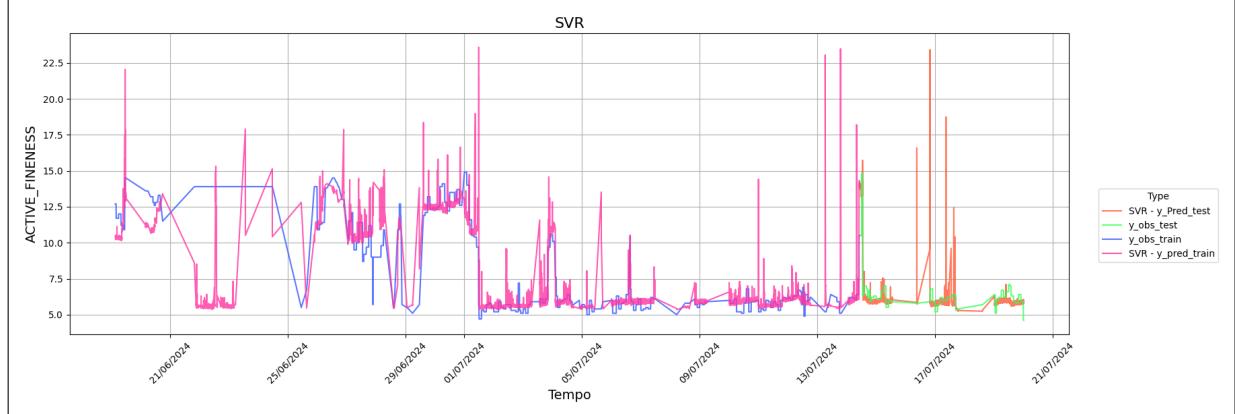
Para o conjunto de treino, o modelo de Floresta Aleatória apresentou desempenho excelente. As métricas de avaliação foram: RMSE (Raiz do Erro Quadrático Médio) de 0.0647 e MAE (Erro Médio Absoluto) de 0.0243.

No conjunto de teste, o desempenho do modelo também foi robusto, mas com redução natural na precisão comparado ao conjunto de treino. O RMSE foi de 0.7502 e o MAE foi de 0.5191. Isso demonstra uma boa capacidade de generalização, típica dos modelos de

Floresta Aleatória, que conseguem manter um equilíbrio entre *overfitting* e generalização.

## 6.7 Predição com o Modelo de Regressão por Vetores de Suporte (SVR)

Figura 46 – Modelo de Regressão por Vetores de Suporte (SVR) (treinamento e teste)



Fonte: elaborado pelo autor (2024).

Neste estudo, também foi utilizado o modelo de Regressão por Vetores de Suporte (SVR) para prever a finura do cimento (como pode ser visto no gráfico da figura 47).

Para o conjunto de treino, as métricas do modelo SVR indicaram um ajuste moderado. O RMSE (Raiz do Erro Quadrático Médio) foi de 2.2786 e o MAE (Erro Médio Absoluto) foi de 1.0756, sugerindo erros consideráveis nas previsões.

Para o conjunto de teste, o modelo SVR apresentou resultados melhores em termos de erro. O RMSE foi de 0.8731 e o MAE foi de 0.5140, valores que refletem uma melhoria comparativa na precisão das previsões em relação ao conjunto de treino.

Os resultados indicam que, embora ele tenha uma precisão moderada, tanto no conjunto de treino quanto no de teste, ele é eficaz para capturar tendências gerais nos dados.

## 6.8 Comparação de Modelos e Tempos de Execução

A escolha do modelo preditivo ideal não se baseia apenas em métricas de desempenho como RMSE e MAE, mas também na eficiência em termos de tempo de execução, especialmente em aplicações práticas onde o tempo de processamento é um fator crítico.

### **6.8.1 Tempos de Execução dos Modelos e Análise Comparativa**

Os tempos de execução para cada modelo foram registrados de acordo com o que mostra a tabela abaixo.

Tabela 2 – Tempos de Execução dos Modelos

<b>Modelo</b>	<b>Tempo de Execução (segundos)</b>
Regressão Linear	0.0903
Árvore de Decisão	2.3109
Random Forest	51.4393
SVR	110.0410

A Regressão Linear Múltipla apresentou um tempo de execução rápido (0.0903 segundos) e obteve um desempenho razoável. Sua simplicidade e velocidade tornam-na uma escolha atrativa em cenários onde a rapidez é prioritária e pequenas imprecisões são toleráveis.

A Árvore de Decisão, com um tempo de execução de 2.3109 segundos, ofereceu uma boa combinação de velocidade e capacidade preditiva, capturando interações não lineares com razoável precisão.

Já a Floresta Aleatória, embora tenha exibido um excelente desempenho preditivo, especialmente no conjunto de treino, teve um tempo de execução significativamente mais alto (51.4393 segundos), o que pode ser um fator limitante em aplicações com necessidade de processamento rápido.

Por fim, o SVR teve o maior tempo de execução (110.0410 segundos) e um desempenho preditivo moderado, o que indicou uma baixa eficiência relativa tanto em termos de previsão quanto de tempo de processamento.

### **6.8.2 Escolha do Melhor Modelo**

Considerando a análise de desempenho e os tempos de execução, o modelo de Regressão Linear Múltipla emerge como a escolha mais equilibrada. Apesar de o *Random Forest* ter apresentado melhor capacidade preditiva, o tempo de execução elevado não justifica seu uso quando comparado à velocidade e efetividade da Regressão Linear Múltipla. Esta escolha é baseada na capacidade deste de manter um bom equilíbrio entre precisão das previsões e eficiência de processamento, tornando-a adequada para aplicações em tempo real ou em cenários onde os recursos computacionais são limitados.

### **6.8.3 Conclusão**

A análise comparativa dos modelos revela que a Regressão Linear Múltipla oferece a melhor combinação de desempenho preditivo e eficiência de tempo de execução, recomendando-a como o modelo mais apropriado para a previsão da finura do cimento nas condições estudadas. No entanto, a escolha final do modelo pode depender também de requisitos específicos do contexto de aplicação, como a necessidade de explicabilidade ou a disponibilidade de recursos computacionais.

No contexto industrial, especialmente na produção de cimento, o desenvolvimento de código para análise de variáveis operacionais é uma tarefa complexa que exige o emprego de bibliotecas de programação avançadas. O código produzido na linguagem python foi projetado para explorar as relações entre a finura do cimento e variáveis como vibração do moinho, potência do ventilador, e diferencial de pressão do bag filter, entre outras. Para isso, bibliotecas como Pandas, NumPy, Matplotlib, e Seaborn desempenharam papéis cruciais.

Pandas foi fundamental para a manipulação de dados, permitindo a leitura, limpeza e transformação dos conjuntos de dados. Sua capacidade de lidar com grandes volumes de dados de forma eficiente foi essencial para o pré-processamento necessário antes da análise. NumPy complementou esse processo ao fornecer suporte para operações numéricas rápidas, facilitando cálculos complexos e manipulações de arrays.

Para a visualização dos dados, Matplotlib e Seaborn foram escolhidas por suas capacidades robustas de criação de gráficos. Matplotlib permitiu a personalização detalhada dos gráficos de dispersão, enquanto Seaborn facilitou a aplicação de estilos estéticos e a criação de gráficos mais informativos e visualmente atraentes. Essas bibliotecas foram cruciais para a identificação visual de padrões e correlações entre as variáveis.

Durante a implementação do código, surgiram desafios como a manipulação de dados ausentes e a otimização do desempenho computacional. A integração de Pandas e NumPy permitiu a aplicação de técnicas de imputação e filtragem de dados, garantindo que as análises fossem realizadas apenas com dados completos e relevantes.

A escolha e ajuste dos parâmetros dos modelos estatísticos também foram críticos. A flexibilidade de Seaborn em ajustar automaticamente os parâmetros dos gráficos ajudou a evitar interpretações errôneas das correlações, garantindo a precisão dos resultados.

Para maximizar a eficácia do código, a implementação de pipelines de dados que incluiram etapas de limpeza, transformação e visualização foi fundamental. O uso coordenado

de Pandas e NumPy para manipulação de dados, seguido pela visualização com Matplotlib e Seaborn, proporcionou um fluxo de trabalho eficiente e robusto.

Além disso, práticas de programação defensiva, como a inclusão de verificações de erro, foram essenciais para lidar com exceções durante a execução do código. A documentação clara do código, destacando o uso e a configuração das bibliotecas, facilitou a manutenção e a colaboração entre o aluno e sua orientadora.

## 7 CONCLUSÕES E TRABALHOS FUTUROS

O estudo detalhado do processo produtivo de um moinho vertical de rolos em uma planta de produção de cimento revelou *insights* valiosos sobre a influência das variáveis operacionais na finura da matéria-prima. A análise dos dados coletados ao longo de 61 dias proporcionou uma compreensão aprofundada sobre como diferentes fatores afetam a qualidade do produto final.

Os resultados indicaram que a finura cimento é um parâmetro crítico, com a porcentagem de material retido na peneira servindo como um importante indicador de qualidade. Observou-se que, em alguns momentos, os valores de finura ultrapassaram o limite máximo permitido, o que destaca a necessidade de um controle rigoroso das condições operacionais para assegurar a conformidade com as normas técnicas.

A análise das variáveis operacionais, como a vibração do moinho e a potência do ventilador, mostrou que a ausência de *outliers* significativos que contribuem para a estabilidade do processo. No entanto, a presença de valores zerados em diversas medições, como no diferencial de pressão do *bag filter* e na temperatura de saída do moinho, ressaltou a importância de tratar adequadamente esses dados para evitar distorções nas análises.

A aplicação de filtros para remover valores anômalos e a análise de correlação de Pearson foram fundamentais para identificar relações significativas entre as variáveis. A correlação ajudou a destacar variáveis preditoras relevantes, eliminando a multicolinearidade e aprimorando a precisão dos modelos preditivos.

As métricas de desempenho do modelo (MAE e o RMSE) confirmaram a eficácia dos modelos preditivos em estimar a finura do cimento. Os erros observados foram relativamente pequenos, indicando que os modelos são robustos e capazes de prever a finura dentro dos padrões estabelecidos pela NBR 16697.

Em suma, este trabalho reforça a importância de um monitoramento contínuo e preciso das variáveis operacionais para otimizar a produção de cimento. A implementação de medidas corretivas e preventivas, baseadas em dados confiáveis, é essencial para garantir a qualidade e a eficiência do processo produtivo.

Para trabalhos futuros, seria interessante explorar a aplicação de técnicas avançadas de aprendizado de máquina e inteligência artificial para otimizar ainda mais o controle das variáveis operacionais no processo de moagem de cimento. Modelos preditivos mais sofisticados poderiam ser desenvolvidos para identificar padrões complexos e prever desvios de qualidade

antes que ocorram, permitindo intervenções proativas. Outra área promissora seria a investigação dos impactos ambientais associados ao processo de produção, com foco na redução de emissões e no aumento da eficiência energética, contribuindo para a sustentabilidade da indústria cimenteira.

## REFERÊNCIAS

- 16697, A. N. *ABNT NBR 16697: Cimento Portland - Requisitos*. 2018. Associação Brasileira de Normas Técnicas.
- ANDREATTA, K. A. Estimativa da finura do cimento durante o processo de moagem em moinho de bolas. Vitória, 2020.
- BATTAGIN, A. F. Uma breve história do cimento portland. **Associação Brasileira de Cimento Portland. São Paulo.** Disponível em [www.abcp.com.br](http://www.abcp.com.br) [15/07/2003], 2009.
- de Myttenaere, A.; GOLDEN, B.; Le Grand, B.; ROSSI, F. Mean absolute percentage error for regression models. **Neurocomputing**, v. 192, p. 38–48, 2016. ISSN 0925-2312. Advances in artificial neural networks, machine learning and computational intelligence. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0925231216003325>.
- DEHGHANI, A. A.; MOVAHEDI, N.; GHORBANI, K.; ESLAMIAN, S. Chapter 10 - decision tree algorithms. In: ESLAMIAN, S.; ESLAMIAN, F. (Ed.). **Handbook of Hydroinformatics**. Elsevier, 2023. p. 171–187. ISBN 978-0-12-821285-1. Disponível em: <https://www.sciencedirect.com/science/article/pii/B978012821285100004X>.
- ELLIS, G. Chapter 10 - introduction to observers in control systems. In: ELLIS, G. (Ed.). **Control System Design Guide (Third Edition)**. Third edition. Burlington: Academic Press, 2004. p. 191–218. ISBN 978-0-12-237461-6. Disponível em: <https://www.sciencedirect.com/science/article/pii/B9780122374616500114>.
- FÁVERO, L.; BELFIORE, P. e. **Manual de Análise de Dados : Estatística e Modelagem Multivariada com Excel, SPSS e Stata**. [S. l.]: ELSEVIER, 2017.
- FÁVERO, L. P.; BELFIORE, P.; de Freitas Souza, R. Chapter 21 - random forests. In: FÁVERO, L. P.; BELFIORE, P.; de Freitas Souza, R. (Ed.). **Data Science, Analytics and Machine Learning with R**. Academic Press, 2023. p. 429–440. ISBN 978-0-12-824271-1. Disponível em: <https://www.sciencedirect.com/science/article/pii/B9780128242711000184>.
- GILES, D. E.; SRIVASTAVA, V. K. The exact distribution of a least squares regression coefficient estimator after a preliminary t-test. **Statistics Probability Letters**, v. 16, n. 1, p. 59–64, 1993. ISSN 0167-7152. Disponível em: <https://www.sciencedirect.com/science/article/pii/0167715293901242>.
- LIMA, A. B. de. O processo produtivo do cimento portland. Universidade Federal de Minas Gerais, 2011.
- LIN, X.; QIAN, Z. Modeling of vertical mill raw meal grinding process and optimal setting of operating parameters based on wavelet neural network. In: IEEE. **2014 international joint conference on neural networks (IJCNN)**. [S. l.], 2014. p. 3015–3020.
- LIU, G.; OUYANG, Z.; HAO, X.; SHI, X.; ZHENG, L.; ZHAO, Y. Prediction of raw meal fineness in the grinding process of cement raw material: A two-dimensional convolutional neural network prediction method. **Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering**, SAGE Publications Sage UK: London, England, v. 235, n. 6, p. 823–838, 2021.

MENESES, L. C. de. Estudo de variáveis que afetam a vibração do corpo de um moinho vertical de rolos. 2023. Disponível em: <https://drive.google.com/file/d/1qiZywxOBjG7TlgfdUMVj9N7AM2dhdIyB/view?usp=sharing>.

PEREIRA, M. F. **Estudo sobre os tipos de cimento comercializados em Campo Mourão.** Dissertação (B.S. thesis) – Universidade Tecnológica Federal do Paraná, 2012.

SAINANI, K. L. The value of scatter plots. **PMR**, v. 8, n. 12, p. 1213–1217, 2016. ISSN 1934-1482. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1934148216310784>.

SHOBHA, G.; RANGASWAMY, S. Chapter 8 - machine learning. In: GUDIVADA, V. N.; RAO, C. (Ed.). **Computational Analysis and Understanding of Natural Languages: Principles, Methods and Applications**. Elsevier, 2018, (Handbook of Statistics, v. 38). p. 197–228. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0169716118300191>.

SIMONETO, G. W. *et al.* **Avaliação da Alteração da Finura e Composição do Cimento Portland Brasileiro nas Últimas Décadas: Estudo Exploratório.** Dissertação (B.S. thesis), 2020.

STANIŠIĆ, D.; JORGOVANOVIĆ, N.; POPOV, N.; ČONGRADAC, V. Soft sensor for real-time cement fineness estimation. **ISA transactions**, Elsevier, v. 55, p. 250–259, 2015.

UBE Machinery Corporation, LTD. **Ube Vertical Mill.** [S. l.]: UBE Machinery Corporation, LTD., 1980.

WBCSD, I. Cement technology roadmap 2009: carbon emissions reductions up to 2050. **World Business Council for Sustainable Development and International Energy Agency**, 2009.

ZHANG, F.; O'DONNELL, L. J. Chapter 7 - support vector regression. In: MECHELLI, A.; VIEIRA, S. (Ed.). **Machine Learning**. Academic Press, 2020. p. 123–140. ISBN 978-0-12-815739-8. Disponível em: <https://www.sciencedirect.com/science/article/pii/B9780128157398000079>.