



**UNIVERSIDADE FEDERAL DO CEARÁ  
CAMPUS DE RUSSAS  
CURSO DE GRADUAÇÃO EM ENGENHARIA MECÂNICA**

**JOÃO VICTOR DA ROCHA ARAÚJO**

**MODELOS PARA PREDIÇÃO DE BLAINE E FINURA  
NO PROCESSO DE MOAGEM DE CIMENTO**

**RUSSAS**

**2025**

JOÃO VICTOR DA ROCHA ARAÚJO

MODELOS PARA PREDIÇÃO DE BLAINE E FINURA  
NO PROCESSO DE MOAGEM DE CIMENTO

Trabalho de Conclusão de Curso apresentado ao  
Curso de Graduação em Engenharia Mecânica  
do Campus de Russas da Universidade Federal  
do Ceará, como requisito à obtenção do grau de  
bacharel em Engenharia Mecânica.

Orientador: Prof. Dr. Dmontier Pinheiro  
Aragão Junior

RUSSAS

2025

Dados Internacionais de Catalogação na Publicação  
Universidade Federal do Ceará  
Sistema de Bibliotecas  
Gerada automaticamente pelo módulo Catalog, mediante os dados fornecidos pelo(a) autor(a)

---

A689m Araújo, João Victor da Rocha.

Modelos para predição de blaine e finura no processo de moagem de cimento / João Victor da Rocha Araújo. – 2025.  
64 f. : il. color.

Trabalho de Conclusão de Curso (graduação) – Universidade Federal do Ceará, Campus de Russas,  
Curso de Engenharia Mecânica, Russas, 2025.

Orientação: Prof. Dr. Dmontier Pinheiro Aragão Junior.

1. Inteligência artificial. 2. Finura. 3. Blaine. I. Título.

CDD 620.1

---

**JOÃO VICTOR DA ROCHA ARAÚJO**

**MODELOS PARA PREDIÇÃO DE BLAINE E FINURA  
NO PROCESSO DE MOAGEM DE CIMENTO**

Trabalho de Conclusão de Curso apresentado ao  
Curso de Graduação em Engenharia Mecânica  
do Campus de Russas da Universidade Federal  
do Ceará, como requisito à obtenção do grau de  
bacharel em Engenharia Mecânica.

Aprovada em: 01 de Agosto de 2025

**BANCA EXAMINADORA**

---

Prof. Dr. Dmontier Pinheiro Aragão  
Junior (Orientador)  
Universidade Federal do Ceará (UFC)

---

Profa. Dra. Rosineide Fernando da Paz  
Universidade Federal do Ceará (UFC)

---

Luis Antonio Viana Franklin  
Universidade do Estado do Ceará (UECE)

---

Gerson Almeida Ribeiro  
Companhia de Cimento Apodi

Aos meus pais. Seus ensinamentos e toda a dedicação na minha criação foram fundamentais para que eu seguisse pelo caminho do bem. E aos meus irmãos, o companheirismo de vocês ao longo da vida me ensinou o verdadeiro valor da amizade.

## **AGRADECIMENTOS**

Aos meus pais, por sempre acreditarem em mim e me apoiarem de diversas maneiras ao longo dos anos, proporcionando uma base sólida e uma boa educação.

Aos meus irmãos, que sempre estiveram ao meu lado, incentivando-me a ser uma pessoa e um profissional melhor a cada dia.

Ao meu amigo Ismael Carvalho, que desde o ensino médio tem sido uma presença constante, uma amizade que levo com gratidão e carinho.

Ao Prof. Dr. Dmontier Pinheiro Aragão Junior, por sua orientação, paciência e por confiar em mim em diversos momentos nessa etapa da graduação.

Ao Luis Franklin, que nos últimos anos tem sido mais que um colega, um verdadeiro amigo, sempre pronto a ajudar e apoiar nesta jornada.

A todos os estagiários da Cimento Apodi, com quem tive o prazer de conviver e compartilhar experiências enriquecedoras. Em especial, agradeço à Maria Yane, Laila Ellen e Kely Mota, pela parceria e amizade.

À equipe de Automação Gerson Ribeiro, Luiz Paulo e Aderlanio Maia, pois, com a paciência e o apoio deles, além de conseguir me desenvolver profissionalmente, também conquistei boas amizades.

À Shirley Naira, que esteve comigo ao longo do ensino médio e de toda a graduação, sendo não apenas uma grande amiga, mas também um apoio constante em minha caminhada.

E a todos as pessoas que de alguma forma me ajudaram nessa caminhada.

“O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado.”

(Ariano Suassuna)

## **RESUMO**

A inteligência artificial vem avançando em várias áreas, como, por exemplo, automação de processos, segurança digital e tarefas do cotidiano humano. Fazendo contraste com a tradição da produção de cimento, a tecnologia vem não só para substituir processos manuais, como também para auxiliar na cadeia produtiva como um todo. Atualmente, na industria cimenteira, o processo de medição da finura e do blaine do cimento acontece de forma manual, em intervalos de duas horas entre cada medição. Nesse sentido, o estudo de modelos de aprendizado de máquina pode abrir portas para uma eventual integração da inteligência artificial com os painéis lógicos da fábrica, visto que parte da tomada de decisão do operador é baseada nesses dois parâmetros. Com isso, este trabalho propõe o estudo de modelos de aprendizado de máquina para a predição da finura e da porosidade. Notou-se que alguns modelos tiveram boa interpretação dos dados industriais para a predição dessas duas variaveis. Espera-se que este trabalho possa auxiliar essa integração futuramente na industria cimenteira, tornando o processo mais moderno e eficiente.

**Palavras-chave:** predição; inteligência; artificial; finura; blaine.

## **ABSTRACT**

Artificial intelligence has been advancing in several areas, such as process automation, digital security, and everyday human tasks. In contrast to the traditional practices of cement production, technology is not only replacing manual processes but also assisting the entire production chain. Currently, in the cement industry, the measurement of cement fineness and Blaine is performed manually, with intervals of two hours between each measurement. In this context, the study of machine learning models can open the door to a future integration of artificial intelligence with the factory's logic panels, since part of the operator's decision-making is based on these two parameters. Therefore, this work proposes the study of machine learning models for the prediction of fineness and porosity. It was observed that some models achieved good interpretation of industrial data for predicting these two variables. It is expected that this research may support future integration of AI in the cement industry, making the process more modern and efficient.

**Keywords:** prediction; artificial; intelligence; fineness; blaine.

## LISTA DE FIGURAS

|   |    |
|---|----|
| Figura 1 – Representação de um Moinho Vertical de Rolos.                | 19 |
| Figura 2 – Peneiras utilizadas no processo de peneiramento.             | 23 |
| Figura 3 – Peneirador a vácuo.  | 23 |
| Figura 4 – Equipamento utilizado no ensaio para determinar o Blaine.    | 24 |
| Figura 5 – Marcações para se determinar o tempo de desnível do líquido. | 25 |
| Figura 6 – Regressão Linear.  | 28 |
| Figura 7 – Utilização do Kernel RBF com SVR.                            | 29 |
| Figura 8 – Função de Ativação Sigmoid.                                  | 30 |
| Figura 9 – Função de Ativação Softmax.                                  | 30 |
| Figura 10 – Árvore de decisão Random Forest.                            | 31 |
| Figura 11 – Alimentação Total Moinho 1 e 2.                             | 38 |
| Figura 12 – Arraste (%DA01) Moinho 1.                                   | 39 |
| Figura 13 – Diferencial de pressão do filtro de manga.                  | 40 |
| Figura 14 – Recirculação (%DA02).                                       | 41 |
| Figura 15 – Velocidade do Classificador.                                | 42 |
| Figura 16 – Correlação de Pearson Finura.                               | 44 |
| Figura 17 – Correlação de Pearson Blaine.                               | 46 |
| Figura 18 – Finura - Regressão Linear.                                  | 48 |
| Figura 19 – Finura - Regressão Linear - Comparativo.                    | 49 |
| Figura 20 – Finura - SVR.   | 50 |
| Figura 21 – Finura - SVR - Comparativo.                                 | 51 |
| Figura 22 – Finura - MLP.   | 52 |
| Figura 23 – Finura - MLP - Comparativo.                                 | 53 |
| Figura 24 – Finura - Random Forest.                                     | 54 |
| Figura 25 – Finura - RandomForestFinura - Comparativo.                  | 55 |
| Figura 26 – Blaine - Regressão Linear.                                  | 57 |
| Figura 27 – Blaine - Regressão Linear - Comparativo.                    | 58 |
| Figura 28 – Blaine - SVR.   | 59 |
| Figura 29 – Blaine - SVR - Comparativo.                                 | 60 |
| Figura 30 – Blaine - MLP.   | 61 |
| Figura 31 – Blaine - MLP - Comparativo.                                 | 62 |

|  |    |
|--|----|
| Figura 32 – Blaine - Random Forest. . . . .                  | 63 |
| Figura 33 – Blaine - Regressão Linear - Comparativo. . . . . | 64 |

## **LISTA DE TABELAS**

|  |    |
|--|----|
| Tabela 1 – Faixa de valores das variáveis de processo. . . . .                   | 43 |
| Tabela 2 – Métricas do modelo de Regressão Linear para os moinhos 1 e 2. . . . . | 50 |
| Tabela 3 – Métricas do modelo SVR para os moinhos 1 e 2. . . . .                 | 52 |
| Tabela 4 – Métricas do modelo MLP para os moinhos 1 e 2. . . . .                 | 54 |
| Tabela 5 – Métricas do modelo Random Forest para os moinhos 1 e 2. . . . .       | 56 |
| Tabela 6 – Métricas do modelo de Regressão Linear para os moinhos 1 e 2. . . . . | 59 |
| Tabela 7 – Métricas do modelo SVR para os moinhos 1 e 2. . . . .                 | 61 |
| Tabela 8 – Métricas do modelo MLP para os moinhos 1 e 2. . . . .                 | 63 |
| Tabela 9 – Métricas do modelo Random Forest para os moinhos 1 e 2. . . . .       | 64 |

## **LISTA DE QUADROS**

|  |    |
|--|----|
| Quadro 1 – Composição dos tipos de cimento Portland. . . . . | 20 |
| Quadro 2 – Requisitos físicos do cimento Portland. . . . .   | 21 |

## LISTA DE SÍMBOLOS

|         |                                  |
|---------|----------------------------------|
| $C_2S$  | Silicato dicálcico               |
| $C_3A$  | Aluminato tricálcico             |
| $C_3S$  | Silicato tricálcico              |
| $C_4AF$ | Ferroaluminato tetracálcico      |
| $IA$    | Inteligência Artificial          |
| $MAE$   | Erro Absoluto Médio              |
| $MLP$   | Perceptron de Múltiplas Camadas  |
| $MQO$   | Mínimos quadrados ordinários     |
| $mmca$  | Milímetros de coluna de água     |
| $\mu m$ | Micrômetro                       |
| $R^2$   | Coeficiente de Determinação      |
| $RMSE$  | Raiz do Erro Quadrático Médio    |
| $SSE$   | Soma dos Quadrados dos Erros     |
| $SVM$   | Support Vector Machine           |
| $SVR$   | Regressão por Vetores de Suporte |
| $SST$   | Soma Total dos Quadrados         |

## SUMÁRIO

|              |   |           |
|--------------|---|-----------|
| <b>1</b>     | <b>INTRODUÇÃO . . . . .</b>   | <b>16</b> |
| <b>1.1</b>   | <b>Objetivos do Trabalho . . . . .</b>  | <b>17</b> |
| <b>1.1.1</b> | <b><i>Objetivo Geral . . . . .</i></b>  | <b>17</b> |
| <b>1.1.2</b> | <b><i>Objetivos Específicos . . . . .</i></b>                                     | <b>17</b> |
| <b>1.2</b>   | <b>Justificativa . . . . .</b>  | <b>18</b> |
| <b>2</b>     | <b>FUNDAMENTAÇÃO TEÓRICA . . . . .</b>  | <b>19</b> |
| <b>2.1</b>   | <b>Finura do Cimento . . . . .</b>  | <b>22</b> |
| <b>2.2</b>   | <b>Índice Blaine . . . . .</b>  | <b>24</b> |
| <b>2.3</b>   | <b>Aprendizado de Máquina . . . . .</b>   | <b>26</b> |
| <b>2.3.1</b> | <b><i>Regressão Linear . . . . .</i></b>  | <b>27</b> |
| <b>2.3.2</b> | <b><i>Support Vector Regression (SVR) . . . . .</i></b>                           | <b>28</b> |
| <b>2.3.3</b> | <b><i>Multi-Layer Perceptron (MLP) . . . . .</i></b>                              | <b>29</b> |
| <b>2.3.4</b> | <b><i>Random Forest . . . . .</i></b>   | <b>30</b> |
| <b>2.4</b>   | <b>Métricas de Avaliação . . . . .</b>  | <b>32</b> |
| <b>2.4.1</b> | <b><i>Coeficiente de Determinação (<math>R^2</math>) . . . . .</i></b>            | <b>32</b> |
| <b>2.4.2</b> | <b><i>Erro Absoluto Médio (MAE) . . . . .</i></b>                                 | <b>33</b> |
| <b>2.4.3</b> | <b><i>Raiz do Erro Quadrático Médio (RMSE) . . . . .</i></b>                      | <b>33</b> |
| <b>3</b>     | <b>METODOLOGIA . . . . .</b>  | <b>34</b> |
| <b>3.1</b>   | <b>Coleta de Dados Operacionais . . . . .</b>                                     | <b>34</b> |
| <b>3.2</b>   | <b>Apoio Técnico e Experiência Operacional . . . . .</b>                          | <b>34</b> |
| <b>3.3</b>   | <b>Organização e Estruturação dos Dados . . . . .</b>                             | <b>34</b> |
| <b>3.4</b>   | <b>Tratamento e Limpeza dos Dados . . . . .</b>                                   | <b>35</b> |
| <b>3.5</b>   | <b>Análise de Correlação . . . . .</b>  | <b>35</b> |
| <b>3.6</b>   | <b>Aplicação de Modelos de Machine Learning e Deep Learning . . . . .</b>         | <b>36</b> |
| <b>3.7</b>   | <b>Avaliação dos Modelos Preditivos e Validação dos Resultados . . . . .</b>      | <b>36</b> |
| <b>4</b>     | <b>RESULTADOS . . . . .</b>   | <b>38</b> |
| <b>4.1</b>   | <b>Séries temporais para todas as variáveis sem aplicação de filtro . . . . .</b> | <b>38</b> |
| <b>4.1.1</b> | <b><i>Alimentação Total . . . . .</i></b>   | <b>38</b> |
| <b>4.1.2</b> | <b><i>Arraste (%DA01) . . . . .</i></b>   | <b>39</b> |
| <b>4.1.3</b> | <b><i>Diferencial de pressão do filtro de manga . . . . .</i></b>                 | <b>40</b> |

|                |   |    |
|----------------|---|----|
| <b>4.1.4</b>   | <i>Recirculação (%DA02)</i> . . . . .           | 41 |
| <b>4.1.5</b>   | <i>Velocidade do Classificador</i> . . . . .    | 42 |
| <b>4.2</b>     | <b>Correlação de Pearson</b> . . . . .          | 44 |
| <b>4.3</b>     | <b>Resultados Moinhos 1 e 2</b> . . . . .       | 48 |
| <b>4.3.1</b>   | <i>Finura</i> . . . . .                         | 48 |
| <i>4.3.1.1</i> | <i>Regressão Linear</i> . . . . .               | 48 |
| <i>4.3.1.2</i> | <i>SVR</i> . . . . .                            | 50 |
| <i>4.3.1.3</i> | <i>MLP</i> . . . . .                            | 52 |
| <i>4.3.1.4</i> | <i>Random Forest</i> . . . . .                  | 54 |
| <b>4.3.2</b>   | <i>Blaine</i> . . . . .                         | 57 |
| <i>4.3.2.1</i> | <i>Regressão Linear</i> . . . . .               | 57 |
| <i>4.3.2.2</i> | <i>SVR</i> . . . . .                            | 59 |
| <i>4.3.2.3</i> | <i>MLP</i> . . . . .                            | 61 |
| <i>4.3.2.4</i> | <i>Random Forest</i> . . . . .                  | 63 |
| <b>5</b>       | <b>CONCLUSÕES E TRABALHOS FUTUROS</b> . . . . . | 65 |
|                | <b>REFERÊNCIAS</b> . . . . .                    | 66 |

## 1 INTRODUÇÃO

Humanos dependem de seus esforços para aprimorar a maneira de realizar algum tipo de atividade, enquanto computadores apenas executam funções predeterminadas a eles, ou seja, seguem padrões fornecidos e podem realizar ações com mais eficiência, mas não podem aprender com a experiência que estas ações promovem (Michalski *et al.*, 1990). Os estudos sobre inteligência artificial (IA) tem avançado nos últimos anos, abrangendo diversas aplicações e ramos a serem estruturados e pesquisados, em busca de automatizar trabalhos rotineiros, além de distinguir imagens, falas e avanços na medicina. Um dos maiores desafios é fazer com que tarefas fáceis, resolvidas de maneira intuitivas, mas de difícil descrição, realizadas pelo ser humano também sejam realizadas através de inteligências artificiais (Goodfellow *et al.*, 2016).

O controle de qualidade do produto é feito para garantir o desempenho, a durabilidade e se está conforme as normas técnicas do cimento produzido. Alguns desses parâmetros são o blaine e a finura. Blaine é a área superficial específica do cimento, medida em  $\text{cm}^2/\text{g}$ , enquanto a finura é medida pelo resíduo que fica retido na peneira (Associação Brasileira de Normas Técnicas, 2014).

Os valores dessas duas variáveis são obtidos a partir de análises laboratoriais, com intervalos de duas horas entre cada um dos valores. Como esse tempo de espera entre cada um dos valores é relativamente alto, o uso de modelos de IA é interessante para um melhor ajuste de parâmetros das variáveis-alvo, visando à obtenção de valores dentro de faixas definidas em normas, como as NBR, fazendo com que se obtenham vários benefícios.

Os benefícios obtidos com os valores mais ajustados são níveis de resistência e humidade do cimento melhores, além de menor consumo energético, que é um fator muito importante, pois durante a moagem ocorre o maior gasto de energia no processo de produção do cimento (FLSmidth, 2024a).

Com isso, temos que o objetivo desse trabalho é verificar qual modelo de inteligência artificial melhor se ajusta aos dados industriais selecionados, com o intuito de prever variáveis como blaine e finura do cimento produzido, de forma a atender às normas da indústria cimenteira.

O treinamento do modelo para o Moinho 1 e 2 foi realizado com dados coletados da planta com uma margem de aproximadamente 80~100 dias considerando que logo após o moinho 2 passaria por uma grande parada para manutenção.

Após o treinamento e validação dos modelos, foram realizados testes para avaliar a qualidade das previsões do blaine e da finura. Os resultados foram satisfatórios para as previsões, sendo os de Regressão Linear e *Random Forest* os melhores nesse contexto. As métricas utilizadas foram R<sup>2</sup>, MAE e RMSE.

Para o blaine, os modelos apresentaram um erro mais alto em relação à finura devido à natureza da sua unidade de medida, porém foram satisfatórios em ambos os casos. Isso possibilita ter uma boa estimativa contínua em tempo real dos valores, com uma boa confiabilidade, ou seja, permite ajustes operacionais mesmo antes dos dados laboratoriais serem disponibilizados.

De maneira geral, os resultados que foram obtidos pelos modelos em ambas as variáveis foram satisfatórios, e isso pode vir a se refletir em valores de consumo energético na etapa de moagem e também no tempo de produção.

## **1.1 Objetivos do Trabalho**

Este capítulo tem o intuito de mostrar a motivação e justificativa por trás da realização desse trabalho, assim como os principais objetivos gerais e específicos que se deseja realizar/alcançar com o mesmo.

### **1.1.1 *Objetivo Geral***

Propor modelos eficientes de previsão para blaine e finura do Cimento *Portland*, verificando quais variáveis contribuem mais para os valores reais e assim fazendo uso de técnicas de IA como *Machine Learning* e rede neural artificial (RNA).

### **1.1.2 *Objetivos Específicos***

- Criar uma base de dados para um estudo mais aprofundado sobre os valores de blaine e finura;
- Verificar dados não válidos e retirá-los para a realização das análises;
- Ajustar os hiperparâmetros dos vários modelos para receberem os dados;
- Verificar os resultados obtidos das análises e se eles foram satisfatórios;

## 1.2 Justificativa

A finura e o blaine estão diretamente interligados com a hidratação do cimento. Sua velocidade para liberar o calor, ou seja, pode-se dizer a superfície específica é proporcional à reação inicial de cada composto, porém, em um momento mais avançado da hidratação, essa correlação é quase zero (Neville, 2016). Podemos concluir que quanto mais fino o material estiver, maior reação inicial ela vai ter, resultando em uma resistência inicial maior para Cimentos Portland.

As normas brasileiras que abrangem os níveis de finura e blaine têm a intenção de padronizar e colocar níveis ideais para cada tipo de uso, com o intuito de atingir níveis de resistência, humidade e outros fatores que serão levados em conta para o usuário final. A previsão dessas variáveis têm sua importância na indústria para ter um controle maior sobre as propriedades do produto, otimizar o tempo de produção evitando que ocorra uma moagem excessiva que afetaria o consumo de energia (FLSmidth, 2024a).

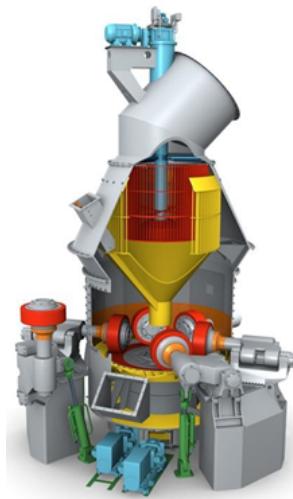
## 2 FUNDAMENTAÇÃO TEÓRICA

Uma das fases mais importantes na produção do cimento é a etapa em que ocorre a moagem do cimento, sendo que nela é usado o clínquer, que é transformado em um pó fino e homogêneo a partir da mistura com outros materiais como calcário, escória, gesso e outros, que são esperados para obter as características necessárias de cada um dos cimentos (Associação Brasileira de Normas Técnicas, 2018).

O cimento portland tem sua qualidade e desempenho diretamente relacionado com a composição desses materiais usados como matéria-prima, cada um deles impacta nas suas propriedades mecânicas como durabilidade, tempo de reação, hidratação. O clínquer é o principal material usado na criação do cimento Portland (Meneses, 2023), ele é resultado de uma calcinação da mistura de calcário e argila em alta temperatura. Ele é composto por  $C_3S$ ,  $C_2S$ ,  $C_3A$  e  $C_4AF$  (Gobbo, 2003).

A moagem retratada neste trabalho é feita em dois moinhos de rolos verticais idênticos, com isso, na moagem a granulometria do material é reduzida a partir da ação dos rolos sobre uma mesa rotativa, o controle sobre a granulometria é bastante importante, pois tem uma grande relação direta com propriedades como resistência mecânica, tempo de pega e hidratação do cimento.

Figura 1 – Representação de um Moinho Vertical de Rolos.



Fonte: Cruz (2017).

Cada tipo de cimento tem algumas características específicas para quais ele foi projetado que faz com que tenha que se atender requisitos de resistência e durabilidade, para que essas propriedades estejam de acordo com a composição dos cimentos segue uma padronização que envolve normas técnicas, como a (Associação Brasileira de Normas Técnicas, 2018) na qual estabelece níveis de materiais pozolânicos, carbônicos, escória e clínquer, assim como faixas de valores mínimos de resistência que devem ser alcançados em até 28 dias de idade do cimento.

Quadro 1 – Composição dos tipos de cimento Portland.

| Designação normalizada  | Sigla             | Classe de resistência | Sufixo       | Clínquer + sulfatos de cálcio | Escória granulada de alto-forno | Material pozolânico | Material carbonático |
|---|-------------------|-----------------------|--------------|-------------------------------|---------------------------------|---------------------|----------------------|
| Cimento Portland comum  | CP I              | 25, 32 ou 40          | RS ou BC     | 95 – 100                      | 0 – 5                           |                     |                      |
|   | CP I-S            |                       |              | 90 – 94                       | 0                               | 0                   | 6 – 10               |
| Cimento Portland composto com escória granulada de alto-forno | CP II-E           |                       |              | 51 – 94                       | 6 – 34                          | 0                   | 0 – 15               |
| Cimento Portland composto com material pozolânico             | CP II-Z           |                       |              | 71 – 94                       | 0                               | 6 – 14              | 0 – 15               |
| Cimento Portland composto com material carbonático            | CP II-F           |                       |              | 75 – 89                       | 0                               | 0                   | 11 – 25              |
| Cimento Portland de alto forno                                | CP III            |                       |              | 25 – 65                       | 35 – 75                         | 0                   | 0 – 10               |
| Cimento Portland pozolânico                                   | CP IV             |                       |              | 45 – 85                       | 0                               | 15 – 50             | 0 – 10               |
| Cimento Portland de alta resistência inicial                  | CP V <sup>a</sup> | ARI                   |              | 90 – 100                      | 0                               | 0                   | 0 – 10               |
| Cimento Portland branco                                       | Estrutural        | CPB                   | 25, 32 ou 40 | 75 – 100                      | –                               | –                   | 0 – 25               |
|   | Não estrutural    |                       |              | 50 – 74                       | –                               | –                   | 26 – 50              |

<sup>a</sup> No caso de cimento Portland de alta resistência inicial resistente a sulfatos (CP V-ARI RS), podem ser adicionadas escórias granuladas de alto-forno ou materiais pozolânicos.

Fonte: (Associação Brasileira de Normas Técnicas, 2018).

Quadro 2 – Requisitos físicos do cimento Portland.

| Sigla <sup>a</sup> | Classe | Finura                     | Tempo de início de pega | Expansibilidade a quente | Resistência à compressão MPa |    |        |        | Índice de brancura |
|--------------------|--------|----------------------------|-------------------------|--------------------------|------------------------------|----|--------|--------|--------------------|
|                    |        | Resíduo na peneira 75 µm % |                         |                          | min                          | mm | 1 dia  | 3 dias |                    |
| CP I               | 25     | ≤ 12,0                     | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 8,0  | ≥ 15,0 | ≥ 25,0             |
| CP I-S             |        | ≤ 12,0                     | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 10,0 | ≥ 20,0 | ≥ 32,0             |
| CP II-E            |        | ≤ 12,0                     | ≥ 60                    | ≤ 5                      | –                            | –  | –      | –      | –                  |
| CP II-F            |        | ≤ 10,0                     | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 15,0 | ≥ 25,0 | ≥ 40,0             |
| CP II-Z            |        | ≤ 10,0                     | ≥ 60                    | ≤ 5                      | –                            | –  | –      | –      | –                  |
| CP III             | 32     | ≤ 8,0                      | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 8,0  | ≥ 15,0 | ≥ 25,0             |
| CP IV              |        | ≤ 8,0                      | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 10,0 | ≥ 20,0 | ≥ 32,0             |
| CP V               |        | ≤ 8,0                      | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 12,0 | ≥ 23,0 | ≥ 40,0             |
| CPB Estrutural     | 40     | ≤ 6,0                      | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 14,0 | ≥ 24,0 | ≥ 34,0             |
| CPB Não estrutural |        | ≤ 12 <sup>b</sup>          | ≥ 60                    | ≤ 5                      | –                            | –  | –      | –      | –                  |
| CPB Não estrutural |        | ≤ 12 <sup>b</sup>          | ≥ 60                    | ≤ 5                      | –                            | –  | –      | –      | –                  |
| CPB Não estrutural |        | ≤ 12 <sup>b</sup>          | ≥ 60                    | ≤ 5                      | –                            | –  | –      | –      | –                  |
| CPB Não estrutural | –      | ≤ 12,0 <sup>b</sup>        | ≥ 60                    | ≤ 5                      | –                            | –  | ≥ 5,0  | ≥ 7,0  | ≥ 10,0             |
| CPB Não estrutural | –      | ≤ 12,0 <sup>b</sup>        | ≥ 60                    | ≤ 5                      | –                            | –  | –      | –      | –                  |

<sup>a</sup> Requisitos aplicáveis também aos cimentos resistentes a sulfatos e de baixo calor de hidratação, identificados por sua sigla seguida do sufixo RS ou BC, respectivamente.  
<sup>b</sup> Resíduo na peneira 45 µm.

Fonte: (Associação Brasileira de Normas Técnicas, 2018).

Na etapa de moagem, a eficiência energética é um fator com um grande nível de importância, pois é nesta fase do processo de fabricação que mais se consome energia elétrica, por isso a indústria tem tentado modernizar e aprimorar os moinhos para que os custos sejam reduzidos e ao mesmo tempo entreguem a qualidade final esperada do cimento de acordo com informações da empresa FLSmidth, essas modernizações ao longo do tempo fizeram com que o consumo de energia dos moinhos de rolos verticais seja de 30% a 45% menores se comparados a moinhos de bolas no processo de moagem de cimento e de 40% a 50% menor para escória (FLSmidth, 2024b).

Em decorrência disso, a moagem é um passo importante e estratégico no qual são determinadas em grande parte as propriedades do cimento produzido, mas também são notados os ganhos de eficiência energética no processo de fabricação.

## 2.1 Finura do Cimento

A finura do cimento é medida através de métodos como superfície específica blaine e peneiramento para visualizar a retenção de material, cimento bastante fino pode fazer com que as reações ocorram de maneira bastante rápida, enquanto o contrário pode levar a uma redução de resistência mecânica, por isso a finura do cimento é um dos parâmetros importantes que são monitorados no processo de fabricação do cimento (Neville, 2016).

Uma das propriedades físicas do cimento na qual é relacionado ao tamanho das partículas é a finura, a granulometria que é resultado do processo de moagem da mistura de clínquer, calcário, escória e outros elementos que compõem o cimento. É um parâmetro de grande influência, na qual está relacionado a alguns comportamentos que o cimento tem na sua aplicação, ainda segundo Neville isto interfere na hidratação, tempo de pega, resistência mecânica e também em sua durabilidade.

No processo de reação química entre a água e os compostos do cimento, ela ocorre em sua grande parte na superfície das partículas, fazendo com que quanto mais fino for o material, maior será sua área superficial na qual será possível ter a reação e acelerando o processo de pega e o ganho de resistência inicial. Porém, um material muito fino terá um gasto excessivo de água, aumentando a porosidade do material e todo seu processo faz com que tenha um impacto negativo na durabilidade do material.

Como se sabe, a finura pode ser determinada por métodos como peneiramento e o de permeabilidade de blaine, o método de peneiramento é composto de um ensaio simples que mede em valores percentuais as partículas que estão retidas nas peneiras, apesar da norma (Associação Brasileira de Normas Técnicas, 2018) pedir para se utilizar a peneira de 75 $\mu\text{m}$  (nº 200), no trabalho vamos utilizar peneiras de 45 $\mu\text{m}$  (nº 325) e 38 $\mu\text{m}$  (nº 400), para ter uma sensibilidade maior na detecção de partículas mais finas, além de permitir uma captura de variação maior. E mesmo sendo um processo rápido, não representa tão bem a granulometria total do material, como em partículas muito finas na qual influencia bastante na hidratação.

Figura 2 – Peneiras utilizadas no processo de peneiramento.



Fonte: O autor (2025).

Monitorar e controlar os valores de finura é uma maneira de assegurar a regularidade e o desempenho do cimento de acordo com as normas. Uma variação grande dessa propriedade como foi visto, pode comprometer as estruturas do cimento e impactar suas propriedades.

É usado um peneirador a vácuo para realizar todo o processo de cálculo da finura do material, o valor utilizado para isso foi de 200mmca, sendo controlado o tempo no qual o material será exposto ao vácuo e medido em uma balança com resolução de 0.01 g.

Figura 3 – Peneirador a vácuo.



Fonte: O autor (2025).

## 2.2 Índice Blaine

Blaine é uma medida da área superficial específica do cimento, sendo normalmente expressa em  $\text{cm}^2/\text{g}$ . Determinada pelo método de permeabilidade ao ar, esse método é bastante utilizado para se avaliar a finura do cimento portland. O ensaio deste método que pode ser visto na Figura 4, é baseado na resistência que uma corrente de ar encontra ao atravessar um recipiente compacto composto de partículas de cimento, como no outro método, quanto menor for o tamanho de sua granulometria maior será a sua área superficial, sendo assim maior será a resistência ao fluxo de ar, o que resulta em um maior valor de blaine (Associação Brasileira de Normas Técnicas, 2014).

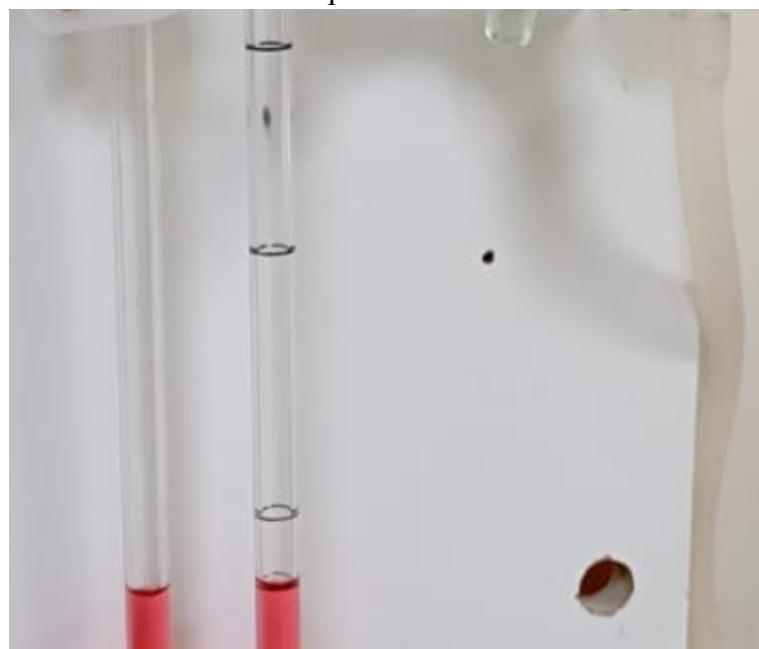
Figura 4 – Equipamento utilizado  
no ensaio para  
determinar o Blaine.



Fonte: O autor (2025).

Blaine está totalmente relacionado com a finura do material, assim sendo, um indicador importante na produção de cimento, sua área superficial está relacionada com a taxa na qual o material é hidratado, pois quanto maior for o blaine, maior será sua área superficial assim ele terá uma área de maior contato, e isso acelera as reações químicas e o contrário também ocorre quanto menor for o índice, a hidratação ocorrerá de maneira mais lenta, ou seja, a reação química vai ocorrer de maneira mais devagar atingindo uma resistência inicial menor levando em consideração o mesmo tempo (Neville, 2016).

Figura 5 – Marcações para se determinar o tempo de desnível do líquido.



Fonte: O autor (2025).

Valor importante no cálculo do blaine, que é resultante do ensaio, é o tempo em segundos no qual o líquido sai da segunda marcação para a primeira marcação, como é visto na Figura 5.

$$S = \frac{K \cdot \sqrt{e^3} \cdot \sqrt{t}}{p \cdot (1-e) \cdot \sqrt{0.1n}} \quad (2.1)$$

- K é a constante do aparelho, K = 2.4195;
- “e” representa a porosidade da camada;
- t é o tempo que foi medido em segundos;s

- $p$  é a massa específica do cimento;
- $n$  é a viscosidade do ar à temperatura do ensaio;

Alguns fatores que influenciam no valor do índice de blaine são o tempo de moagem, pois quanto maior o tempo, maior será o índice do blaine, porém, o custo energético será maior, os materiais utilizados e os índices da utilização de cada um deles também afetam o resultado final.

O controle do blaine baseado nas normas vigentes como (Associação Brasileira de Normas Técnicas, 2014). É importante garantir sua margem para se ter uma boa qualidade e resistência nos diversos tipos de cimento para cada uma de suas aplicações.

### **2.3 Aprendizado de Máquina**

O Aprendizado de Máquinas é um dos vários campos da Inteligência Artificial (IA) no qual objetivo central é a identificação de padrões em dados, sobre fenômenos que envolvem incertezas, em vez de seguir instruções, os modelos de aprendizado de máquina aprendem com esses dados, fazendo ajustes nos seus próprios parâmetros com base no histórico, fazendo uma generalização para novos dados (Mitchell, 1997).

*Deep Learning* é um tipo de aprendizado de máquina no qual se tem uma espécie de hierarquia de conceitos, isso permite o aprendizado de conceitos mais complicados por meio de outros mais simples, esse aprendizado tem, várias camadas, para se chegar no resultado esperado (Goodfellow *et al.*, 2016).

Na criação do modelo são levados em consideração seu aprendizado se tem esses seguintes tipos aprendizado supervisionado no qual o modelo aprende a partir de uma base de dados onde cada entrada está associada a uma saída conhecida, aprendizado não supervisionado onde os dados não têm suas entradas vinculadas a uma saída conhecida e aprendizado por reforço que aprende por tentativa e erro.

O tipo de aprendizado usado neste trabalho será o supervisionado, pois ele será treinado a partir de um conjunto de dados que possuem rótulo, ou seja, para cada uma das várias variáveis independentes existe uma variável dependente.

### 2.3.1 Regressão Linear

Sendo bastante utilizado quando se trata de aprendizado de máquinas, o seu principal é objetivo é a criação de um modelo feito através da relação entre uma variável dependente (*target*) e uma ou mais variáveis independentes (*features*) através de uma equação linear. Segundo (Montgomery *et al.*, 2012), o modelo pode ser representado por duas equações:

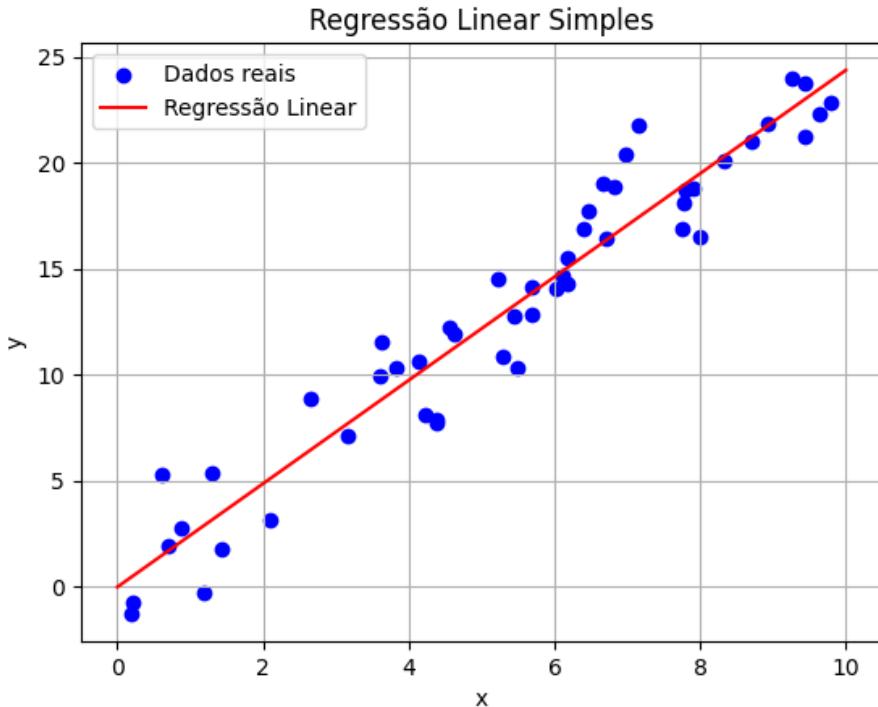
$$y = \beta_0 + \beta_1 x + \varepsilon \quad (2.2)$$

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon \quad (2.3)$$

Sendo a primeira regressão linear simples, e a segunda, a regressão linear múltipla, que será a usada neste trabalho, onde  $y$  representa a variável dependente,  $x_k$  são as variáveis independentes,  $\beta_k$  são os coeficientes que indicam a influência de cada variável independente sobre  $y$  e o termo de erro é representado por  $\varepsilon$ . O ajuste do modelo é geralmente feito pelo método dos mínimos quadrados ordinários (MQO), que minimiza a soma dos quadrados dos erros.

Embora seja um modelo simples, como pode ser visto graficamente na Figura 6, a regressão linear possui limitações, como a grande quantidade de multicolinearidade que pode ser ruim para a criação dos modelos, como a suposição de linearidade, homoscedasticidade e normalidade dos erros. A não utilização desses princípios compromete a validade do modelo, tornando essencial a análise exploratória dos dados e testes estatísticos.

Figura 6 – Regressão Linear.



Fonte: O autor (2025).

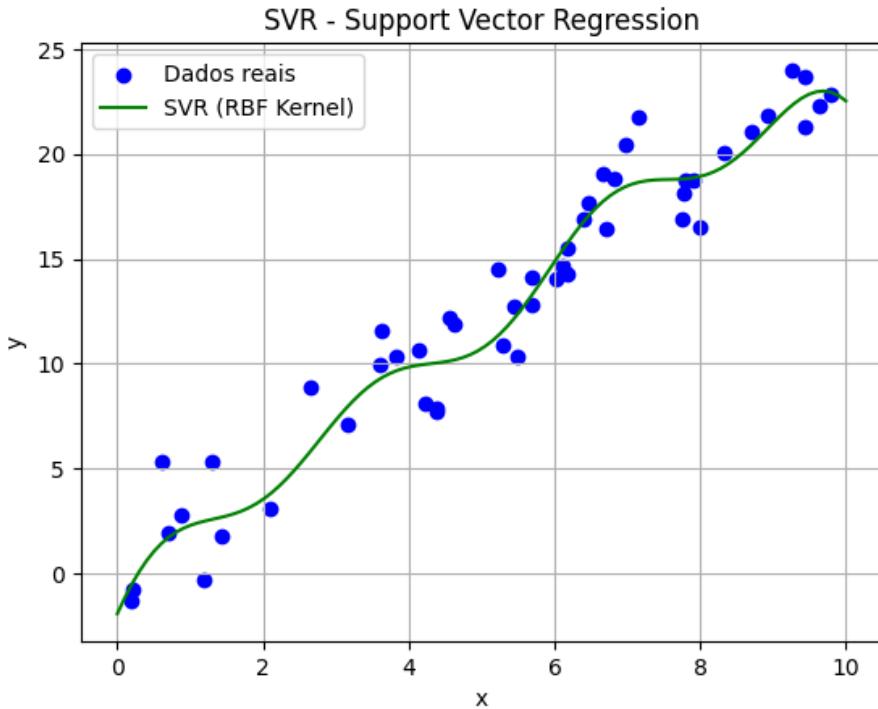
### 2.3.2 Support Vector Regression (SVR)

A Regressão por Vetores de Suporte (SVR) é uma extensão da Máquina de Vetores de Suporte (SVM). Enquanto SVM é usado para problemas de classificação o SVR é usado para problemas de regressão (Deng *et al.*, 2012). Neste trabalho, utilizamos a de regressão. Seu principal objetivo é achar uma função que tenha uma margem de tolerância/desvio  $\epsilon$  para as previsões e seja a mais plana possível. Tende a ter bom desempenho em conjuntos de dados com ruído e alta dimensionalidade, mas exige um maior custo computacional e cuidado com a seleção de hiperparâmetros.

SVR utiliza funções *kernel* como um meio para a projeção de dados em espaços de alta dimensionalidade. Isso permite a criação de modelos com relações não lineares entre as variáveis. Os principais tipos de *kernel* utilizados são Linear, Polinomial e *Radial Basis Function* (RBF).

Apesar do modelo gerado por SVR ter uma ótima capacidade de previsão, também aumenta sua complexidade e a dificuldade de compreender o processo de decisão do modelo, como podemos ver graficamente na Figura 7. Com isso o SVR não fornece uma explicação direta sobre como as variáveis de entrada influenciam as previsões.

Figura 7 – Utilização do Kernel RBF com SVR.



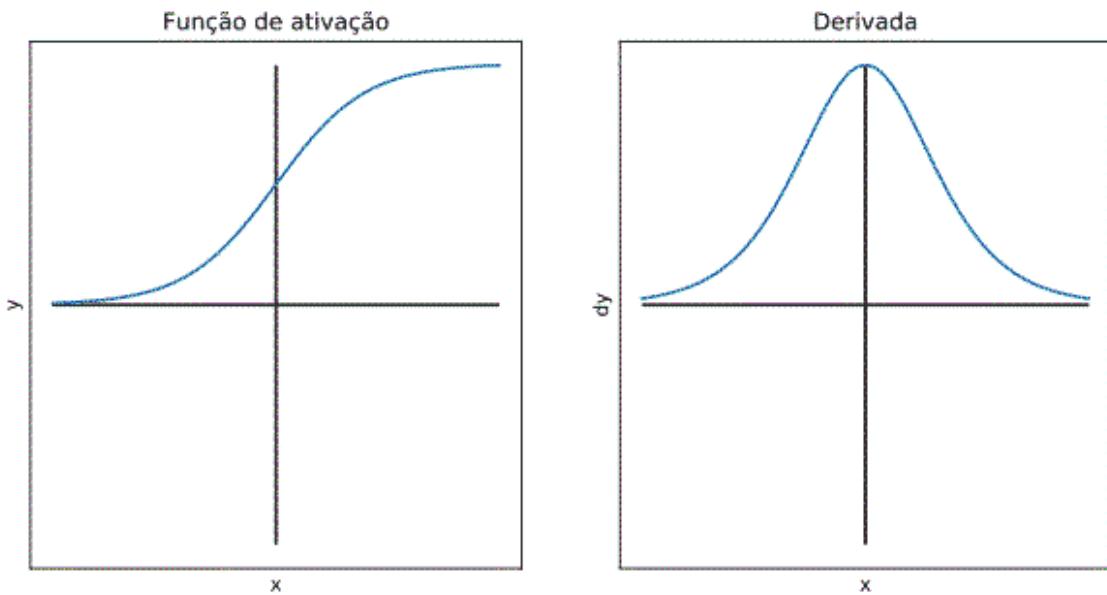
Fonte: O autor (2025).

### 2.3.3 Multi-Layer Perceptron (MLP)

O Perceptron de Múltiplas Camadas (MLP) é um tipo de rede neural artificial *feedforward* na qual os sinais são mandados em uma única direção, saindo da entrada passando para a saída sem *loops*, composta por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída, sendo que essas camadas ocultas são responsáveis por conseguir um modelo com relações complexas e não lineares, sendo bastante utilizada em aprendizado supervisionado, sua utilização compreende a classificação e a regressão (Goodfellow *et al.*, 2016). O nível de previsão do MLP para que ela tenha uma boa generalização dos dados depende da quantidade de neurônios, da taxa de aprendizado, da função de ativação escolhida e quantas épocas serão utilizadas na criação dos modelos.

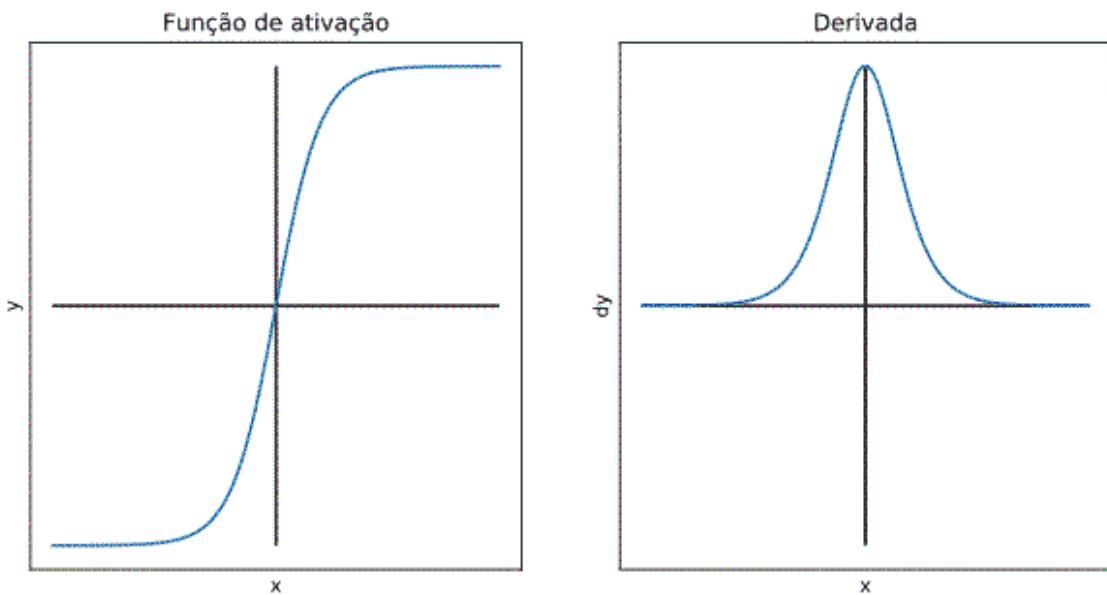
Cada camada oculta possui algum neurônio e nelas são aplicadas uma transformação linear aos dados de entrada além de uma função de ativação, sendo que essa função pode variar dependendo de qual uso deseja, algumas das mais usadas são as funções Sigmoide, Softmax, ReLU, Leaky Relu, sendo mostradas as duas primeiras nas Figuras 8 e 9 respectivamente.

Figura 8 – Função de Ativação Sigmoid.



Fonte: Ceccon (2020).

Figura 9 – Função de Ativação Softmax.



Fonte: Ceccon (2020).

#### 2.3.4 Random Forest

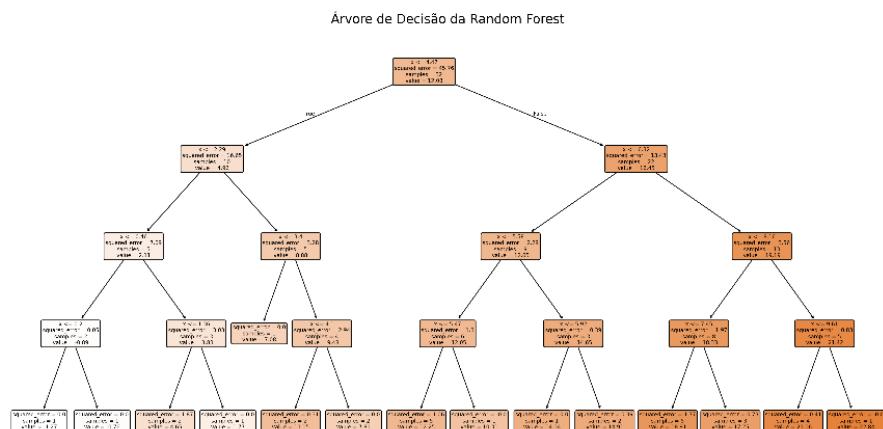
*Random Forest* é um método de *ensemble* sendo que este método consiste em combinar modelos individuais para formar um mais forte. *Random Forest* é baseado em múltiplas árvores de decisão, desenvolvido por (Breiman, 2001). O intuito principal é combinar previsões

de várias árvores, cada uma treinada com uma amostra bootstrap dos dados, ou seja, com uma amostra aleatória dos dados, e uma seleção aleatória de variáveis em cada divisão, isso faz com que o modelo criado tenha menos chance de ter *overfitting*.

Pode ser usado para regressão e classificação, sendo que na regressão a previsão final é a média dos resultados gerados por todas as árvores, já na classificação é utilizado a moda das decisões parciais. Com isso é obtida uma boa acurácia mesmo quando usado um conjunto de dados complexos como de uma indústria que tem muitas variáveis e ruídos.

Mas com todas essas árvores complexas é difícil compreender como o modelo chegou a um determinado valor, além do custo computacional ser alto devido ao grande volumes de dados e números de árvores utilizadas, na Figura 10 podemos ver um exemplo de funcionamento de uma árvore de decisão random forest.

Figura 10 – Árvore de decisão Random Forest.



Fonte: O autor (2025).

## 2.4 Métricas de Avaliação

A avaliação dos modelos é importante para a verificação da performance e também para evitar que os modelos não tenha problemas para ser generalizado para todo o universo que ele deve abranger. As métricas utilizadas neste trabalho são Coeficiente de Determinação ( $R^2$ ), Erro Absoluto Médio (MAE) e Raiz do Erro Quadrático Médio (RMSE).

### 2.4.1 Coeficiente de Determinação ( $R^2$ )

Coeficiente de determinação representado por  $R^2$ , é uma métrica usada para indicar e avaliar o quanto bem um modelo de regressão pode explicar a variação dos dados, ele pode assumir valores positivos e negativos variando de 1 a -1, Além disso quanto mais perto de 1 melhor o modelo explica a variação nos dados enquanto mais perto de -1 seria melhor usar a média para previsão, pois iria mais atrapalhar do que realmente ajudar, além disso pode assumir o valor 0 que uma média dos dados teria uma eficiência aproximada (Developers, 2024).

O cálculo do  $R^2$  é feito a partir da seguinte equação:

$$R^2 = 1 - \frac{SSE}{SST} \quad (2.4)$$

Onde SSE é calculado como:

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.5)$$

Com  $y_i$  sendo os valores reais e  $\hat{y}_i$  os valores preditos pelo modelo, além disso o  $SST$  é calculado através da seguinte equação:

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 \quad (2.6)$$

No qual  $\bar{y}_i$  é a média da soma de todos os valores reais.

### 2.4.2 Erro Absoluto Médio (MAE)

O Erro Absoluto Médio (MAE), é uma métrica usada para uma avaliação do desempenho de modelos. Ele representa o somatório da média das diferenças absolutas entre os valores previstos pelo modelo e os valores reais, ou seja, ele mede o quanto as previsões se diferenciam do valor real (Developers, 2024).

Ela é representada pela seguinte equação:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.7)$$

Um grande motivo para se usar o MAE para interpretar os erros cometidos pelos modelos é que ele está na mesma unidade do resultado que está tentando ser alcançado, e isso facilita a maneira de visualizar o erro, além de não ser tão sensível a valores que poderiam ser errôneos como *outliers* se comparado como o RMSE (Géron, 2019).

### 2.4.3 Raiz do Erro Quadrático Médio (RMSE)

A Raiz do Erro Quadrático Médio (RMSE), assim como os outros também é uma metrica utilizada para avaliar o desempenho de modelos. Ela representa a raiz quadrada da media dos quadrados dos erros entre os valores previstos e os valores reais, assim como o MAE ela também é representada na unidade da variável alvo facilitando assim a interpretação da mesma (Developers, 2024).

Ela é representada matematicamente pela seguinte equação:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.8)$$

Como o RMSE faz a elevação dos erros ao quadrado aplica sua média além de fazer o somatório dos valores e calcular sua raiz quadrada, todo esse processo faz com que ele seja sensível a valores que podem vir a ser errôneos ou seja *outliers*, o que influencia muito no valor final dessa métrica em comparação do MAE (Géron, 2019).

### 3 METODOLOGIA

Este capítulo descreve a metodologia utilizada para analisar e compreender quais variáveis têm maior influência sobre os valores de processo de blaine e finura durante a fabricação do cimento. Foram realizadas várias etapas, desde a coleta dos dados, aplicação de filtros relacionados ao bom funcionamento, utilização de técnicas de *Deep Learning* (DL) e *Machine Learning* (ML), resultando em modelos como Regressão Linear, SVR, MLP e *Random Forest*.

#### 3.1 Coleta de Dados Operacionais

A coleta dos dados foi realizada a partir do sistema *PI System*, um sistema de gerenciamento de dados utilizado na indústria. Os dados foram obtidos por meio do *add-in PI DataLink*, integrado ao Excel, o que permite acesso rápido ao histórico de variáveis operacionais da fábrica.

Foram coletados cinco meses de dados de algumas variáveis dos dois moinhos da planta estudada: Moinho 1 e 2. As coletas foram feitas em intervalos de um minuto. Porém, o moinho 2 teve uma parada de manutenção por alguns dias, e esses dados foram excluídos na etapa de filtragem dos dados.

#### 3.2 Apoio Técnico e Experiência Operacional

A identificação de quais variáveis mais impactariam nas previsões e a escolha de quais delas usar não foi feita de forma aleatória. Houve acompanhamento com os operadores dos moinhos e com o time de processos, que monitoraram diariamente os dois moinhos. Com a experiência técnica desses profissionais, foi possível identificar variáveis com impacto direto sobre os indicadores de blaine e finura do cimento.

Esse conhecimento técnico permitiu a definição de um *status* de boa operação inicial, com o qual foi possível criar modelos com maior assertividade nas previsões.

#### 3.3 Organização e Estruturação dos Dados

Após a obtenção dos dados, eles foram separados em planilhas específicas para cada um dos moinhos. Foram criadas três colunas com valores de 0 ou 1, representando variáveis *dummies* utilizadas para codificar cada tipo de cimento presente nos dados. Isso é necessário

para lidar com as alterações operacionais que ocorrem pelas trocas de produto, permitindo que o modelo reconheça a influência de cada tipo de cimento no processo. Além disso, foram divididos em três partes, sendo elas treinamento, teste e a base sem filtro, que foi utilizada para visualizar cada uma das variáveis de maneira separada e obter filtros melhores.

A separação dos dados em duas planilhas, uma para cada moinho permitiu a criação de modelos para cada um deles de maneira mais simples e intuitiva.

Além disso, foi utilizada uma função para suavizar ruídos de medições que podem ocorrer durante o intervalo de duas horas entre uma amostra e outra, agrupando os dados em intervalos iguais de duas horas. Para cada um desses intervalos, foi calculada a média dos valores de cada uma das variáveis numéricas. Isso permitiu que os modelos fossem criados com dados que contribuíssem para a estabilidade das previsões de blaine e finura durante essa faixa de tempo.

### **3.4 Tratamento e Limpeza dos Dados**

A remoção de valores indesejados foi um dos processos importantes na criação dos modelos, pois os *outliers* poderiam prejudicar a aprendizagem. Por isso, foram aplicados alguns filtros de boa operação, e os seguintes dados foram excluídos das bases de dados dos dois moinhos.

- Períodos de parada, em que os moinhos não estavam em operação, ou seja, alguns valores estariam zerados e outros valores não estariam condizentes com a realidade;
- Inicialização dos moinhos, pois são dados que tendem a apresentar valores que não correspondem ao processo normal de operação;
- Remoção de dados fora de uma faixa definida, relacionada à operação cotidiana dos moinhos;

### **3.5 Análise de Correlação**

Com os dados filtrados, foi realizada uma análise de correlação linear entre as variáveis independentes, utilizadas para gerar a previsão, e as variáveis dependentes, que são aquelas que se deseja prever. Para isso, foi utilizado o coeficiente de correlação de Pearson, que mede a intensidade da relação linear entre duas variáveis.

Os valores do coeficiente de Pearson variam de  $-1$  a  $+1$  (Freitas, 2025), onde:

- +1: ocorre uma correlação positiva entre as duas variáveis, ou seja, à medida que uma variável aumenta, a outra também aumenta proporcionalmente.;
- 0: ausência de correlação linear;
- -1: ocorre uma correlação negativa entre duas variáveis, ou seja, à medida que uma variável aumenta, a outra diminui proporcionalmente.

Valores entre essas faixas podem indicar relações fortes, moderadas ou fracas, sejam positivas ou negativas (Freund, 2006).

### 3.6 Aplicação de Modelos de Machine Learning e Deep Learning

Com os dados tratados e organizados por moinho, foram criados modelos com os seguintes algoritmos e parâmetros:

- Regressão Linear
- SVR (Support Vector Regression)
  - *kernel='rbf'*;
  - *C=100*;
  - *gamma=0.1*;
- MLP (Perceptron Multicamadas)
  - *hidden\_layer\_sizes=(100,)*;
  - *max\_iter=1000*;
- *Random Forest*
  - *n\_estimators=100*;

Ao todo, foram desenvolvidos 16 modelos:

- 8 modelos para o Moinho 1 (4 para Blaine e 4 para Finura);
- 8 modelos para o Moinho 2 (4 para Blaine e 4 para Finura).

### 3.7 Avaliação dos Modelos Preditivos e Validação dos Resultados

Foram utilizadas as seguintes métricas para avaliação dos modelos:

- **Mean Absolute Error (MAE)**: média dos erros absolutos entre os valores reais e previstos;
- **Root Mean Squared Error (RMSE)**: mais sensível a *outliers*, pois penaliza erros grandes;
- **Coeficiente de Determinação ( $R^2$ )**: indica o quanto o modelo explica a variação dos dados.

A aplicação dessas métricas permite comparar os modelos e identificar o de melhor desempenho para cada moinho.

Para validação, os dados foram separados entre treino e teste em ambos os moinhos. Com isso, as métricas e os gráficos gerados permitiram analisar a assertividade entre previsões e valores reais, garantindo que os resultados obtidos estejam dentro do esperado.

## 4 RESULTADOS

Nesse capítulo são apresentados os resultados obtidos a partir das análises que foram realizadas com os dados coletados e filtrados durante o processo de produção de cimento em dois moinhos verticais de rolos, é visto a influencia do processo produtivo sobre a finura e o blaine.

### 4.1 Séries temporais para todas as variáveis sem aplicação de filtro

Nesta seção, são apresentados gráficos de séries temporais de todas as variáveis operacionais incluindo as variáveis alvos, nestes dados não foram aplicados filtros. O período de cada uma das variáveis se estende do dia 01/01/2025 à 26/06/2025.

#### 4.1.1 Alimentação Total

Figura 11 – Alimentação Total Moinho 1 e 2.

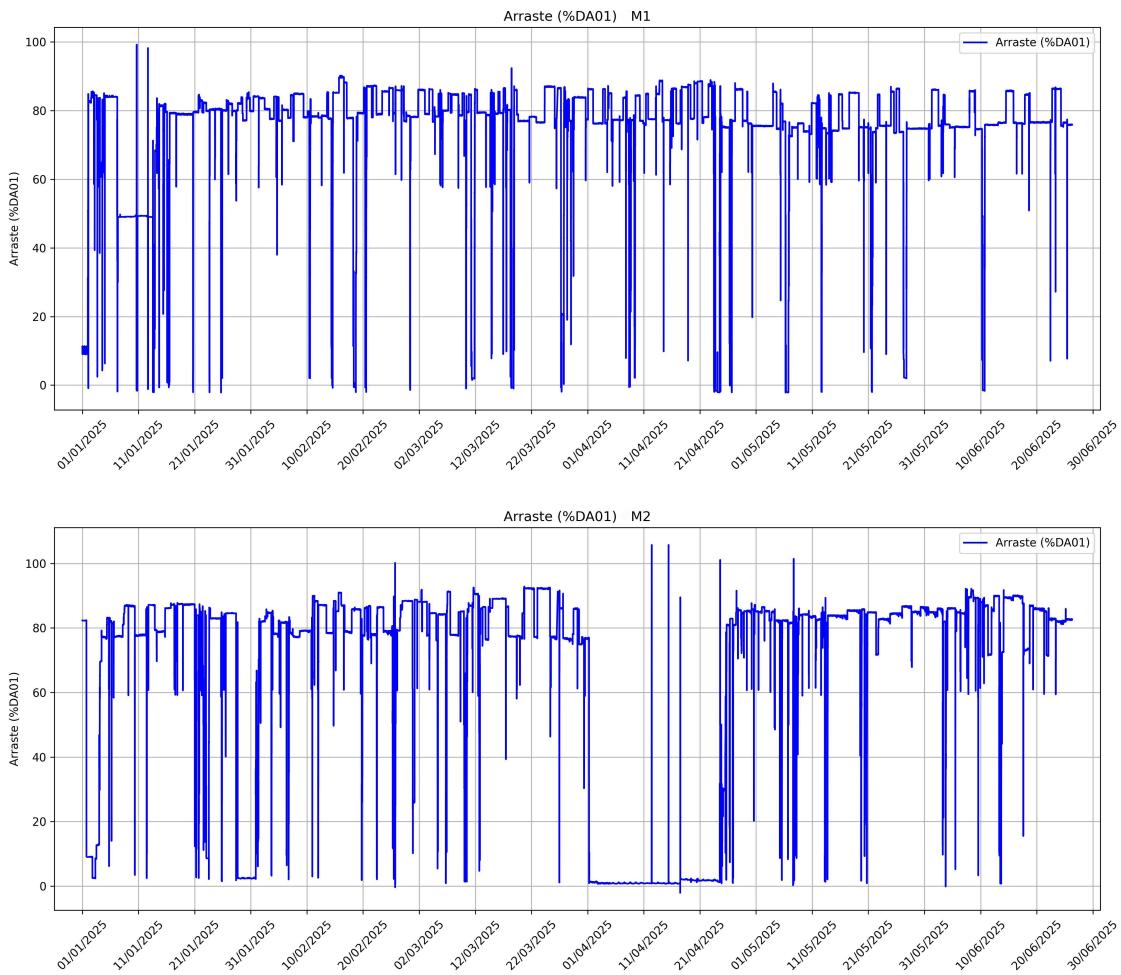


Fonte: O autor (2025).

A alimentação total do moinho está interligada a outras variáveis, como o fato de o moinho estar ligado ou não. Um exemplo disso é que valores zerados indicam que ele está parado, enquanto valores próximos de zero podem significar que o equipamento está em processo de reinicialização da produção ou em fase de parada, ou seja, esse intervalo de valores não é adequado para os modelos, pois são considerados *outliers*. Remover esse tipo de dado é uma forma de garantir que os modelos tenham melhor capacidade de prever os valores necessários durante operações normais.

#### 4.1.2 Arraste (%DA01)

Figura 12 – Arraste (%DA01) Moinho 1.

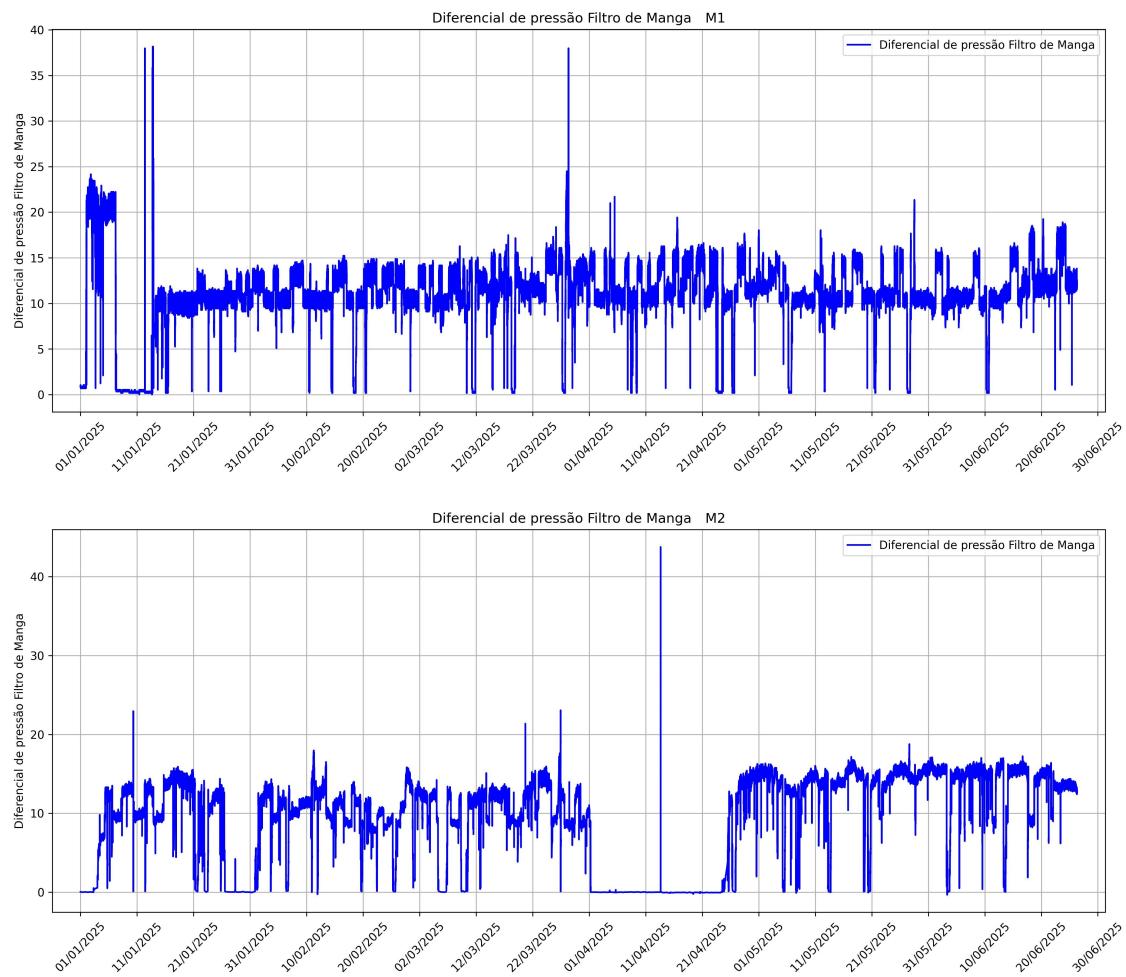


Fonte: O autor (2025).

O arraste de material acontece através da exaustão de gás quente, como é mostrado no gráfico 12 existem valores de arraste zerados ou próximos de zero significa que o moinho estava parado, a remoção desses valores é importante para garantir que os dados utilizados sejam de boa operação do moinho para ter uma melhor predição tanto do blaine como da finura.

#### **4.1.3 Diferencial de pressão do filtro de manga**

Figura 13 – Diferencial de pressão do filtro de manga.

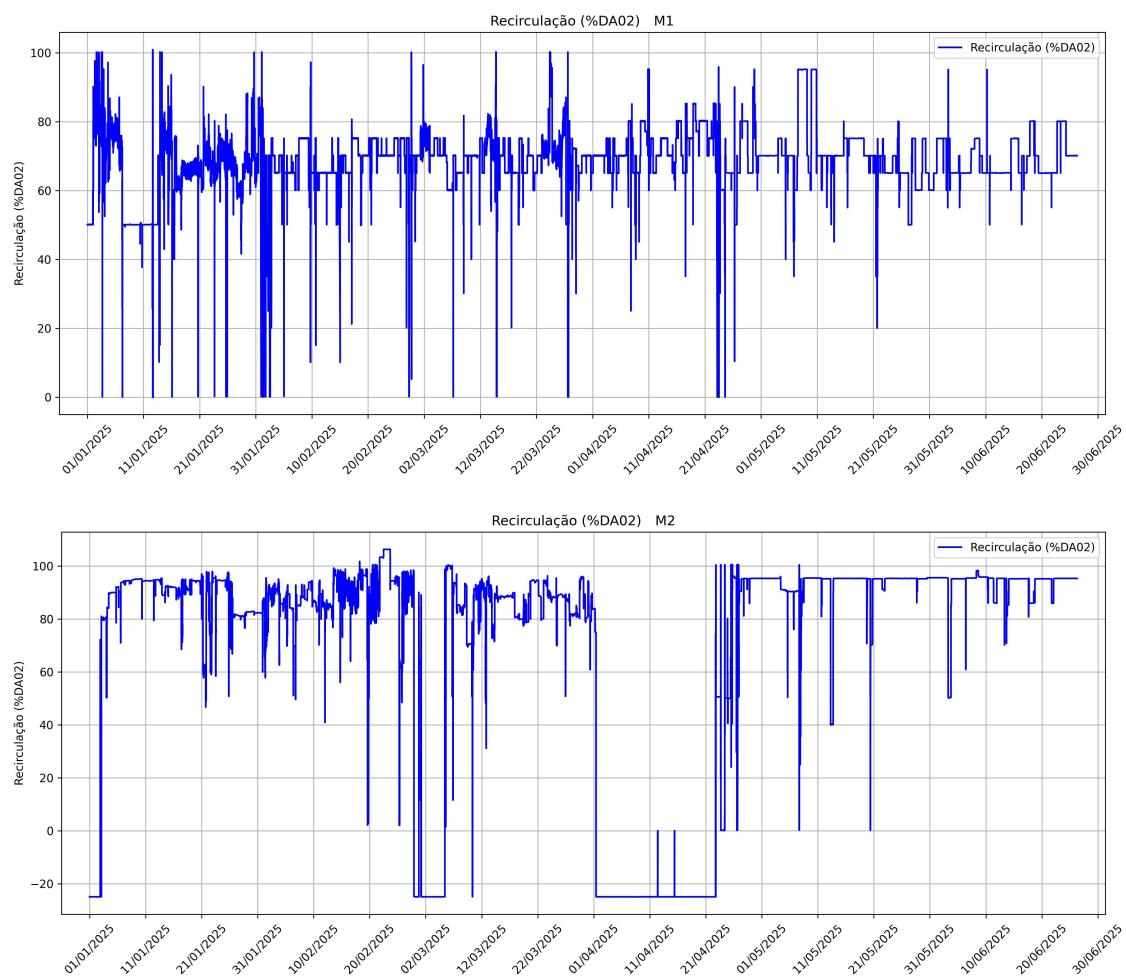


Fonte: O autor (2025).

Valores zerados no diferencial de pressão do filtro de mangas indicam que o moinho está parado. Já valores muito altos indicam que o filtro não está em boas condições para desempenhar sua função. Como pode ser observado nos gráficos, há registros com valores extremamente altos, os quais são considerados outliers. Por isso, para selecionar dados referentes a boas condições de operação, foi adotado um intervalo entre 5 e 25, com base na experiência dos operadores, com o objetivo de obter melhores resultados na criação dos modelos.

#### 4.1.4 Recirculação (%DA02)

Figura 14 – Recirculação (%DA02).

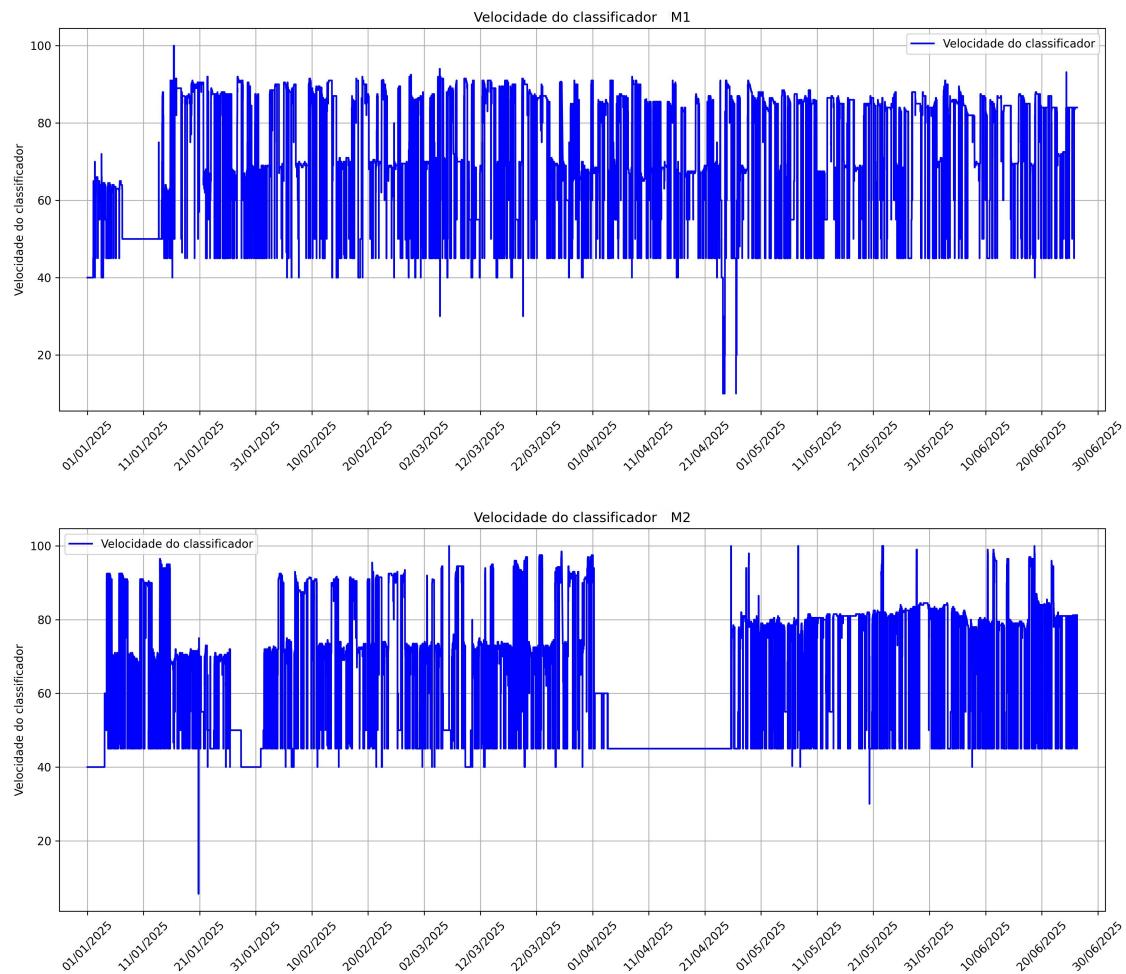


Fonte: O autor (2025).

Nos gráficos, são apresentados valores zerados e também valores negativos, o que não é fisicamente possível, ou seja, são considerados *outliers*. Além disso, há registros com valores acima de 100%, o que também não é viável fisicamente. Tendo isso em vista, para a criação dos modelos, foram considerados apenas os dados com valores acima de 40% e iguais ou inferiores a 100%, com base nos conhecimentos técnicos dos operadores, com o objetivo de garantir maior consistência e representatividade nas operações normais.

#### 4.1.5 *Velocidade do Classificador*

Figura 15 – Velocidade do Classificador.



Fonte: O autor (2025).

Velocidades muito baixas do classificador podem ser consideradas outliers, pois indicam uma condição de operação anormal. Nessas situações, partículas de cimento maiores e fora dos padrões desejados podem passar, o que compromete a qualidade do produto final. Por outro lado, também foram observados alguns valores próximos ou iguais a 100% rpm. Embora

sejam muito altos o que implica em um produto mais fino, tratam-se de dados pontuais que podem não ser consideradas fora de boa operação. E pode ajudar melhorar generalização do modelo.

Tabela 1 – Faixa de valores das variáveis de processo.

| <b>Variáveis de Processo</b>           | <b>Mínimo</b> | <b>Máximo</b> |
|--|---------------|---------------|
| Diferencial de pressão Filtro de Manga | 5             | 25            |
| Velocidade do classificador            | 60            | 100           |
| Alimentação total                      | 50            | 115           |
| Arraste (%DA01)                        | 70            | 95            |
| Recirculação (%DA02)                   | 40            | 100           |

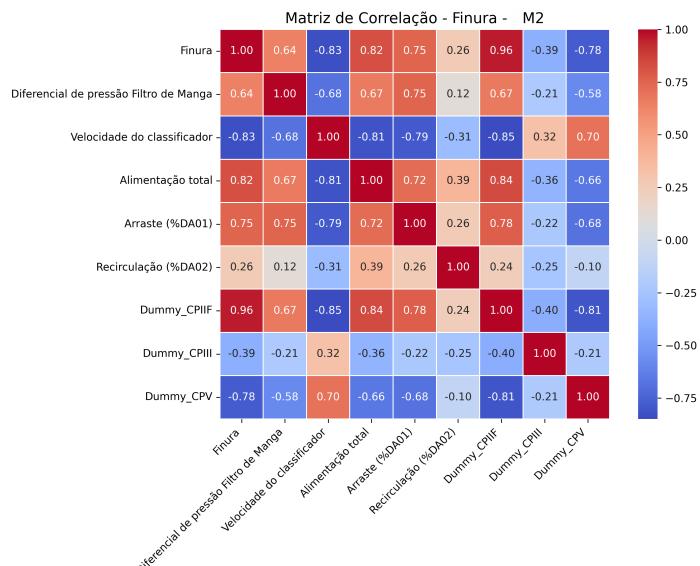
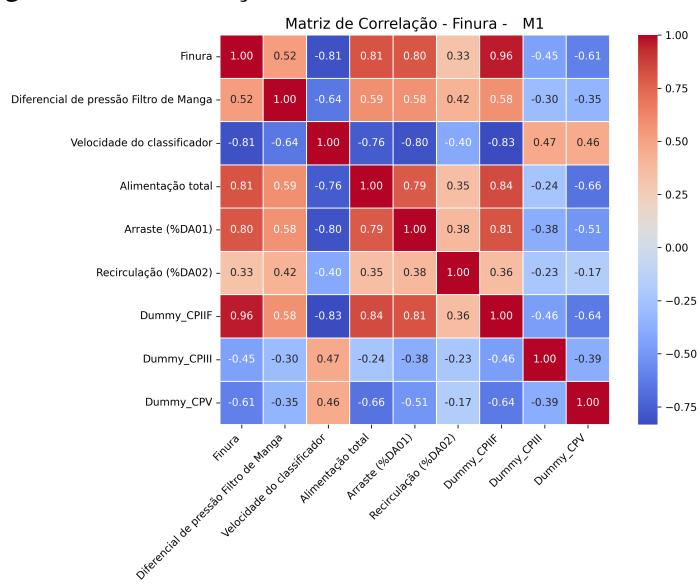
Fonte: O autor (2025).

## 4.2 Correlação de Pearson

Nesta seção é utilizada a correlação de Pearson com intuito de identificar quais variáveis têm relação direta com as variáveis que queremos prever, ajudando a confirmar se as variáveis escolhidas são realmente relevantes para a previsão, o que tornaria os modelos mais precisos e eficientes.

A escolha das variáveis foi feita através do conhecimento técnico dos operadores e do time de processos e, a partir disso, foram verificadas as correlações das variáveis.

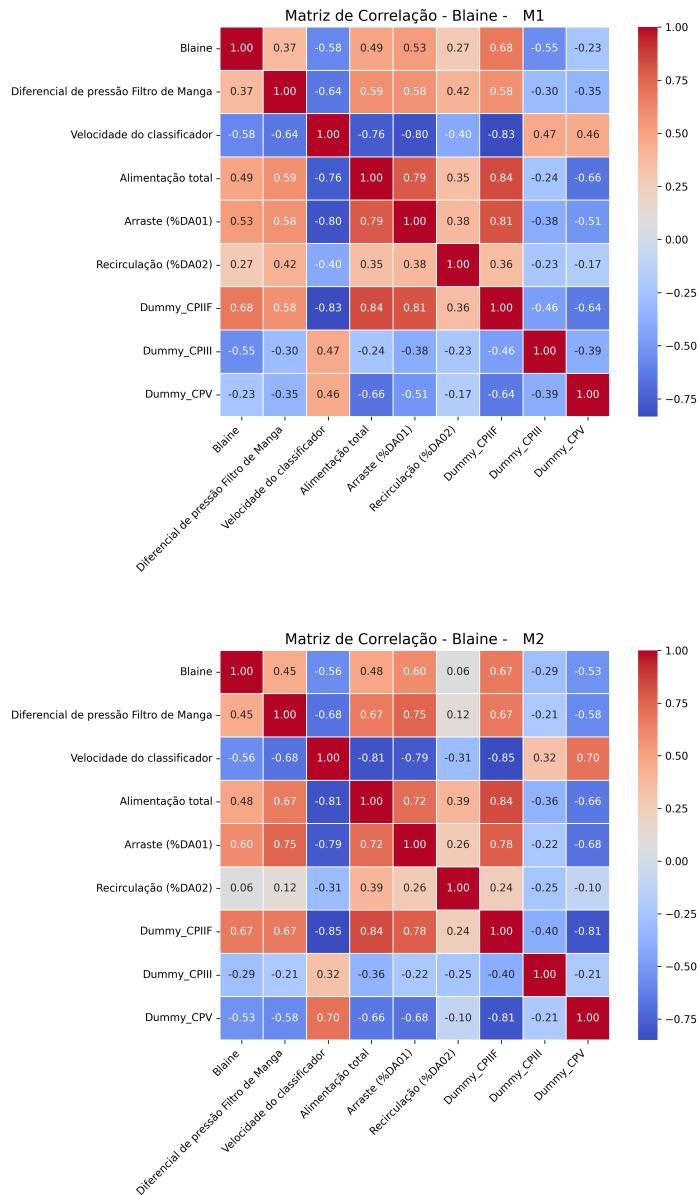
Figura 16 – Correlação de Pearson Finura.



Fonte: O autor (2025).

- **Diferencial de pressão do filtro de mangas:** No diferencial de pressão do filtro de mangas, foi observada uma correlação positiva moderada a forte com a finura do cimento, 0.61 no Moinho 1 e 0.75 no Moinho 2. Esses valores indicam que, à medida que o diferencial de pressão aumenta, a tendência é que a finura também aumente, ou seja, o cimento se torna mais fino.
- **Velocidade do classificador:** A velocidade do classificador apresentou uma correlação negativa forte com a finura do cimento, com valores de -0.93 tanto no Moinho 1 quanto no Moinho 2. Apesar da correlação negativa entre a velocidade do classificador e o blaine, isso se deve à forma como os dados estão sendo usados. Na prática, quanto maior a velocidade, mais fino é o material.
- **Alimentação Total:** A alimentação total do moinho apresentou uma correlação positiva muito forte com a finura do cimento, com valores de 0.87 no Moinho 1 e 0.86 no Moinho 2. Isso nos mostra que, à medida que a alimentação total aumenta, o valor da finura também tende a aumentar.
- **Arraste (%DA01):** O Arraste apresentou uma correlação positiva muito forte com a finura do cimento, sendo de 0.90 no Moinho 1 e 0.85 no Moinho 2. Esses valores indicam que, quanto maior o percentual de arraste, mais fino tende a ser o produto final.
- **Recirculação (%DA02):** A Recirculação apresentou uma correlação positiva fraca a moderada com a finura do cimento, sendo de 0.40 no Moinho 1 e 0.26 no Moinho 2, ou seja, mesmo que tenha uma tendência de que o aumento da recirculação faça com que a produção do cimento seja mais fina, essa influência não é tão grande.
- **Dummy\_CPIIF:** Nos dois moinhos, esse dummy apresentou uma correlação positiva bastante forte, com valores de 0.96 em ambos os moinhos. Isso indica que essa variável tem uma relação muito forte com o aumento da finura.
- **Dummy\_CPIII:** Tem uma correlação negativa moderada em ambos os moinhos, de -0.45 no Moinho 1 e -0.39 no Moinho 2. Ou seja, há uma relação em que, quando essa variável está ativa, a finura do cimento tende a diminuir.
- **Dummy\_CPV:** Apresentou uma correlação bastante negativa, de -0.61 no Moinho 1 e -0.78 no Moinho 2, o que significa que essa variável está ligada à diminuição da finura, ainda mais do que o dummy do CPIII. Isso pode ser devido à quantidade de dados do CPV em relação aos outros tipos de cimento.

Figura 17 – Correlação de Pearson Blaine.



Fonte: O autor (2025).

- **Diferencial de pressão do filtro de mangas:** A correlação entre o diferencial de pressão do filtro de mangas e a variável alvo apresentou valores de 0.42 no Moinho 1 e 0.53 no Moinho 2, indicando uma relação positiva moderada em ambos os casos, ou seja, à medida que o diferencial de pressão aumenta, a variável alvo também tende a aumentar.
- **Velocidade do classificador:** Em relação à velocidade do classificador, observamos uma correlação negativa significativa com o blaine de -0.67 no Moinho 1 e -0.61 no Moinho 2. Apesar da correlação negativa entre a velocidade do classificador e o blaine, isso se deve à forma como os dados estão sendo usados. Na prática, quanto maior a velocidade, mais fino é o material e maior o valor de blaine.
- **Alimentação Total:** Em relação à alimentação total do moinho, observamos uma correlação positiva moderada com o blaine, 0.53 no Moinho 1 e 0.52 no Moinho 2. Isso indica que, à medida que a alimentação total aumenta, o valor de blaine tende a aumentar também, ou seja, o material tende a ficar mais fino.
- **Arraste (%DA01):** O arraste apresentou uma correlação positiva moderada a forte com o blaine, 0.61 no Moinho 1 e 0.64 no Moinho 2. Isso indica que, conforme o percentual de arraste aumenta, o valor de blaine também tende a aumentar, ou seja, o material fica mais fino.
- **Recirculação (%DA02):** A recirculação apresentou uma correlação positiva fraca com o blaine, sendo de 0.35 no Moinho 1 e apenas 0.06 no Moinho 2. No Moinho 1, a correlação mesmo considerada baixa, tem uma tendência no qual o aumento da recirculação esteja ligado ao um aumento do blaine. No Moinho 2, a correlação é quase zero, a recirculação tem pouca ou nenhuma influência direta sobre o valor de blaine.
- **Dummy\_CPIIF:** Apresentou uma correlação positiva, com valores de 0.68 no Moinho 1 e 0.67 no Moinho 2. Isso indica que essa variável tem uma relação forte com o aumento do parâmetro blaine.
- **Dummy\_CPIII:** Tem uma correlação negativa moderada, de -0.55 no Moinho 1 e -0.29 no Moinho 2. Isso indica que o valor do parâmetro blaine tende a diminuir.
- **Dummy\_CPV:** Apresentou uma correlação negativa moderada, de -0.23 no Moinho 1 e -0.53 no Moinho 2. Essa variação indica que essa variável tem uma relação na qual o valor do blaine tende a diminuir quando ela está ativa.

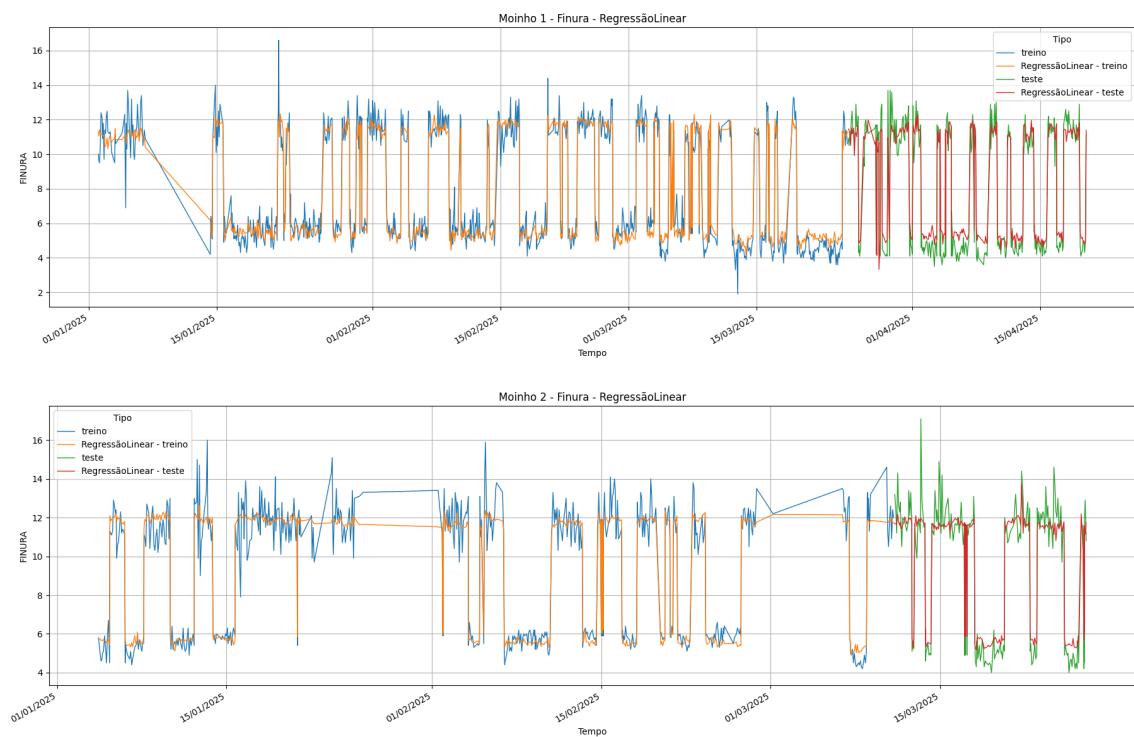
## 4.3 Resultados Moinhos 1 e 2

### 4.3.1 Finura

Nesta seção, avaliamos quatro modelos para a previsão da finura: Regressão Linear, SVR, MLP e *Random Forest*. Cada um desses algoritmos possui características próprias em termos de complexidade e capacidade de generalização. As análises são realizadas por meio de métricas e visualizadas por meio de gráficos comparativos entre os valores reais e os previstos.

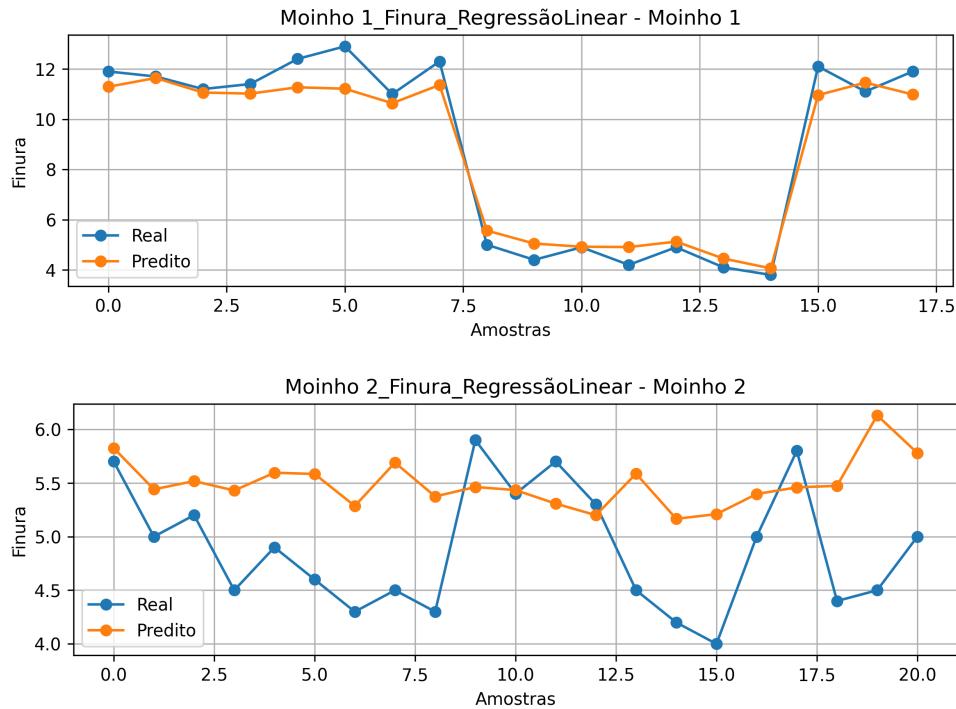
#### 4.3.1.1 Regressão Linear

Figura 18 – Finura - Regressão Linear.



Fonte: O autor (2025).

Figura 19 – Finura - Regressão Linear - Comparativo.



Fonte: O autor (2025).

Na Figura 18, é possível ver os resultados que foram obtidos através de um modelo de Regressão Linear para predizer a variável de finura nos Moinho 1 e Moinho 2. Cada um dos gráficos contêm a série temporal dos valores reais da variável, junto com os valores preditos pelo modelo, sendo eles divididos entre seu treinamento e teste.

É observado na Figura 18 que no Moinho 1, na parte do treinamento as previsões são acompanhadas de forma moderada, porém, no Moinho 2 este acompanhamento não teve tanto sucesso assim. Já na parte de testes podemos ver na Tabela 2 que o modelo conseguiu explicar bem as variações dos dados em ambos os moinhos, mas ainda na própria tabela, podemos ver que o erro no Moinho 2 foi mais alto se comparado com o Moinho 1 isso pode ter ocorrido por conta do treinamento no qual a regressão linear não se deu tão bem com os dados do Moinho 2, mesmo assim foi possível notar que ele tende a acompanhar os pontos de picos e mínimos em alguns pontos, especialmente no Moinho 1.

Para interpretar esses dados, temos que, no Moinho 1 os valores indicam que o modelo foi capaz de explicar aproximadamente 94.2% da variabilidade da finura, com um erro relativamente baixo. Já no Moinho 2, os dados foram um pouco inferiores principalmente se levarmos em conta seu treinamento, mas nos testes seu modelo explicou 92.18% da variação.

Mesmo a Regressão Linear sendo um modelo mais simples, ele conseguiu captar

bem a variabilidade dos dados, mas levando mais afundo usando as outras métricas vemos que isso pode ser confirmado levando em conta que os erros foram baixos de maneira geral.

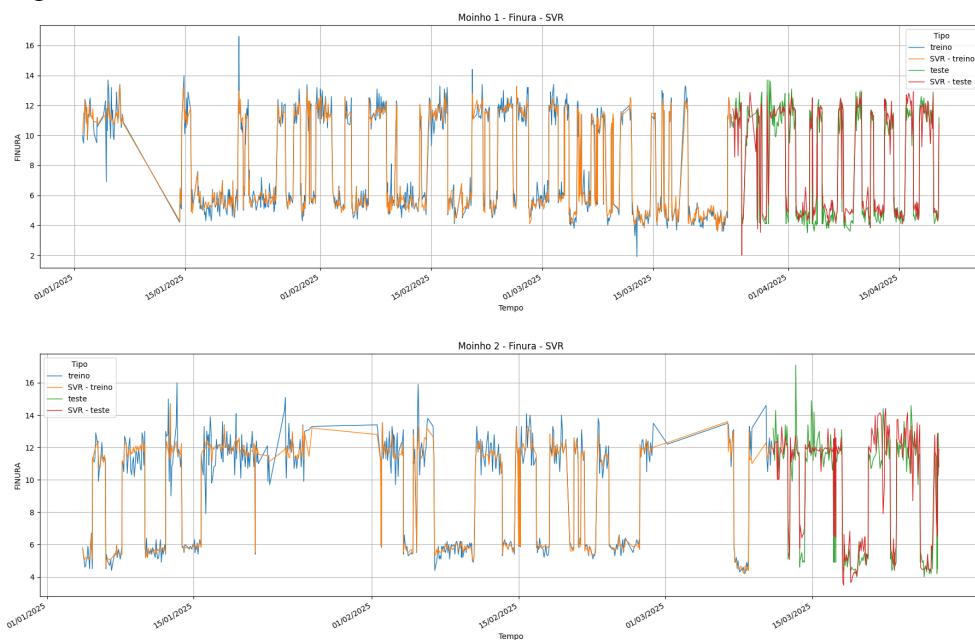
**Tabela 2 – Métricas do modelo de Regressão Linear para os moinhos 1 e 2.**

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 0,6813     | 0,8423      | 0,9421               |
| Moinho 2      | 0,7239     | 0,9727      | 0,9218               |

Fonte: O autor (2025).

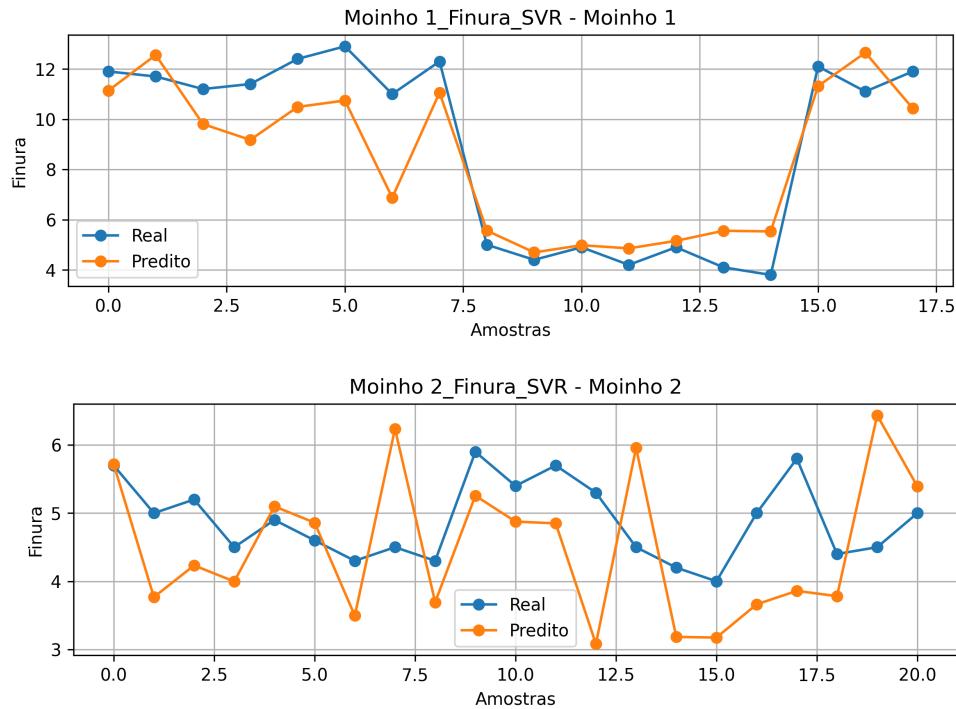
#### 4.3.1.2 SVR

**Figura 20 – Finura - SVR.**



Fonte: O autor (2025).

Figura 21 – Finura - SVR - Comparativo.



Fonte: O autor (2025).

Na Figura 20, podemos ver os resultados obtidos na criação e teste do modelo SVR para a previsão da finura nos moinhos 1 e 2. Diferente da Regressão Linear, o SVR conseguiu acompanhar boa parte do comportamento durante o treinamento, porém, seus resultados nos testes foram ligeiramente inferiores. Ainda assim, o modelo conseguiu seguir os valores reais da série temporal de forma satisfatória.

Mesmo acompanhando os picos e vales, a Tabela 3 mostra que, nos testes, os valores dos erros obtidos foram maiores do que nos modelos mais simples de regressão. O SVR explicou 91.8% da variabilidade da finura no moinho 1 e 83.22% no moinho 2, o que, apesar de um desempenho um pouco inferior, ainda pode ser considerado bastante satisfatório.

Essa diferença de desempenho entre um modelo linear mais simples e um modelo mais robusto, como o SVR pode ser explicada pelo tipo de *kernel* utilizado, no caso RBF, ou pela linearidade dos dados utilizados na criação dos modelos. Esse resultado também abre uma discussão sobre a escolha adequada dos hiperparâmetros, a fim de evitar *overfitting* ou um mau ajuste aos dados.

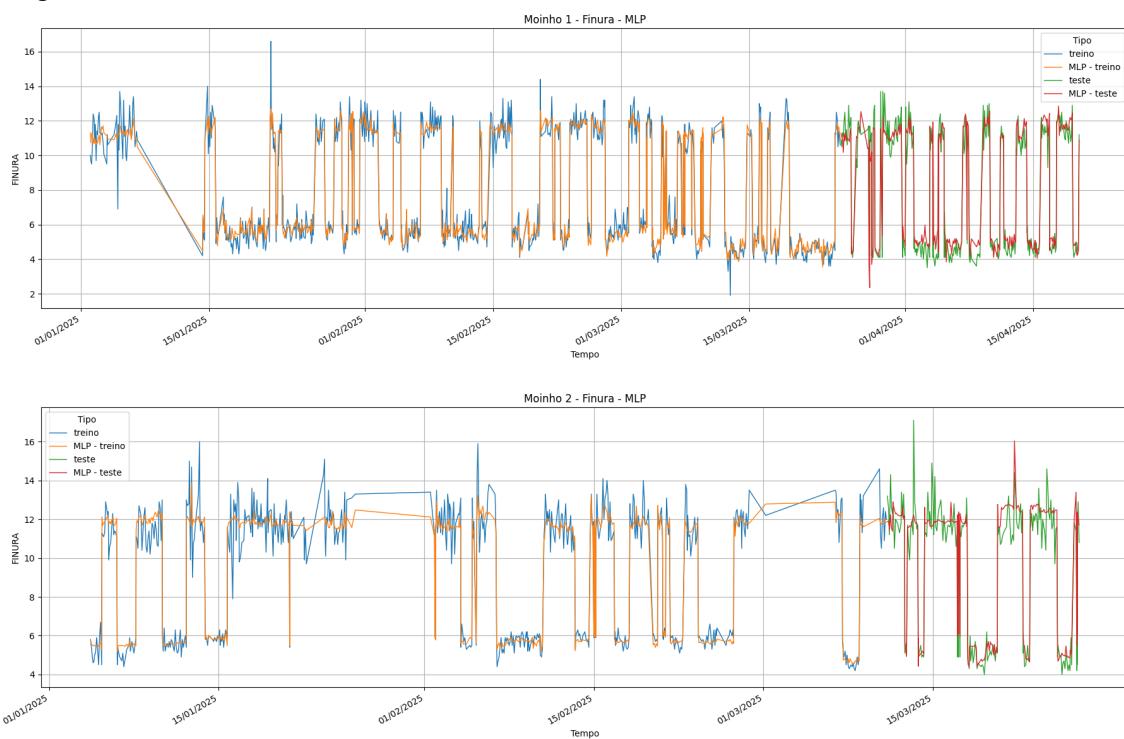
**Tabela 3 – Métricas do modelo  
SVR para os moinhos 1  
e 2.**

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 0,7447     | 1,0034      | 0,9178               |
| Moinho 2      | 1,0516     | 1,4245      | 0,8322               |

Fonte: O autor (2025).

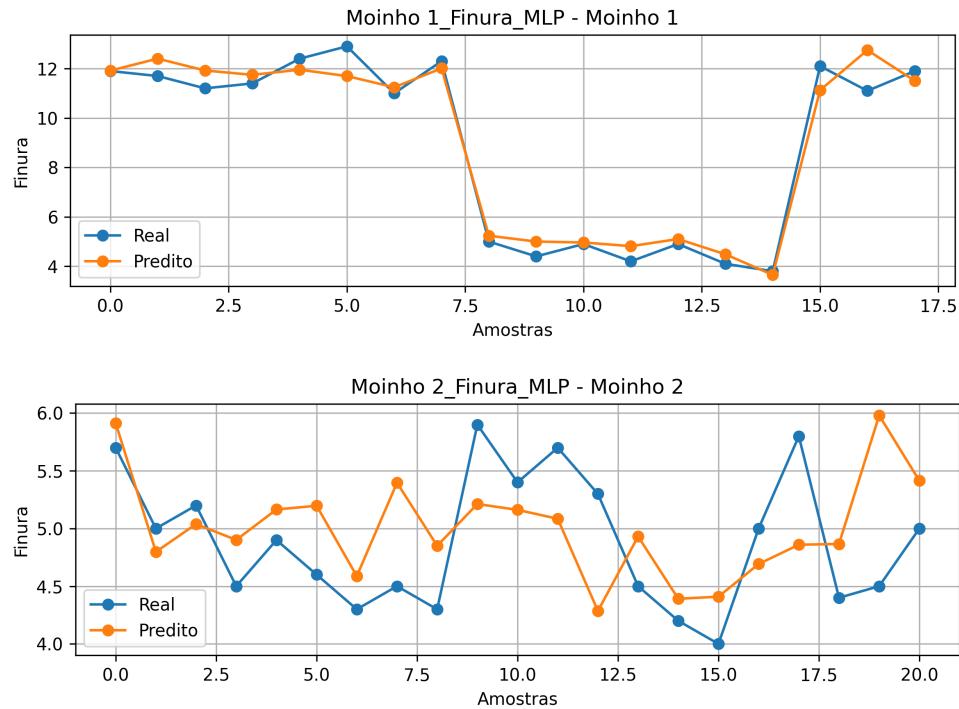
#### 4.3.1.3 MLP

**Figura 22 – Finura - MLP.**



Fonte: O autor (2025).

Figura 23 – Finura - MLP - Comparativo.



Fonte: O autor (2025).

Na Figura 22, temos o gráfico do treinamento e teste do modelo MLP para predição da finura nos moinhos 1 e 2. No moinho 1, podemos observar que o modelo MLP teve uma ótima capacidade de acompanhar os valores reais tanto no treinamento quanto no teste. A predição foi capaz de seguir os picos e vales, mesmo diante de uma alta variação nos dados de finura. Já no moinho 2, o desempenho foi inferior em relação ao acompanhamento dos valores do outro moinho, mas ainda assim conseguiu manter uma boa assertividade.

O modelo de rede neural foi capaz de seguir com precisão as tendências dos valores ao longo do tempo, sendo superior ao SVR e à Regressão Linear em diversos pontos. Com o entendimento sobre a variabilidade dos dados de 94.66% no moinho 1 e 91.96% no moinho 2, o modelo demonstrou um desempenho bastante satisfatório. Esses resultados mostram que modelos de rede neural, como o MLP são capazes de lidar com dados industriais em tempo real, além de se mostrarem eficazes em contextos complexos, como os processos de moagem, destacando-se entre os demais modelos testados.

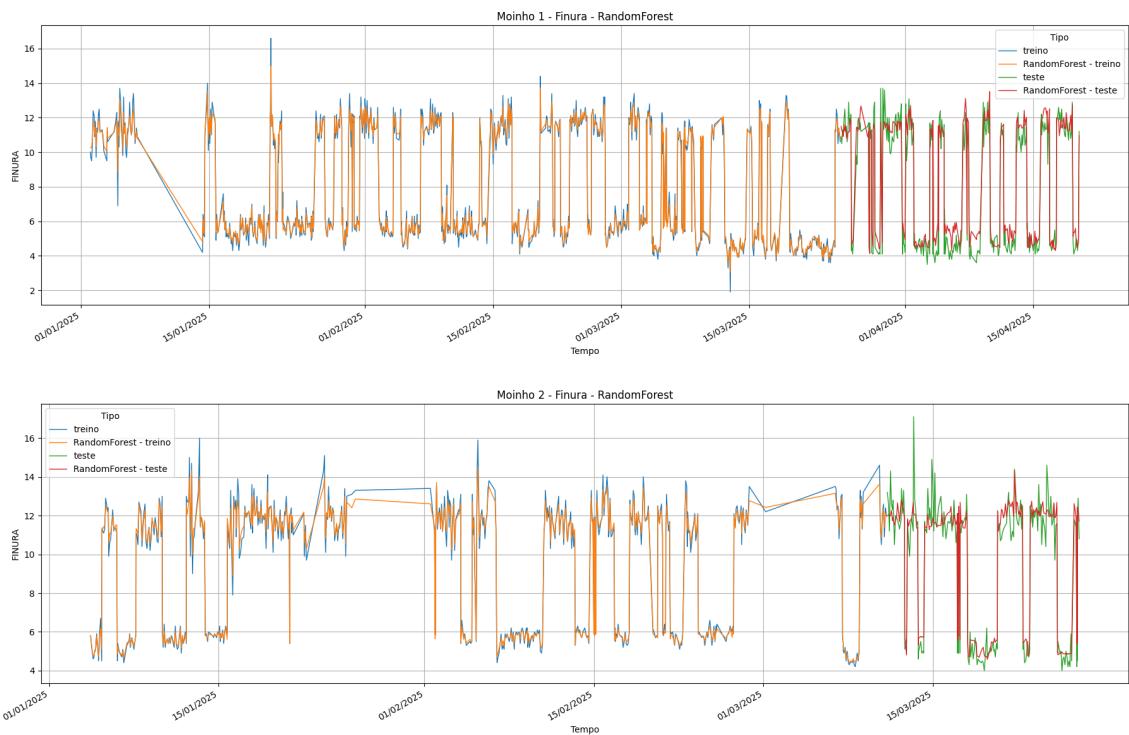
**Tabela 4 – Métricas do modelo  
MLP para os moinhos 1  
e 2.**

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 0,6473     | 0,8089      | 0,9466               |
| Moinho 2      | 0,7553     | 0,9858      | 0,9196               |

Fonte: O autor (2025).

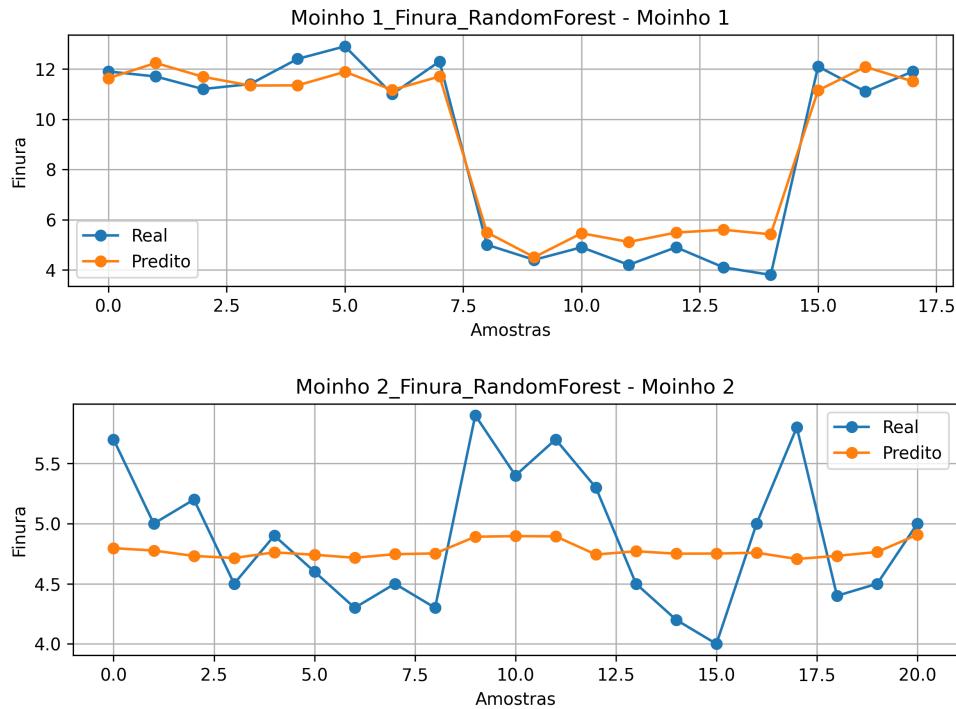
#### 4.3.1.4 Random Forest

**Figura 24 – Finura - Random Forest.**



Fonte: O autor (2025).

Figura 25 – Finura - RandomForestFinura - Comparativo.



Fonte: O autor (2025).

Na Figura 24, é visto os resultados referentes ao treinamento e teste do modelo *Random Forest* para a predição da finura nos moinhos 1 e 2. Diferentemente dos outros modelos, nos quais havia uma adaptação mais eficaz para apenas um dos moinhos, neste caso, foi possível observar que, para ambos os moinhos, os erros foram baixos e houve um bom desempenho no acompanhamento dos valores reais, tanto no treinamento, quanto no teste.

No moinho 1, o modelo apresentou um desempenho consistente. Mesmo que não tenha superado o MLP, ele demonstrou uma boa estabilidade e foi capaz de realizar previsões satisfatórias, mesmo em momentos de instabilidade. O modelo conseguiu explicar 94.08% da variabilidade dos dados. Apesar de não ter sido o melhor modelo para o moinho 1, os resultados obtidos foram bastante positivos.

No moinho 2, o desempenho foi ainda melhor, superando inclusive os outros modelos testados. Ao analisar o gráfico, é possível observar uma excelente aderência à curva real da finura, mesmo que ainda tenha pequenas diferenças entre os valores preditos e os reais em alguns trechos. Ainda assim, o modelo mostrou robustez e capacidade de generalização.

De forma geral, o modelo Random Forest demonstrou boa estabilidade e desempenho em ambos os moinhos, mesmo diante da variabilidade dos dados. É uma boa escolha, pois conseguiu capturar variações que outros modelos não conseguiram, mostrou ser uma ótima

opção para a predição de dados industriais, especialmente em processos complexos, como o de moagem.

Tabela 5 – Métricas do modelo  
Random Forest para os  
moinhos 1 e 2.

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 0,6876     | 0,8515      | 0,9408               |
| Moinho 2      | 0,6624     | 0,9016      | 0,9328               |

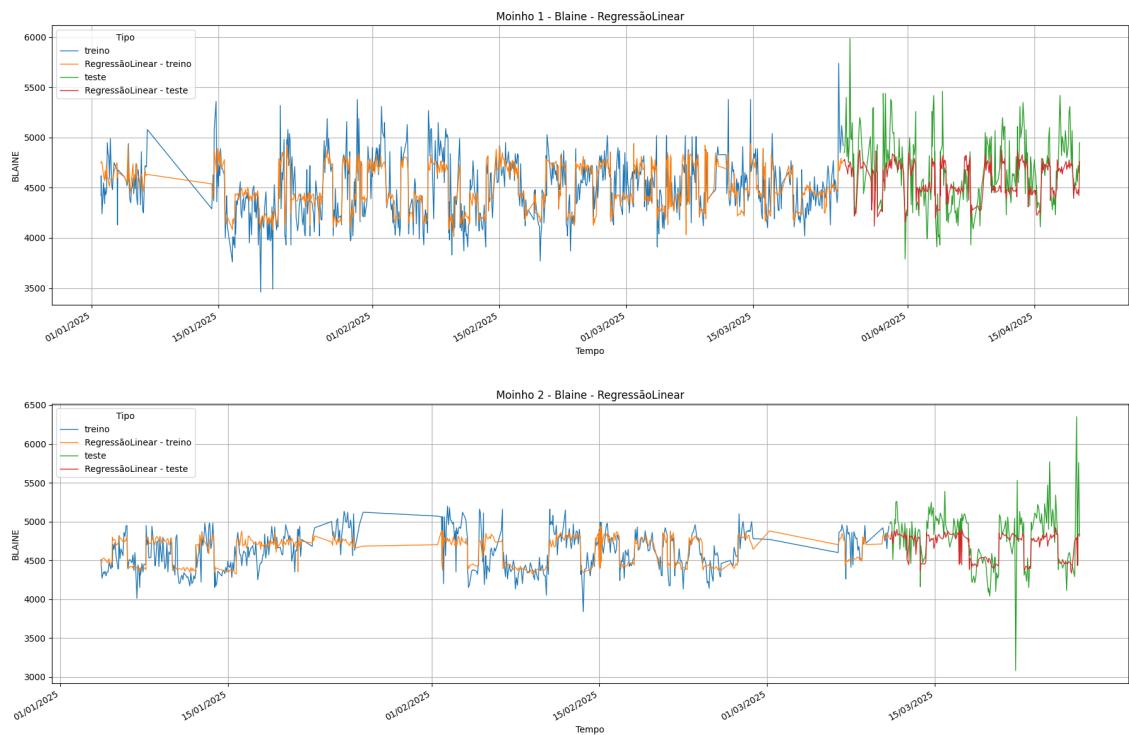
Fonte: O autor (2025).

### 4.3.2 Blaine

Nesta seção, avaliamos quatro modelos para a previsão do blaine: Regressão Linear, SVR, MLP e *Random Forest*. Cada um desses algoritmos possui características próprias em termos de complexidade e capacidade de generalização. As análises são realizadas por meio de métricas e visualizadas por meio de gráficos comparativos entre os valores reais e os previstos.

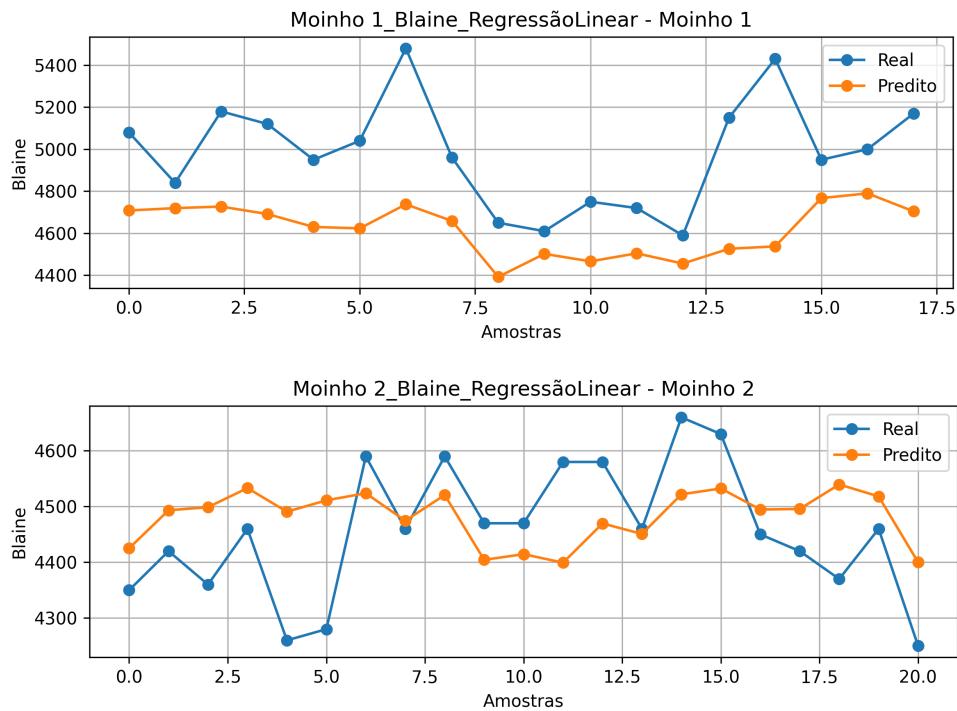
#### 4.3.2.1 Regressão Linear

Figura 26 – Blaine - Regressão Linear.



Fonte: O autor (2025).

Figura 27 – Blaine - Regressão Linear - Comparativo.



Fonte: O autor (2025).

Na Figura 26, podemos observar os resultados do modelo de Regressão Linear, que apresenta os valores reais e preditos nos conjuntos de treinamento e teste para os moinhos 1 e 2.

No Moinho 1, pode-se notar que as previsões conseguem acompanhar a tendência geral dos valores reais, porém, existem muitas oscilações, o que faz com que o número de erros tenda a aumentar. Esses erros podem até ser considerados relativamente altos, dependendo do contexto. O modelo não consegue realizar uma previsão tão satisfatória quanto nas previsões de finura, pois os valores da variável blaine são mais altos e apresentam oscilações maiores. Ainda assim, o modelo conseguiu explicar 40.87% da variabilidade dos dados no Moinho 1.

No Moinho 2, acontece uma situação semelhante. O modelo de Regressão Linear tem ainda mais dificuldade para acompanhar os momentos de pico e quedas abruptas. O erro no Moinho 2 é um pouco maior, de acordo com a métrica RMSE, o que se confirma ao observar que o modelo conseguiu explicar apenas 35.57% da variabilidade dos dados.

De modo geral, o modelo de Regressão Linear pode não ter se mostrado suficiente para representar adequadamente os valores da variável blaine, mas considerando o grau de complexidade da variável isso deve ser levado em consideração. Essa complexidade pode exigir modelos mais robustos e capazes de lidar com relações não lineares.

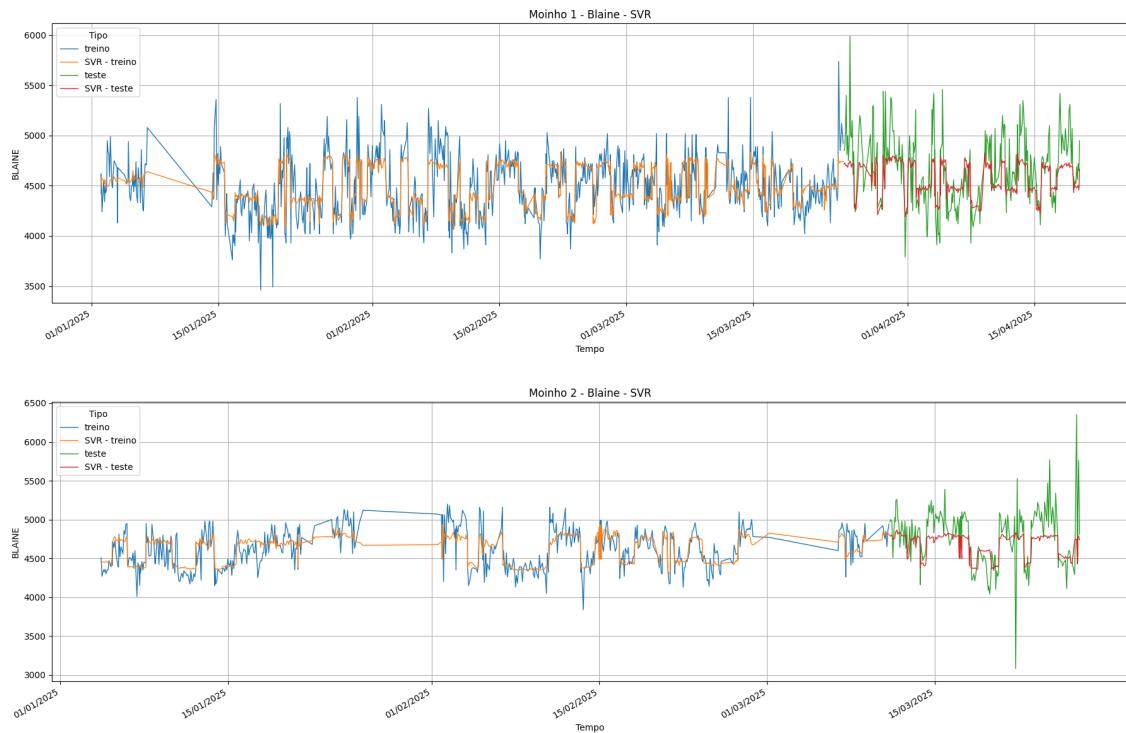
Tabela 6 – Métricas do modelo de Regressão Linear para os moinhos 1 e 2.

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 196,7718   | 260,6165    | 0,4087               |
| Moinho 2      | 192,8461   | 287,2312    | 0,3557               |

Fonte: O autor (2025).

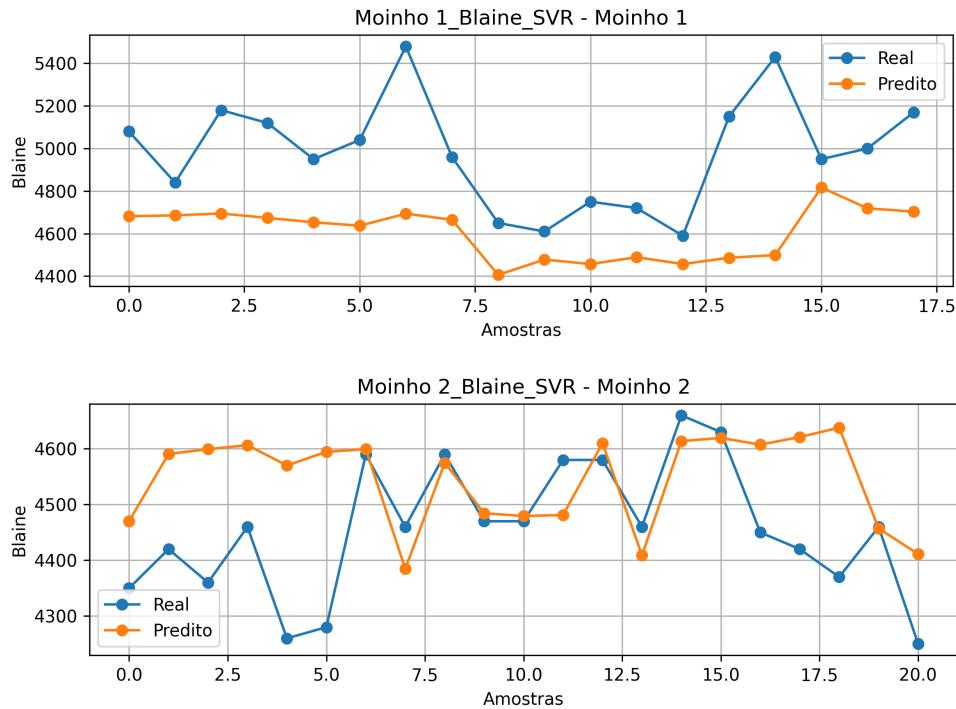
#### 4.3.2.2 SVR

Figura 28 – Blaine - SVR.



Fonte: O autor (2025).

Figura 29 – Blaine - SVR - Comparativo.



Fonte: O autor (2025).

Na Figura 28, são vistos os resultados do modelo SVR correspondente ao treinamento e ao teste da variável de blaine dos moinhos 1 e 2. No moinho moinho 1, podemos ver que o modelo conseguiu capturar de forma razoável a tendência dos dados reais, principalmente quando ocorrem baixas não tão acentuadas, porém, tem dificuldades para predizer picos de variação. Isso pode ter ocorrido devido a ruídos ou ao fato de o modelo não ter conseguido se adequar aos dados operacionais de blaine.

No moinho 2, o comportamento se assemelha, porém, os erros são maiores, o que já nos diz que o modelo é inferior nesse moinho. Essas observações dos gráficos são confirmadas na Tabela 7, que apresenta as métricas desse modelo para os dois moinhos. O moinho 2 consegue explicar a variação dos dados de 40.57%, enquanto o moinho 1 consegue explicar somente 28.55%.

O modelo de SVR teve um melhor desempenho preditivo no moinho 1, com erros menores e uma maior capacidade para explicar a variação, enquanto o moinho 2 teve um desempenho inferior, tanto para os erros como MAE e RMSE.

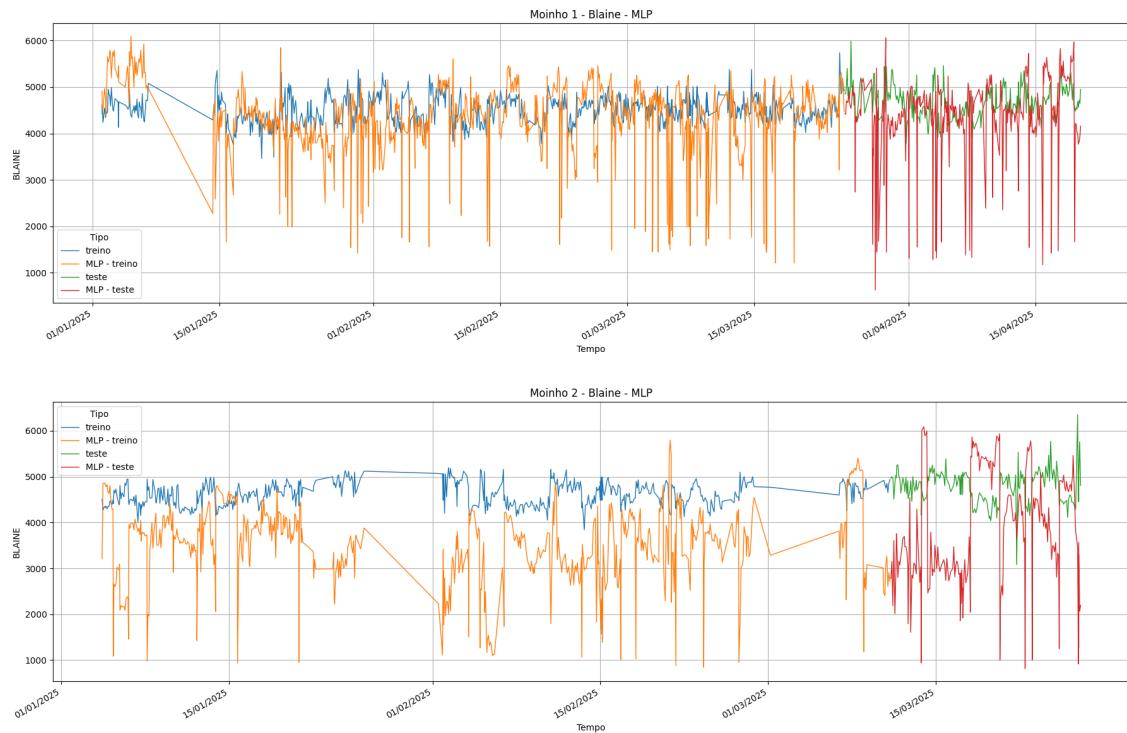
**Tabela 7 – Métricas do modelo  
SVR para os moinhos 1  
e 2.**

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 196,6767   | 261,2796    | 0,4057               |
| Moinho 2      | 209,7279   | 302,4862    | 0,2855               |

Fonte: O autor (2025).

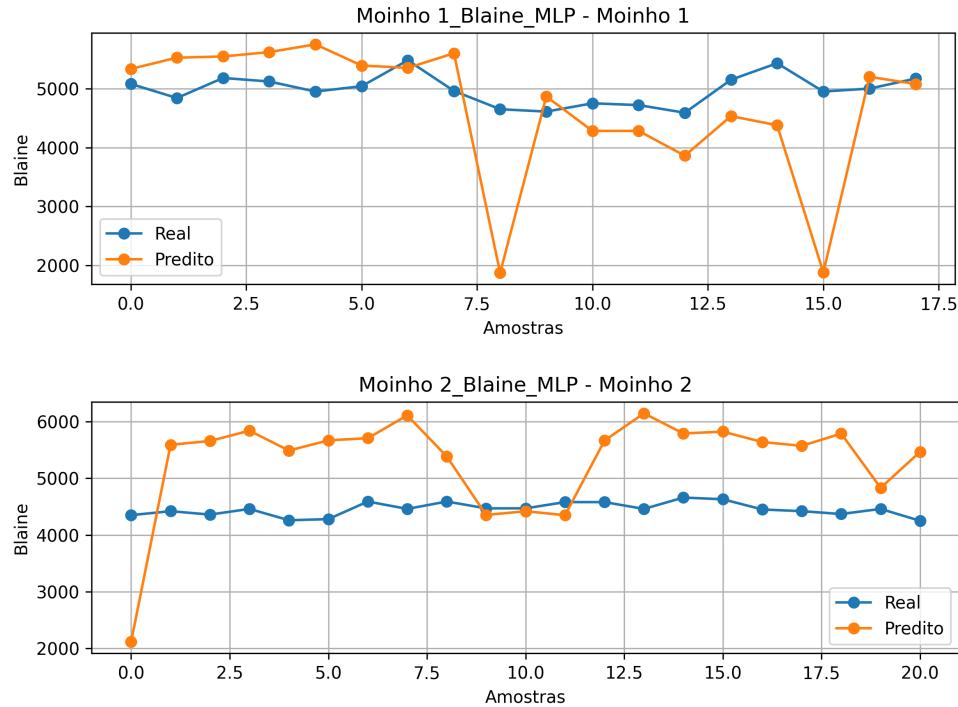
#### 4.3.2.3 MLP

**Figura 30 – Blaine - MLP.**



Fonte: O autor (2025).

Figura 31 – Blaine - MLP - Comparativo.



Fonte: O autor (2025).

Na Figura 30, são observados os resultados do modelo de MLP para treinamento e teste da variável de blaine nos moinhos Moinho 1 e Moinho 2. Observa-se no gráfico que o modelo apresentou grande instabilidade nas previsões.

No moinho Moinho 1, dá para notar visivelmente as previsões muito dispersas se comparadas aos valores reais, não seguindo a tendência dos dados. Há dificuldade para capturar padrões nas regiões da série temporal. No Moinho 2, esse comportamento é ainda maior, com previsões bastante diferentes da realidade, o que demonstra que o modelo foi incapaz de aprender o comportamento da variável.

Os resultados em ambos os moinhos foram bastante inferiores. Com base na Tabela 8, podemos confirmar todas as informações obtidas de maneira visual, e concluir que esse modelo não conseguiu aprender os comportamentos necessários. Isso pode ter ocorrido devido a ruídos, hiperparâmetros mal ajustados ou à complexidade dos dados.

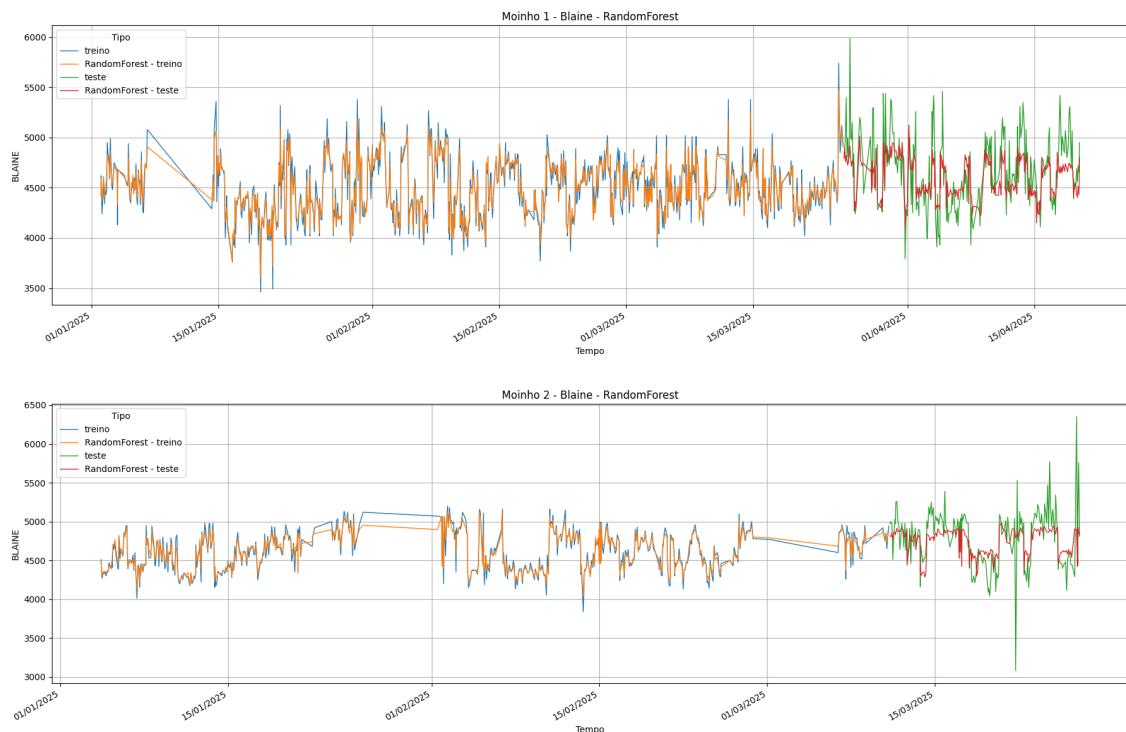
**Tabela 8 – Métricas do modelo  
MLP para os moinhos 1  
e 2.**

| <b>Moinho</b> | <b>MAE</b> | <b>RMSE</b> | <b>R<sup>2</sup></b> |
|---------------|------------|-------------|----------------------|
| Moinho 1      | 656,5183   | 1020,4042   | -8,0644              |
| Moinho 2      | 1519,0821  | 1737,7004   | -22,5804             |

Fonte: O autor (2025).

#### 4.3.2.4 Random Forest

**Figura 32 – Blaine - Random Forest.**

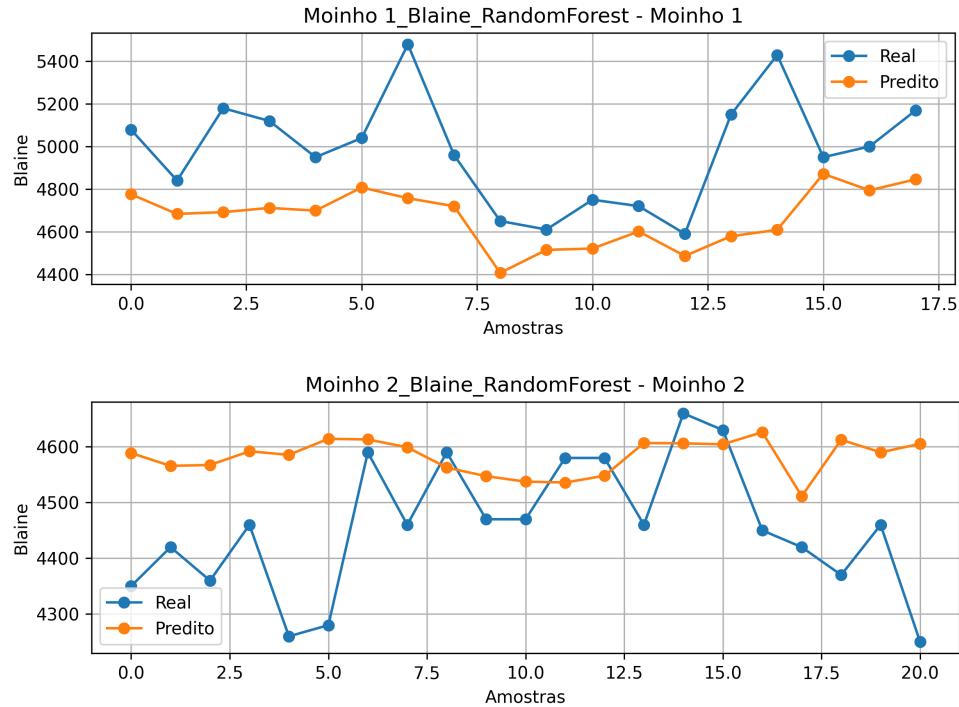


Fonte: O autor (2025).

Na Figura 32, são vistos os resultados do treinamento e teste do modelo *Random Forest* para a predição da variável blaine nos moinhos 1 e 2. É possível notar, no gráfico, que o modelo apresentou um bom alinhamento com os dados reais, ainda mais se comparado aos outros modelos, em que a predição segue a tendência dos valores de maneira mais precisa.

No moinho 1, é possível perceber que o modelo conseguiu fazer previsões que representassem de maneira razoavelmente satisfatória o blaine, mesmo em momentos com muita oscilação. No moinho 2, o comportamento é bastante semelhante, porém, com um aumento na dispersão dos dados.

Figura 33 – Blaine - Regressão Linear - Comparativo.



Fonte: O autor (2025).

Com isso, pode-se dizer que o modelo *Random Forest* apresentou um desempenho consistente nos dois moinhos, sendo o melhor modelo quando se comparam os erros e a capacidade explicativa por meio da Tabela 9, já que, no moinho 1, o modelo consegue explicar 49.12% da variação dos dados, e, no moinho 2, consegue explicar 38.78%. Isso torna o *Random Forest* um modelo promissor em aplicações industriais que envolvem dados operacionais complexos, como é o caso do blaine.

Tabela 9 – Métricas do modelo  
Random Forest para os  
moinhos 1 e 2.

| Moinho   | MAE      | RMSE     | R <sup>2</sup> |
|----------|----------|----------|----------------|
| Moinho 1 | 184,4492 | 241,7463 | 0,4912         |
| Moinho 2 | 190,8552 | 279,9982 | 0,3878         |

Fonte: O autor (2025).

## 5 CONCLUSÕES E TRABALHOS FUTUROS

O estudo da aplicação de modelos para inteligência artificial, utilizando técnicas de ajuste de hiperparâmetros em algoritmos como Regressão Linear, SVR, MLP e *Random Forest*, para a previsão de finura e blaine, a partir de variáveis de processo em tempo real, demonstrou ser viável como um apoio adicional ao controle de qualidade na operação.

Utilizando períodos distintos para treino e teste nos dois moinhos, observou-se que o modelo de *Random Forest* apresentou a melhor acurácia para previsão de blaine em ambos os moinhos, bem como para a finura no moinho 2. No entanto, para a finura do moinho 1, o modelo MLP é mais eficaz, superando os demais em acurácia, conseguindo uma boa generalização e compreensão dos dados. Esse desempenho foi possível graças ao tratamento prévio dos dados, que incluiu a identificação e remoção de outliers.

Contudo, é importante destacar que, com a aplicação do filtro de duas horas e o uso de variáveis *dummies* para representar trocas de produtos, os modelos tornam-se mais robustos às variações operacionais. Essa abordagem aumenta a acurácia dos modelos significativamente.

Ainda assim, nota-se certa dificuldade de predição, atribuída à imprevisibilidade causada por ruídos próprios dos moinhos, ao estado de conservação dos equipamentos e, possivelmente, à escolha das variáveis no processo de criação do modelo. Para trabalhos futuros, recomenda-se avaliar alternativas de variáveis com o intuito de garantir maior acurácia, assim como revisar o processo de moagem no intervalo de tempo utilizado para o treinamento, a fim de reduzir a influência de outliers nos resultados finais.

## REFERÊNCIAS

- Associação Brasileira de Normas Técnicas. **NBR 16372:2014 – Cimento Portland – Terminologia.** Rio de Janeiro: ABNT, 2014. Norma técnica.
- Associação Brasileira de Normas Técnicas. **NBR 16697:2018 – Cimento Portland – Requisitos.** Rio de Janeiro: ABNT, 2018. Norma técnica.
- Breiman, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.
- Ceccon, D. **Funções de ativação: definição, características, e quando usar cada uma.** 2020. IA Expert Academy. Disponível em: <<https://iaexpert.academy/2020/05/25/funcoes-de-ativacao-definicao-caracteristicas-e-quando-usar-cada-uma/>>.
- Cruz, A. **Secagem, moagem e classificação de material (alta umidade) em um único Moinho Vertical de Rolos.** 2017. Disponível em: <<https://www.aspacec.com.br/wp-content/uploads/2017/06/GEBR.-PFEIFFER-MOA-SEC-CLASS.-EM-%C3%A9ANICO-VRM-ANDR%C3%89-CRUZ.pdf>>. Acesso em: 01 jul. 2025.
- Deng, N.; TIAN, Y.; ZHANG, C. **Support Vector Machines: Optimization Based Theory, Algorithms, and Extensions.** Boca Raton: Chapman & Hall/CRC, 2012.
- Developers, S. learn. **Scikit-learn: Model Evaluation.** 2024. <[https://scikit-learn.org/stable/modules/model\\_evaluation.html](https://scikit-learn.org/stable/modules/model_evaluation.html)>. Accessed: 2025-07-09.
- FLSmidth. **Grinding technology – Best practices for operation and maintenance.** Copenhagen, 2024. <[flsmidth-cement.com/cement-hub/posts/webinar-grinding-technology-best-practices-for-operation-and-maintenance](https://flsmidth-cement.com/cement-hub/posts/webinar-grinding-technology-best-practices-for-operation-and-maintenance)>.
- FLSmidth. **OK™ Cement Mill – The most energy-efficient mill for cement grinding.** Copenhagen, 2024. <<https://www.flsmidth-cement.com/files/7b7aff249cc8348e9458a0869e0b9ca68475edfb.pdf>>/OK-Cement-Mill.pdf>.
- Freitas, E. B. B. d. Trabalho de Conclusão de Curso (Graduação em Engenharia Civil), **Análise do processo de moagem em moinho vertical para previsão da finura do cimento Portland.** Russas: Universidade Federal do Ceará, Campus de Russas, 2025. Orientadora: Rosineide Fernando da Paz. Disponível em: <<http://repositorio.ufc.br/handle/riufc/80047>>.
- Freund, J. E. **Estatística Aplicada: Economia, Administração e Contabilidade.** 11. ed. Porto Alegre: Bookman, 2006. Tradução de Claus Ivo Doering.
- Gobbo, L. de A. **Os compostos do clínquer Portland: sua caracterização por difração de raios-X e quantificação por refinamento de Rietveld.** 2003. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/44/44133/tde-09102003-112552>>. Acesso em: 01 jul. 2025.
- Goodfellow, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning.** Cambridge: MIT Press, 2016.
- Géron, A. **Mãos à Obra: Aprendizado de Máquina com Scikit-Learn e TensorFlow.** São Paulo: Starlin Alta Editora e Consultoria Eireli, 2019.

Meneses, L. C. d. Trabalho de Conclusão de Curso (Graduação em Engenharia Mecânica), **Estudo de variáveis que afetam a vibração do corpo de um moinho vertical de rolos.** Russas: Universidade Federal do Ceará, Campus de Russas, 2023. Orientadora: Rosineide Fernando da Paz. Disponível em: <<http://repositorio.ufc.br/handle/riufc/75153>>.

Michalski, R. S.; KOUBA, J.; DAVIS, J. G. (Ed.). **Machine Learning: An Artificial Intelligence Approach. Volume III.** San Mateo: Morgan Kaufmann Publishers, 1990.

Mitchell, T. M. **Machine Learning.** New York: McGraw-Hill, 1997.

Montgomery, D. C.; PECK, E. A.; VINING, G. G. **Introduction to linear regression analysis.** 5. ed. Hoboken: John Wiley & Sons, 2012.

Neville, A. M. **Propriedades do Concreto.** 5. ed. São Paulo: Bookman, 2016.